FAIML HW1

姓名： 常志强
学号： PB25030753

第一题

(a)

$$y - Z = (f_*(x_0) + \epsilon) - Z = \epsilon + (f_*(x_0) - Z)$$

$$(y - Z)^2 = \epsilon^2 + 2\epsilon(f_*(x_0) - Z) + (f_*(x_0) - Z)^2$$

由于 ϵ 与 S 独立，且 $\mathbb{E}[\epsilon] = 0$，$\mathbb{E}[\epsilon^2] = \sigma^2$，我们可以将期望拆解：

$$\begin{aligned}\mathbb{E}_{S,\epsilon}[(y - Z)^2] &= \mathbb{E}_{S,\epsilon}[\epsilon^2] + 2\mathbb{E}_{S,\epsilon}[\epsilon(f_*(x_0) - Z)] + \mathbb{E}_{S,\epsilon}[(f_*(x_0) - Z)^2] \\ &= \mathbb{E}_{\epsilon}[\epsilon^2] + 2\mathbb{E}_{\epsilon}[\epsilon] \cdot \mathbb{E}_S[f_*(x_0) - Z] + \mathbb{E}_S[(f_*(x_0) - Z)^2] \\ &= \sigma^2 + 0 + \mathbb{E}_S[(f_*(x_0) - Z)^2]\end{aligned}$$

$$\begin{aligned}\mathbb{E}_S[(f_*(x_0) - Z)^2] &= \mathbb{E}_S[(f_*(x_0) - m + m - Z)^2] \\ &= \mathbb{E}_S[(f_*(x_0) - m)^2 + 2(f_*(x_0) - m)(m - Z) + (m - Z)^2] \\ &= (f_*(x_0) - m)^2 + 2(f_*(x_0) - m)\mathbb{E}_S[m - Z] + \mathbb{E}_S[(m - Z)^2]\end{aligned}$$

- 因为 $(f_*(x_0) - m)^2$ 对 S 是常数，可以直接提出。
- 因为 $\mathbb{E}_S[m - Z] = m - \mathbb{E}_S[Z] = 0$，所以第二项为 0。
- 最后一项 $\mathbb{E}_S[(m - Z)^2]$ 正好是 Z 的方差 $\mathrm{Var}_S(Z)$。

因此：

$$\mathbb{E}_S[(f_*(x_0) - Z)^2] = (m - f_*(x_0))^2 + \mathrm{Var}_S(Z)$$

代回原式，得

$$\mathbb{E}_{S,\epsilon}[(y - Z)^2] = \sigma^2 + (m - f_*(x_0))^2 + \mathrm{Var}_S(Z)$$

(b)

1. 若模型的平均预测等于真实条件均值，则期望测试误差一定为零。

- 判断：错误
- 理由： 当 $m = f_*(x_0)$ 时，偏差平方项 $(m - f_*(x_0))^2 = 0$。但期望测试误差还包含测试噪声 σ^2 和模型预测方差 $\mathrm{Var}_S(Z)$，除非这两项同时为零，否则期望测试误差不为零。

2. 在测试噪声不变时，若平方偏差的增加小于预测方差的减少，则期望测试误差下降。

- 判断：正确
- 理由： 期望测试误差由三项相加组成，当测试噪声 σ^2 保持不变时，偏差平方的增加小于方差的减少，则满足 $\Delta\mathrm{Bias}^2 + \Delta\mathrm{Var} < 0$，期望测试误差就会下降。

3. 模型的训练误差越低，其泛化表现越好。

- 判断：错误
- 理由： 训练误差低并不必然意味着泛化表现好。模型可能过度拟合了训练数据中的噪声，导致训练误差极低，但预测方差 $\mathrm{Var}_S(Z)$ 变大，从而使得泛化（期望测试）误差变大。

第二题

(a) 单输出损失与可加分解

第 j 个输出的均方误差为

$$L_j(w_j) = \frac{1}{N}\sum_{i=1}^{N}\big(w_j \cdot \phi(x_i) - y_{ij}\big)^2.$$

总平方损失为

$$L(W) = \frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{n}\big(w_j \cdot \phi(x_i) - y_{ij}\big)^2 = \sum_{j=1}^{n} L_j(w_j).$$

即

$$L(W) = L_1(w_1) + L_2(w_2) + \cdots + L_n(w_n).$$

只改变 w_k、保持其他 w_j $(j \neq k)$ 不变时，只有第 k 个损失项 $L_k(w_k)$ 可能变化；所有 $j \neq k$ 的 $L_j(w_j)$ 完全不含 w_k，因此不变。

理由：模型中第 j 个输出为

$$f_j(x) = w_j \cdot \phi(x),$$

它只依赖于第 j 列参数 w_j。所以改变 w_k 只影响第 k 个输出的预测及对应损失。

(b)

可以。

各输出的最优参数：

$$w_j^* \in \arg\min_{w_j} L_j(w_j), \qquad j = 1, \ldots, n,$$

组合成

$$W^* = [w_1^*, w_2^*, \ldots, w_n^*].$$

则 W^* 是联合损失 $L(W)$ 的最优解。

证明：

独立最优推导联合最优：

对任意 $W = [w_1, \ldots, w_n]$，有

$$L(W) = \sum_{j=1}^{n} L_j(w_j) \geq \sum_{j=1}^{n} L_j(w_j^*) = L(W^*).$$

因此独立最优解的组合 W^* 是联合最优解。

联合最优推导独立最优：

设

$$\bar{W} = [\bar{w}_1, \ldots, \bar{w}_n]$$

是联合损失 $L(W)$ 的最优解。固定其他列不动，只把第 j 列换成任意 $v \in \mathbb{R}^d$，得到

$$W' = [\bar{w}_1, \ldots, \bar{w}_{j-1}, v, \bar{w}_{j+1}, \ldots, \bar{w}_n].$$

则

$$L(W') = L_j(v) + \sum_{k \neq j} L_k(\bar{w}_k).$$

由 $\bar{W}$ 联合最优，

$$L(W') \geq L(\bar{W}) = L_j(\bar{w}_j) + \sum_{k \neq j} L_k(\bar{w}_k).$$

消去相同项得

$$L_j(v) \geq L_j(\bar{w}_j)$$

对任意 v 成立。因此

$$\bar{w}_j \in \arg\min_{w_j} L_j(w_j).$$

所以联合最优解的每一列参数也分别是最优的。

因此分别最小化各L_j后组合，与联合最小化L等价。

这里不需要假设不同输出在统计上独立。

原因：总损失在代数上可以分解为各输出损失之和，且各输出参数不耦合，所以不需要统计独立性。

(c)

不能直接组合两个单输出问题的最优解。

当 $n = 2$ 且要求

$$w_1 = w_2 = w$$

时，总损失变为

$$L_{\text{shared}}(w) = L_1(w) + L_2(w).$$

设两个单输出问题的最优解分别为

$$w_1^* = \arg\min_w L_1(w), \qquad w_2^* = \arg\min_w L_2(w),$$

且它们唯一且不同：

$$w_1^* \neq w_2^*.$$

无约束时，各自的最小值为

$$L_1(w_1^*), \qquad L_2(w_2^*).$$

若希望在共享参数下同时达到这两个最小值，就需要存在 w 使得

$$L_1(w) = L_1(w_1^*), \qquad L_2(w) = L_2(w_2^*).$$

由于最优解唯一，这要求

$$w = w_1^* \quad \text{且} \quad w = w_2^*,$$

即

$$w_1^* = w_2^*,$$

与假设矛盾。因此不存在一个共享的 w 能同时达到两个单输出问题各自的无约束最小值。

事实上，对任意 w，

$$L_{\text{shared}}(w) = L_1(w) + L_2(w) > L_1(w_1^*) + L_2(w_2^*)$$

所以共享约束下的最优值严格大于两个无约束最优值之和。

在 (b) 中，等价性依赖于“各输出的参数向量 w_j 可以独立选择”，即损失可分解为

$$L(W) = \sum_{j=1}^{n} L_j(w_j),$$

且各变量互不重叠。加入 $w_1 = w_2$ 后，参数发生耦合，不能再对两列独立最小化，因此 (b) 的独立优化条件不再满足。

第三题

(a)

$$\Phi(x) = [1, x_1, x_2]^T$$

$$\Phi = \begin{bmatrix} 1 & 1 & 0 \\ 1 & 0 & 1 \\ 1 & 1 & 1 \\ 1 & -1 & 0 \\ 1 & 0 & -1 \\ 1 & -1 & -1 \end{bmatrix}, \quad y = \begin{bmatrix} 2 \\ 0 \\ 3 \\ -4 \\ -2 \\ -5 \end{bmatrix}$$

$$\Phi \in \mathbb{R}^{6\times 3}, \qquad y \in \mathbb{R}^{6\times 1}$$

如果 $\exists w_A \in \mathbb{R}^3$，使得

$$f_w(x_i) = y_i, \quad i = 1, \dots, 6$$

对六条样本成立，则

$$\Phi w_A = y$$

有解，解得

$$w_A = [-1, 3, 1]^T$$

(b)

设

$$w = (w_0, w_1, w_2)^T$$

目标函数为

$$J_\lambda(w) = \frac{1}{6}\|\Phi w - y\|^2 + \lambda \|Pw\|_2^2$$

展开得

$$\begin{aligned} J_\lambda(w) = \frac{1}{6}\Big[&(w_0 + w_1 - 2)^2 + (w_0 + w_2)^2 + (w_0 + w_1 + w_2 - 3)^2 \\ &+ (w_0 - w_1 + 4)^2 + (w_0 - w_2 + 2)^2 + (w_0 - w_1 - w_2 + 5)^2\Big] \\ &+ \lambda(w_1^2 + w_2^2) \end{aligned}$$

整理得

$$\begin{aligned} J_\lambda(w) = &\frac{1}{6}(6w_0^2 + 4w_1^2 + 4w_2^2 + 4w_1 w_2) \\ &- \frac{1}{3}(-6w_0 + 14w_1 + 10w_2) + \frac{29}{3} + \lambda(w_1^2 + w_2^2) \end{aligned}$$

梯度为

$$\nabla J_\lambda(w) = \frac{1}{3}\Phi^T(\Phi w - y) + 2\lambda P w$$

展开得

$$\nabla J_\lambda(w) = \begin{pmatrix} 2w_0 + 2 \\ \dfrac{4w_1 + 2w_2 - 14}{3} + 2\lambda w_1 \\ \dfrac{2w_1 + 4w_2 - 10}{3} + 2\lambda w_2 \end{pmatrix}$$

(c)

残差为

$$r^{(0)} = \Phi w^{(0)} - y = (-1, -1, -3, 3, 3, 5)^T$$

梯度为

$$\nabla J_\lambda(w^{(0)}) = \left(2, -\frac{10}{3}, -\frac{14}{3}\right)$$

更新公式为

$$\begin{aligned} w^{(1)} &= w^{(0)} - \eta \nabla J_\lambda(w^{(0)}) \\ &= (0,1,-1)^T - \frac{1}{4}\left(2, -\frac{10}{3}, -\frac{14}{3}\right)^T \\ &= \left(-\frac{1}{2}, \frac{11}{6}, \frac{1}{6}\right)^T \end{aligned}$$

目标函数值为

$$\begin{aligned} J_\lambda(w^{(0)}) &= \frac{1}{6}\|r^{(0)}\|^2 + \lambda \|P w^{(0)}\|_2^2 \\ &= \frac{1}{6} \times 54 + \frac{1}{3} \times 2 \\ &= \frac{29}{3} \end{aligned}$$

以及

$$\begin{aligned} J_\lambda(w^{(1)}) &= \frac{1}{6}\|\Phi w^{(1)} - y\|^2 + \lambda \|P w^{(1)}\|_2^2 \\ &= \frac{367}{108} \end{aligned}$$

因此

$$J_\lambda(w^{(1)}) < J_\lambda(w^{(0)})$$

说明这次更新使目标函数下降。

(d)

对于 w_A，由于

$$\Phi w_A = y$$

所以

$$L(w_A) = 0$$

$$\|P w_A\|_2^2 = 9 + 1 = 10$$

在 3 个验证样本上：

$$MSE = \frac{1}{3}\sum_{i=1}^{3}(f_{w_A}(x_i) - y_i)^2 \quad = \frac{1}{3}\left(1^2 + 0^2 + (-2)^2\right) = \frac{5}{3}$$

对于 w_B，有

$$r = \Phi w_B - y = (-1, 0, -1, 1, 0, 1)^T$$

损失为

$$L(w_B) = \frac{1}{6}(1+1+1+1) = \frac{2}{3}$$

$$\|Pw_B\|_2^2 = w_{B1}^2 + w_{B2}^2$$

验证 MSE 为

$$\begin{aligned} MSE &= \frac{1}{3}\sum_{i=1}^{3}(w_B(x_i) - y_i)^2 \\ &= \frac{1}{3}\left((-2)^2 + (-1)^2 + (-1)^2\right) \\ &= 2 \end{aligned}$$

根据验证结果，应选择 w_A，因为 w_A 在验证集上表现更好。

在计算验证 MSE 时，不应加入正则惩罚项，因为验证集评估的是泛化误差，而正则项是模型复杂度的控制，两者不应混在一起。

(e)

由全局最优性可知：

$$J_{\lambda_1}(w^{(1)}) \le J_{\lambda_1}(w^{(2)})$$

以及

$$J_{\lambda_2}(w^{(2)}) \le J_{\lambda_2}(w^{(1)})$$

展开可得：

$$L(w_1) + \lambda_1\|Pw_1\|^2 \le L(w_2) + \lambda_1\|Pw_2\|^2$$

$$L(w_2) + \lambda_2\|Pw_2\|^2 \le L(w_1) + \lambda_2\|Pw_1\|^2$$

移项得

$$\lambda_1\left(\|Pw_1\|^2 - \|Pw_2\|^2\right) \le L(w_2) - L(w_1) \qquad (①)$$

$$\lambda_2\left(\|Pw_2\|^2 - \|Pw_1\|^2\right) \le L(w_1) - L(w_2)$$

两边相加得

$$(\lambda_1 - \lambda_2)\left(\|Pw_1\|^2 - \|Pw_2\|^2\right) \le 0$$

将

$$\|Pw^{(2)}\|^2 \le \|Pw^{(1)}\|^2$$

代入 ① 中，可得

$$L(w^{(2)}) \ge L(w^{(1)})$$

增大 λ 不一定降低 MSE。

- λ 过小时，模型容易过拟合；
- λ 过大时，模型容易欠拟合；
- MSE 在这两种情况下都可能较大。

(f)

设 $L_0(w)$ 为原始损失。使用普通梯度下降：

$$\begin{aligned} w^{(t+1)} &= w^{(t)} - \eta \nabla L_0(w^{(t)}) - 2\eta\lambda w^{(t)} \\ &= (1 - 2\eta\lambda) w^{(t)} - \eta \nabla L_0(w^{(t)}) \end{aligned}$$

使用权重衰减更新：

$$w^{(t+1)} = D_c w^{(t)} - \eta \nabla L_0(w^{(t)})$$

两者等价时

$$c = 1 - 2\eta\lambda = 1 - 2 \times \frac{1}{4} \times \frac{1}{3} = \frac{5}{6}$$

D_c 的第一个对角元素为 1，因为第一个权重 w_0 为截距。若对截距进行衰减，会生成不必要的整体平移偏差。

这与正则化矩阵

$$P = \mathrm{diag}(0, 1, 1)$$

的第一个对角元素为 0 相呼应。

因此

$$D_c = \mathrm{diag}(1, c, c)$$

只衰减 w_1 和 w_2，不衰减截距 w_0。

第四题

(a)

在数据集上：

$$L_A(t) = \sigma^6(t) \left(1 - \sigma(t)\right)^2$$

$$\begin{aligned} J_A(t) &= -\frac{1}{8} \ln L_A(t) \\ &= -\frac{3}{4} \ln \sigma(t) - \frac{1}{4} \ln(1 - \sigma(t)) \end{aligned}$$

$$L_B(t) = \sigma^8(t)$$

$$J_B(t) = -\frac{1}{8} \ln L_B(t) = -\ln \sigma(t) = \ln(1 + e^{-t})$$

一般地，

$$J(t) = -\frac{1}{8} \ln L(t)$$

由于 $\ln x$ 在 $(0,+\infty)$ 上单调递增，因此

$$\min L_D(t) \iff \max J_D(t), \qquad J_D(t) = -\frac{1}{n}\ln L_D(t)$$

所以最大化似然等价于最小化负对数似然损失。

(b)

令

$$s = \sigma(t)$$

则

$$J_A(t) = -\frac{3}{4}\ln s - \frac{1}{4}\ln(1-s) = f(s)$$

求导得

$$\frac{\partial f}{\partial s} = -\frac{3}{4}\cdot\frac{1}{s} + \frac{1}{4}\cdot\frac{1}{1-s} = \frac{4s-3}{4s(1-s)}$$

令

$$\frac{\partial f}{\partial s} = 0$$

得

$$s = \frac{3}{4}$$

又因为

$$f''(s) = \frac{3}{4s^2} + \frac{1}{4(1-s)^2} > 0$$

所以 $f(s)$ 为严格凸函数，在 $s=\frac{3}{4}$ 处取得唯一最小值：

$$f\left(\frac{3}{4}\right) = 2\ln 2 - \frac{3}{4}\ln 3$$

此时 $J_A(t)$ 最小，最优参数 t 满足

$$\sigma(t) = \frac{3}{4}$$

即

$$\frac{1}{1+e^{-t}} = \frac{3}{4} \quad \Rightarrow \quad e^{-t} = \frac{1}{3} \quad \Rightarrow \quad t = \ln 3$$

唯一性证明：

$$J_A'(t) = \sigma(t) - \frac{3}{4}$$

$$J_A''(t) = \sigma(t)(1-\sigma(t)) > 0$$

因此 $J_A(t)$ 在 $\mathbb{R}$ 上为严格凸函数，仅有唯一驻点，故最优解唯一。

对于数据集 B：

$$J_B(t) = \ln(1 + e^{-t})$$

当

$$t \to +\infty$$

时，

$$J_B(t) \to 0$$

且

$$1 + e^{-t} > 1 \quad \Rightarrow \quad J_B(t) > 0$$

因为

$$\inf_t J_B(t) = 0$$

所以不存在有限参数 t 使其达到下确界 0。

原因：

- 数据集 A 在每个 x 处标签有重叠，错误率非零，因此最优解为有限值；
- 数据集 B 完全线性可分，无限增大 t 会使所有真实标签概率趋于 1，损失趋于 0，无法在有限值达到最优。

(c)

放大前决策边界：

$$P(y = 1 \mid x) = \sigma(tx) = \frac{1}{2}$$

$$\iff tx = 0 \iff x = 0$$

放大后决策边界：

$$P(y = 1 \mid x) = \sigma(ctx) = \frac{1}{2}$$

$$\iff ctx = 0 \iff x = 0$$

因此决策边界不变。

对于数据 B：

- 分类错误率：由于决策边界不变，分类错误率也不变，保持为 0；
- 真实标签预测概率：放大前为 $\sigma(t)$，放大后为 $\sigma(ct)$。若 $c > 1,\ t > 0$，则

$$\sigma(ct) > \sigma(t)$$

即预测概率增大；

- 平均负对数似然：

$$J_B(t) = -\ln \sigma(t), \qquad J_B(ct) = -\ln \sigma(ct)$$

因为

$$\sigma(ct) > \sigma(t) \iff J_B(ct) < J_B(t)$$

所以平均负对数似然下降。

差异原因：

分类错误率只关心预测值是否越过阈值，已经为 0 后无法继续降低；而概率和负对数似然关心置信度，放大权重会让模型更加“自信”，使真实标签概率更接近 1，因此负对数似然继续下降。

(d)

1. 错误。

在数据集 B 上，任意 $t > 0$ 都有分类错误率为 0，但 $J_B(t)$ 的下界为 0，有限 t 达不到。因此分类错误率为 0 不等同于负对数似然已经最小。

2. 错误。

训练样本上的真实标签概率接近 1，只说明模型在训练集上越来越自信，可能是过拟合。对于测试数据，若模型过度自信或测试分布与训练分布存在差异，测试平均负对数似然反而可能变差。训练损失下降不能保证测试损失下降。

加入 L2 正则项为什么能抑制权重无限增大

在数据集 D_B 上，无正则化时

$$J_B(t) = \ln(1 + e^{-t})$$

当 $t \to +\infty$ 时损失趋近于 0，因此模型会倾向于让 t 无限增大。

加入正则项后，目标变为

$$J_B(t) + \lambda t^2 = \ln(1 + e^{-t}) + \lambda t^2, \qquad \lambda > 0$$

当 t 很大时，数据损失已经很小且趋于常数 0，但二次惩罚 λt^2 会迅速增大并最终主导目标函数。因此最优的 t 被限制在有限范围内，不会无限增大，从而抑制权重过大和过度自信。