FAIML Lab1 实验报告

常志强
PB25030753

2026 年 10 月 21 日

1 思考题

1. 复现 ℓ_1 / ℓ_2 系数路径与数据来源

题面：重现课件（第 42、48 页）中 ℓ_1、ℓ_2 正则化的“系数路径”，并解释数据来源。

（1）数据来源。课件 p42/p49 的 8 个特征列（bedrooms、bathrooms、sqft_living、sqft_lot、floors、yr_built、yr_renovated、waterfront）与 Kaggle 数据集 House Sales in King County, USA（`https://www.kaggle.com/datasets/harlfoxem/housesalesprediction`，CC0 许可）的列名完全一致，由此判定课件图的数据来源即该数据集。本实验下载自该数据集的 GitHub 镜像（`https://raw.githubusercontent.com/Willie-Conway/House-Sales-Price-Prediction-King-County-USA-Project/main/House-Sales-Price-Prediction/housing.csv`）。

（2）数据处理（根据讲义）。课件 p20 批注“all features normalized so coeff. on same scale”，于是笔者对 8 个特征做了标准化，使各特征系数处于同一尺度。同时剔除数据集中含缺失的 16 行（21613 → 21597，占 0.07%）。λ 取 0 至 2×10^5 共 201 个等距点，与课件一致。

（3）复现结果与简单分析。$\lambda = 0$ 处的最小二乘解（单位：美元/σ）为 sqft_living 268 160、waterfront 63 307、bathrooms 49 137、floors 28 399、yr_renovated 3 397、sqft_lot −12 378、bedrooms −56 868、yr_built −92 382，与课件量级一致。ℓ_2（Ridge）路径**只缩不归零**，其中 bedrooms 与 bathrooms 在 $\lambda \lesssim 2 \times 10^4$ 先升后降。ℓ_1（Lasso）路径随 λ 增大**精确归零**，归零顺序为 sqft_lot (9k) → yr_renovated (13k) → bedrooms (21k) → floors (23k) → bathrooms (26k) → yr_built (45k) → waterfront (79k)，至 $\lambda = 2 \times 10^5$ 只剩 sqft_living（57.7k）。综上，两条路径的趋势与量级均与课件一致。

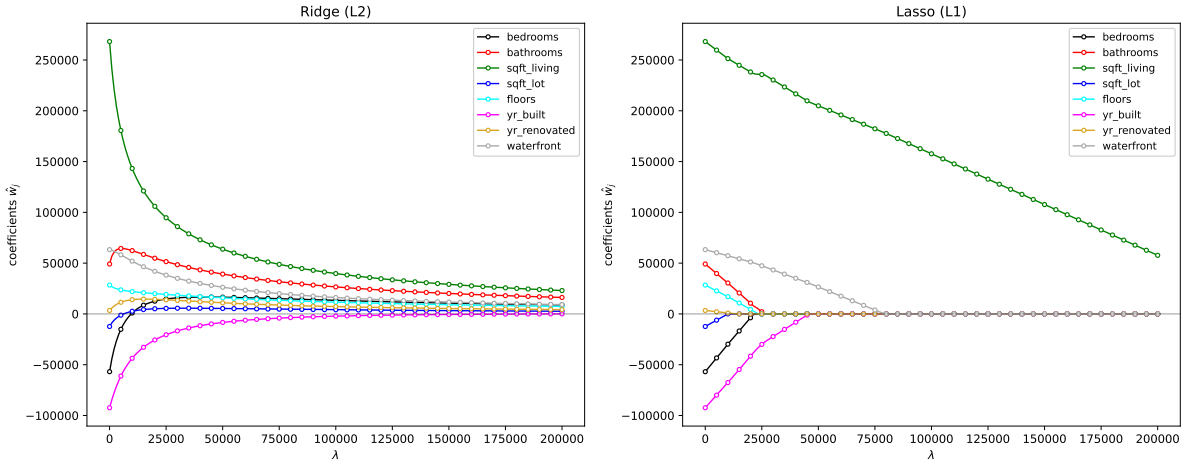


图 1: King County 数据（8 特征 z-score、price 中心化）的系数路径。左：Ridge（ℓ_2）——只缩不归零；右：Lasso（ℓ_1）——精确归零，sqft_living 保留到最后。

2. 用案例说明 ℓ_2 阈值化做特征选择为什么不好

题面：请用案例说明 ℓ_2 正则化在回归中将很小的系数设为 0 进行特征选择是不好的（相比 ℓ_1 正则化，课件第 44 页）。

（1）案例设置。在 Q1 的 8 列基础上加入 sqft_above 构成 9 特征（它与 sqft_living 的相关 $r = 0.876$，是最强共线对，两者形成强共线性对），对数据进行标准化后，考察“$|w_j| < \tau$ 视为 0”的阈值化特征选择。

（2）阈值化 Ridge 的三个问题。第一，选择结果高度依赖阈值与路径：同一 Ridge 拟合（$\lambda = 2 \times 10^4$）下，$\tau = 10^4 \to 2 \times 10^4 \to 5 \times 10^4 \to 10^5$ 对应选中 $7 \to 5 \to 2 \to 0$ 个特征，$\tau = 10^5$ 时连 sqft_living 都被删空；固定 $\tau = 10^4$ 沿 λ 扫描，保留集跳变 11 次、含 3 次“回升”。相比之下，Lasso 的零模式沿 λ 特征数逐渐减少。第二，笔者构造出的共线组被“平摊”后整组删除：预测依赖共线组内两个系数之和，多个系数可能都较小但总体权重较高。例如对于构造的共线组，在 $\tau = 10^5$ 下单特征模型保留、9 特征模型两个成员双双被删。为了表现极端情况，笔者用了合成数据（其中两个特征 $x_2 \equiv x_1$）把机制推到极限：Ridge 精确对半，会被删掉整组，而 Lasso 保留一个代表 $(237\,689,\, 0)$。

（3）原因分析。阈值化把“收缩量”误当“重要性”：Ridge 的 $\hat{w}(\lambda)$ 恒非零且连续收缩，大 λ 下全体都小，但系数小并不代表不重要；共线时 $|w_j|$ 更不是重要性度量，共线的特征过多就能把每个系数压到阈值之下；τ 还是人为引入的第二个超参数，没有目标函数可供优化，选择集随 τ、λ 与数据扰动跳变。相反，ℓ_1 的零来自 KKT 条件与软阈值，特征数沿 λ 单调递减、仅由单一超参数控制，对共线组保留一个代表。综上，ℓ_2 阈值化做特征选择是不好的，ℓ_1 才是合理的。

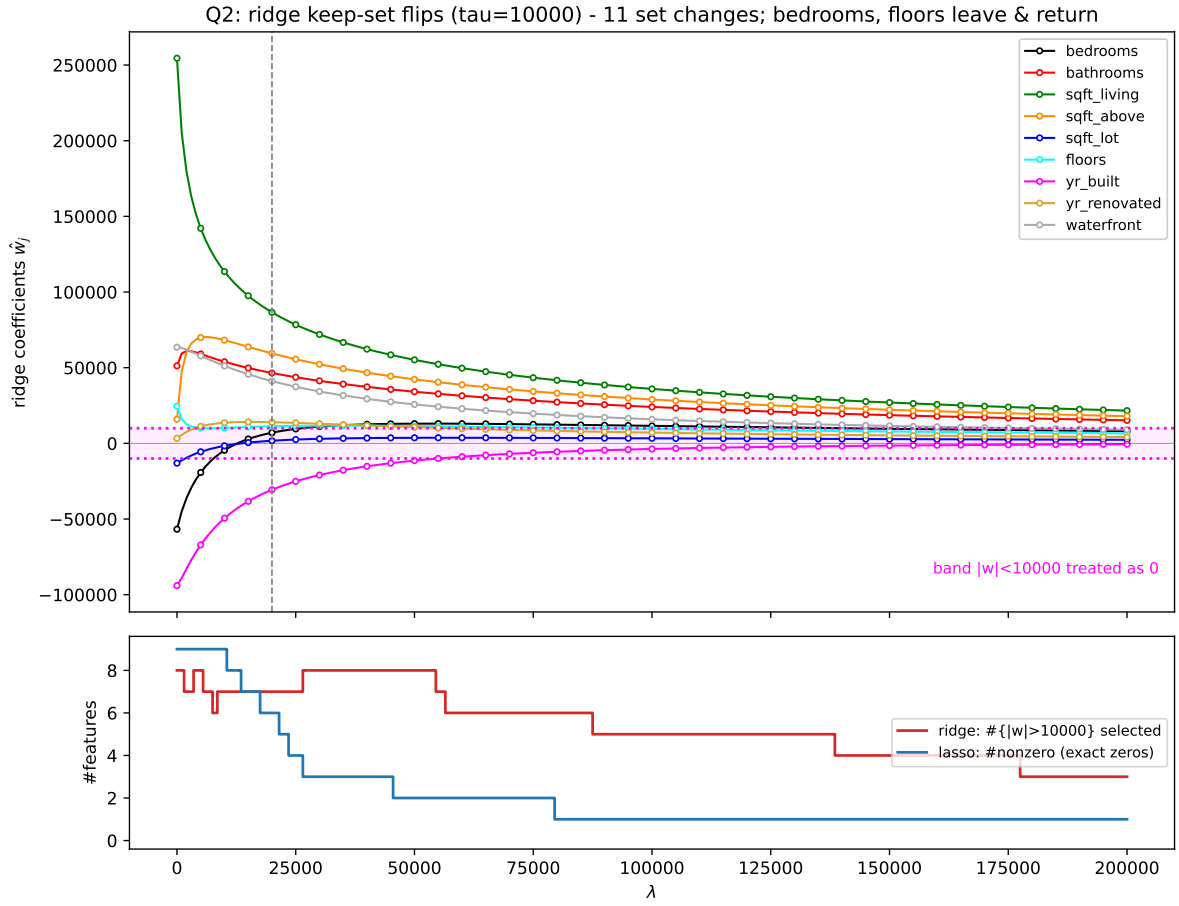


图 2: 阈值化 ridge 的“选择路径”连单调性都不满足：$\tau = 10^4$ 时保留计数沿 λ 跳变 11 次（含 3 次回归）；lasso 非零数严格单调。

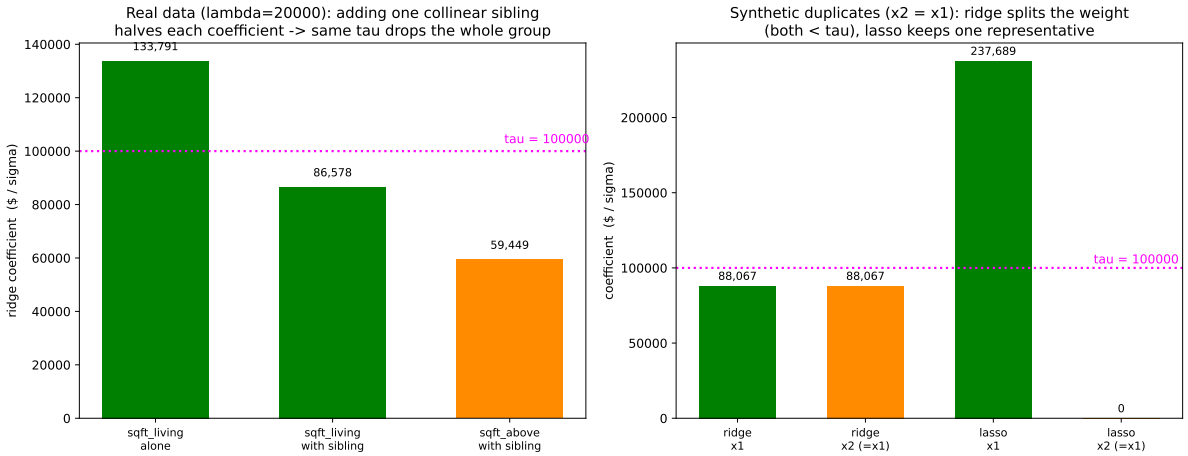


图 3: 共线案例：加入一个共线兄弟即可让每个系数减半、$\tau = 10^5$ 下整组被删（133 791 → 86 578 + 59 449）；lasso 组内保留一个代表（237 689, 0）。

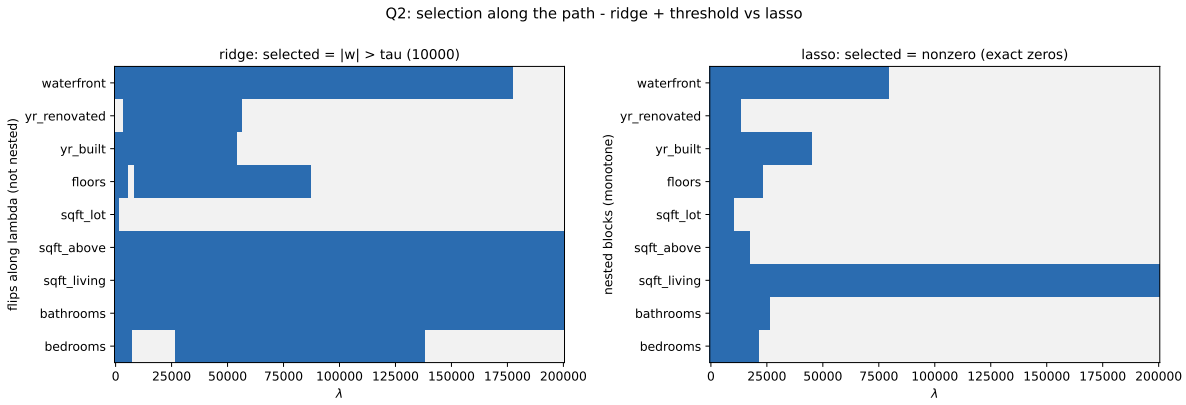


图 4: 结构判据：ridge 阈值化选择集不嵌套（bedrooms、floors 离而复返）；lasso 零模式严格嵌套，每特征仅一个连续非零窗口 $[0, \lambda^*]$。

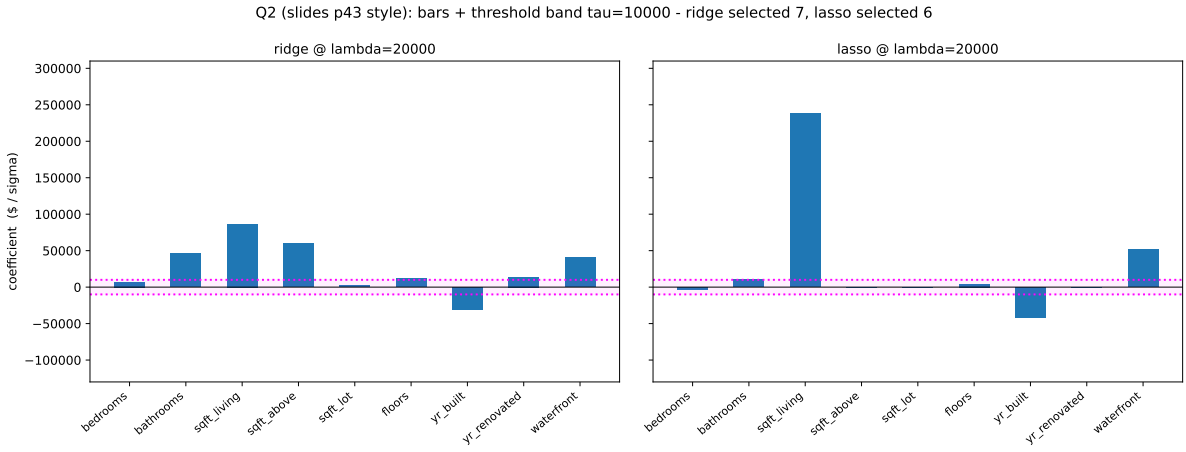


图 5: 同一 $\lambda = 2\times10^4$ 截面（p43 画风）：阈值化 ridge 与 lasso 的保留集在 bedrooms、yr_renovated、sqft_above 三个特征上互相矛盾；τ 从 10^4 扫到 10^5，ridge 保留数 $7 \to 5 \to 2 \to 0$。

3. 与 sklearn 实现有拟合效果差异吗

题面：你的模型相比于 sklearn 的实现有拟合效果上的差异吗？（简要说明即可）（提示：可以在做完后两项实验后回答该题。）

（1）先把两边的正则强度对齐。因为两边正则参数的写法不同，需要先对齐。不换算可能会把“超参不同”当成“实现不同”。本实验的目标函数是 $(1/N)\cdot\text{loss}+\lambda_1\|w\|_1+\lambda_2\|w\|_2^2$，换算到 sklearn 是 Ridge $\alpha=N\lambda_2$、Lasso $\alpha=\lambda_1/2$、ElasticNet $\alpha\rho=\lambda_1/2$ 且 $\alpha(1-\rho)=\lambda_2$、逻辑回归 $C=1/(2N\lambda_2)$。对比用三组数据：world L11 的 z-score 版和 raw 版（$N=500$）、truth L20（raw，$N=5088$）；指标来自提交用的 `model.py`，收敛曲线用更新式一致的副本。

（2）结论：没有本质差异。同一个目标函数只要都充分收敛，两边就是同一个解——A2/A4 行 cos $=1.00000$、relL2 $=0.002$。看到的差别都来自三类“非模型因素”。一是优化器：手写 GD 是固定步长，步子不能超过稳定界；world raw L11 无正则时界约 5.4×10^{-4}，取 lr$=10^{-3}$ 第 8 轮 loss 就爆到 1.14×10^{10}，被自动中止，而 sklearn 用精确求解器，没有步长问题。二是训练预算：轮数有限，相当于提前停在一个权重较小的点，反而起到正则作用，valid 更好（A1 $306.55<311.56$、B1 $223.58<395.02$、T2 $0.8867>0.8600$）；继续训练会向 sklearn 的解靠拢（cos $0.897\to0.997$），valid 可能变差（B2b 162.4 vs B2 150.4）。三是正则强度的定义：sklearn 默认 $C=1$ 时 truth valid 只有 0.8500，不换算就会误判。

（3）一处反例。T1 行里，sklearn 不做正则（`penalty=None`）的 valid 对数损失高达 27.77。原因是 truth 训练集近似线性可分，无正则的最优解在无穷远，精确求解会把权重一路推大；手写 GD 只有有限轮，相当于提前停住（ll 0.255），反而稳。一句话总结：差异是**优化差异**（步长、求解器、训练轮数、早停），不是模型或实现差异。

行	设置（ours 口径）	sklearn 等价	ours valid	sk valid	cos	relL2
A1	world z-score，无正则，ep20000	LinearRegression	306.55	311.56	0.99929	0.039
A2	world z-score，$\lambda_2=1.0$	Ridge $\alpha=500$	167.06	167.17	1.00000	0.002
A3	world z-score，$\lambda_1=10^{-3}$	Lasso $\alpha=5\times10^{-4}$[a]	238.36	598.47	0.594	0.814
A4	world z-score，$\lambda_1=10^{-3}+\lambda_2=1.0$	ElasticNet	167.04	167.16	1.00000	0.002
B1	world raw，无正则，ep20000	LinearRegression	223.58	395.02	0.871	0.573
B2	world raw，历史最优，ep2000	ElasticNet	150.43	165.34	0.897	0.475
B2b	world raw，历史最优，ep20000	ElasticNet	162.36	165.34	0.997	0.082

表 1: world（L11，valid MSE；小者好）与 sklearn 逐配置对比。[a]：A3 的 sklearn Lasso 未收敛到 tol（dual gap $\gg$ tol），数值仅供参考。

行	设置	ours acc	sk acc	ours ll	sk ll	cos
T1	无正则，ep4000	0.8867	0.8533	0.255	27.77	0.772
T2	$\lambda_2=10^{-3}$（sk $C\approx0.098$），ep5000	0.8867	0.8600	0.257	0.383	0.802
T2b	同 T2，ep10000	0.8733	0.8600	0.269	0.383	0.883
T3	最优配置 $\lambda_1=\lambda_2=10^{-3}$，ep5000	0.8967	0.8600	0.259	0.383	0.712

表 2: truth（L20，valid 准确率；大者好）与 sklearn 对比。T1 行 sklearn 无正则的 ll$=27.77$ 灾难：可分数据上 MLE 在无穷远。参考：sklearn 默认 $C=1$（更强正则）$\to$ valid 0.8500。

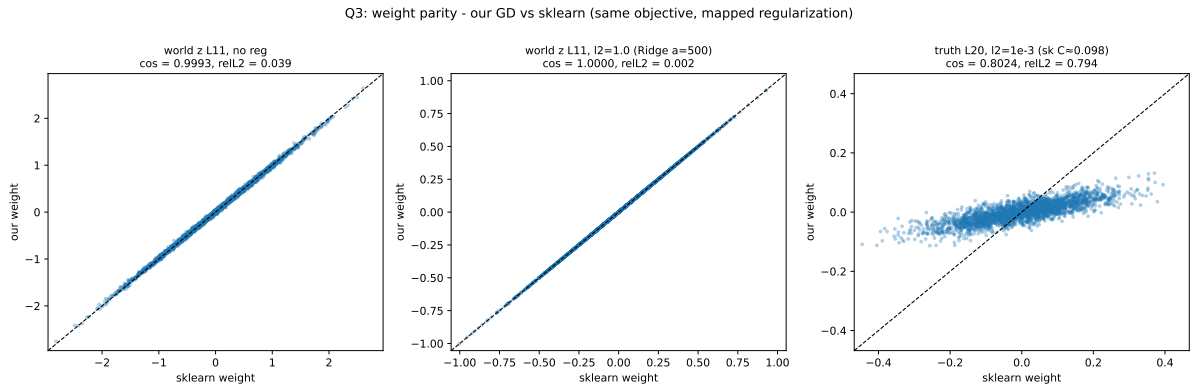


图 6: 对齐正则口径后权重逐点比对：world（$\lambda_2 = 1.0$）落在对角线上（cos = 1.00000）——同一目标函数充分收敛 ⇒ 同解；truth 未充分收敛时权重整体压向 0（relL2 = 0.794）。

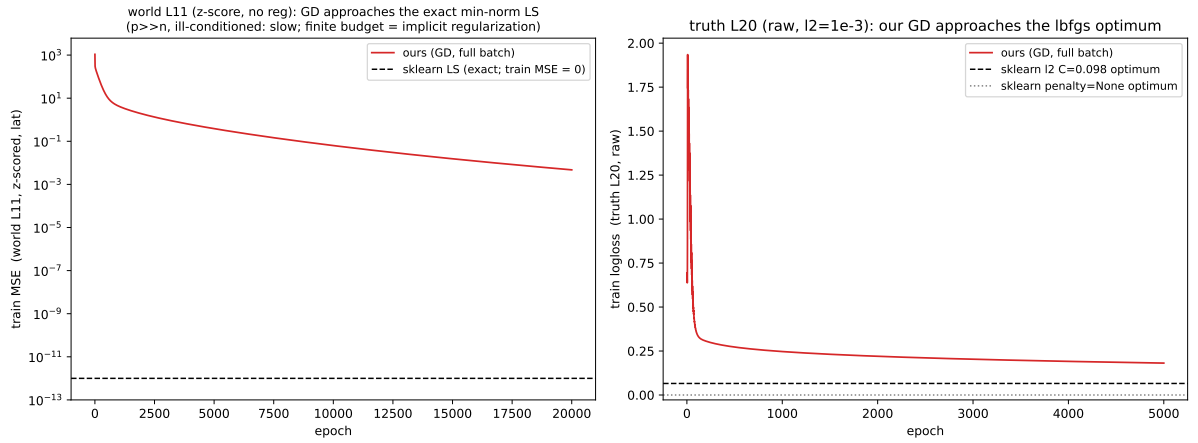


图 7: 收敛曲线：world（$p \gg n$ 病态）GD 20000 轮仅到 0.0047（精确 LS= 0）；truth GD 5000 轮停于 0.181，未达 lbfgs 最优 0.066——有限预算 GD 天然早停、起正则化作用。

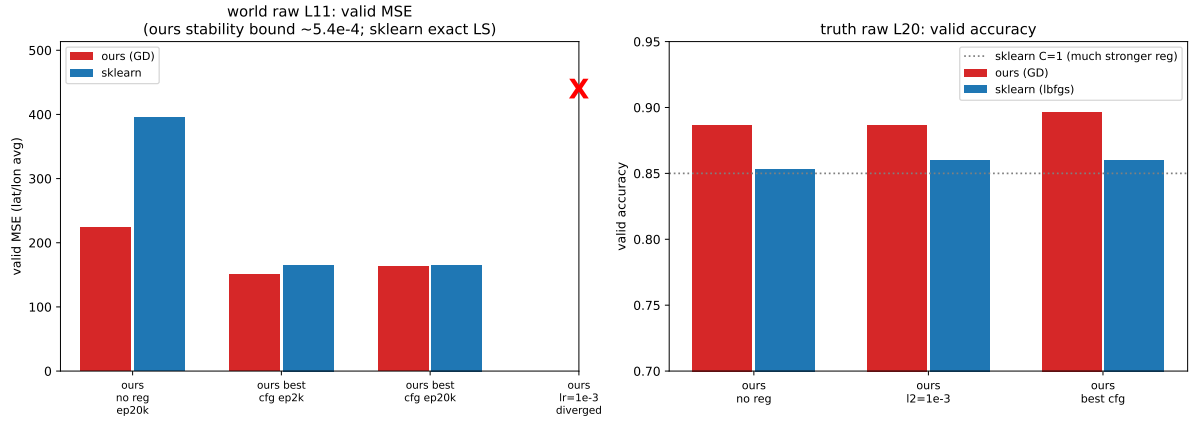


图 8: valid 指标总览：world raw 早停的 223.6 ≪ 精确 LS 的 395.0；lr= 10^{-3} 超稳定界第 8 轮发散（红叉）。truth：ours 全面不低于 lbfgs；灰线为 $C = 1$ 口径陷阱。

4. world：不同层中间表征的预测效果对比与选层

题面：对比不同层中间表征的预测效果，并分析原因；你在最终模型提交中是如何选择特征选取层次的？

（1）实验设置。实验提供了 11，23，35 共 3 层，笔者以 3 为间隔提取了另外十层，共计 13 层（$2, 5, \ldots, 35$）。由于实测时发现不同层按照统一的超参数会出现 loss inf 现象，所以对数据做了标准化，最后再把权重折算回去。采用了同一套配置做对照：lr$= 0.002$、2000 轮、$\lambda_2 = 1.0$、$\lambda_1 = 10^{-3}$。

（2）结果分析。曲线呈 **倒 U 形**：浅层 L2–L11 差异不显著，中层 L14–L29 明显更差（L17/L20/L23 显著），深层 MSE 先降后升。std 中最低为 L2（157.57），但与 L5/L8/L11 差异不显著；全场最低为 raw L11（150.43）——world 水平锁定在 150–167（$R^2 \approx 0.955$），继续调参并未发现显著收益。

（3）原因分析。world 的目标是位置坐标，这类信息在浅层表征中最接近线性可分；随层深增加，表征经过更多非线性变换、语义抽象增强，坐标的线性可读性下降，中层出现低谷。深层在 L29–L32 段 MSE 下降（L32 为局部最低 180.31），随后 L34/L35 又回升；下降的可能原因是深层把位置重新编码为更全局的线性方向。

（4）最终选层。提交选中 **L11**，有三个原因：一是 L11 与 L2/L5/L8 差异并不显著（可以参见表 3），L2 虽然略微好一点但是与 L11 差异不大；二是 L11 是实验本身提供的，与实验本身关联性更好；三是标准化一定程度上影响了 2，5，8，11 四层之间细微的差距，例如笔者对 L2 和 L11 在不进行标准化、统一超参数做了训练，发现 L11 略微优于 L2。综上所述，笔者选择 11 层作为最终选层。

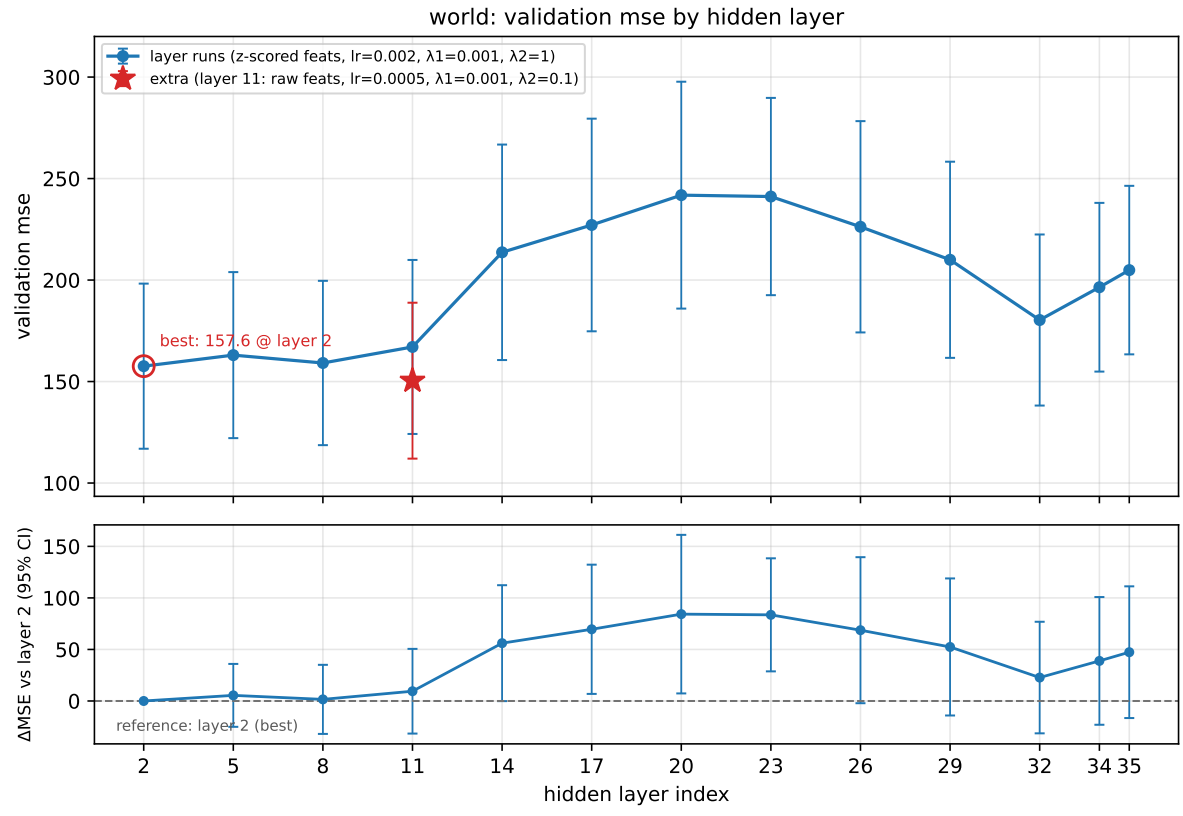


图 9: world 各层验证 MSE（上：±1 SE，红圈 = 最优 std 层，红星 = raw L11 extra；下：与 L2 的配对差 95% CI）。浅层平台—中层低谷—深层回升的倒 U 形。

层	配置	MSE	±SE	Δ vs L2（95% CI）	判定
2	std	**157.57**	40.7	参考	最优
5	std	163.02	40.9	$+5.4 \pm 30.5$	不显著
8	std	159.14	40.5	$+1.6 \pm 33.5$	不显著
11	std	167.04	42.9	$+9.5 \pm 41.1$	不显著
14	std	213.67	53.1	$+56.1 \pm 56.2$	边缘
17	std	227.13	52.4	$+69.6 \pm 62.7$	显著
20	std	241.83	55.9	$+84.3 \pm 76.9$	显著
23	std	241.14	48.6	$+83.6 \pm 54.8$	显著
26	std	226.25	52.0	$+68.7 \pm 70.8$	边缘
29	std	209.99	48.3	$+52.4 \pm 66.5$	不显著
32	std	180.31	42.1	$+22.7 \pm 54.1$	不显著
34	std	196.46	41.6	$+38.9 \pm 61.9$	不显著
35	std	204.91	41.5	$+47.3 \pm 63.9$	不显著
11	raw（extra）	**150.43**	38.4	—	全场最低

表 3: world 13 层验证 MSE 全表（含 raw extra）。

5. world：正则化与学习率的选择

题面：你在最终模型提交中是怎么选择正则化的？请说明理由；

（1）为什么正则化？world 是 $N = 500$、$D = 2560$，样本远少于维度，本身是一个欠定问题，必须正则化。默认的对照设置为 lr=0.003, epochs=2000, λ 1=0.001， λ 2=1, layer=11。

（2）正则扫描。固定其他，扫 λ_2：0.1 时训练残差已经很小（≈ 3），但 valid MSE 209，明显过拟合；1.0 最好（167.06）；3.0 正则强度过高，MSE 回升到 184.57。把 λ_1 从 0 扫到 0.1，valid MSE 只从 167.07 降到 165.82，差异不显著，所以后续沿用 10^{-3}。

（3）学习率扫描。学习率在稳定界内选（见后面对稳定界探索的说明），再用训练表现验证：标准化的 L11 的界是 3.6×10^{-3}，取 lr= 5×10^{-4}，$= 1 \times 10^{-3}$，$= 2 \times 10^{-3}$，$= 3 \times 10^{-3}$，5×10^{-3}。结果来看 lr== 1×10^{-3} 结果最好，故选择 lr== 1×10^{-3}。

（4）最终提交。第 4 题的 lr= 2×10^{-3}、$\lambda_2 = 1.0$ 是 13 层共用的对照配置；固定 L11 后可以单独选：**raw L11**（lr= 5×10^{-4}、2000 轮、$\lambda_2 = 0.1$）valid MSE **150.43**，λ_2 由首轮 88653 的 raw 扫描在 $\{0, 10^{-3}, 10^{-2}, 10^{-1}\}$ 中选出；备选 z-score L2（157.57，第 4 题 std 层里最好）。同层的 z-score 版（lr= 3×10^{-3}、$\lambda_2 = 1.0$）是 167.06，与第 4 题 L11 行（lr= 2×10^{-3}，167.04）只差平台内的 lr，说明两套配置对得上。raw L11 与 std L2 差 7.1，不显著（t= -0.46），按点估计和跨预处理稳健性选 raw（理由见第 4 题第（4）点）。训练脚本还带发散兜底：一旦发散就把 lr 减半重试，最多 4 次。推导见附录 D，扫描全表见附录 B。

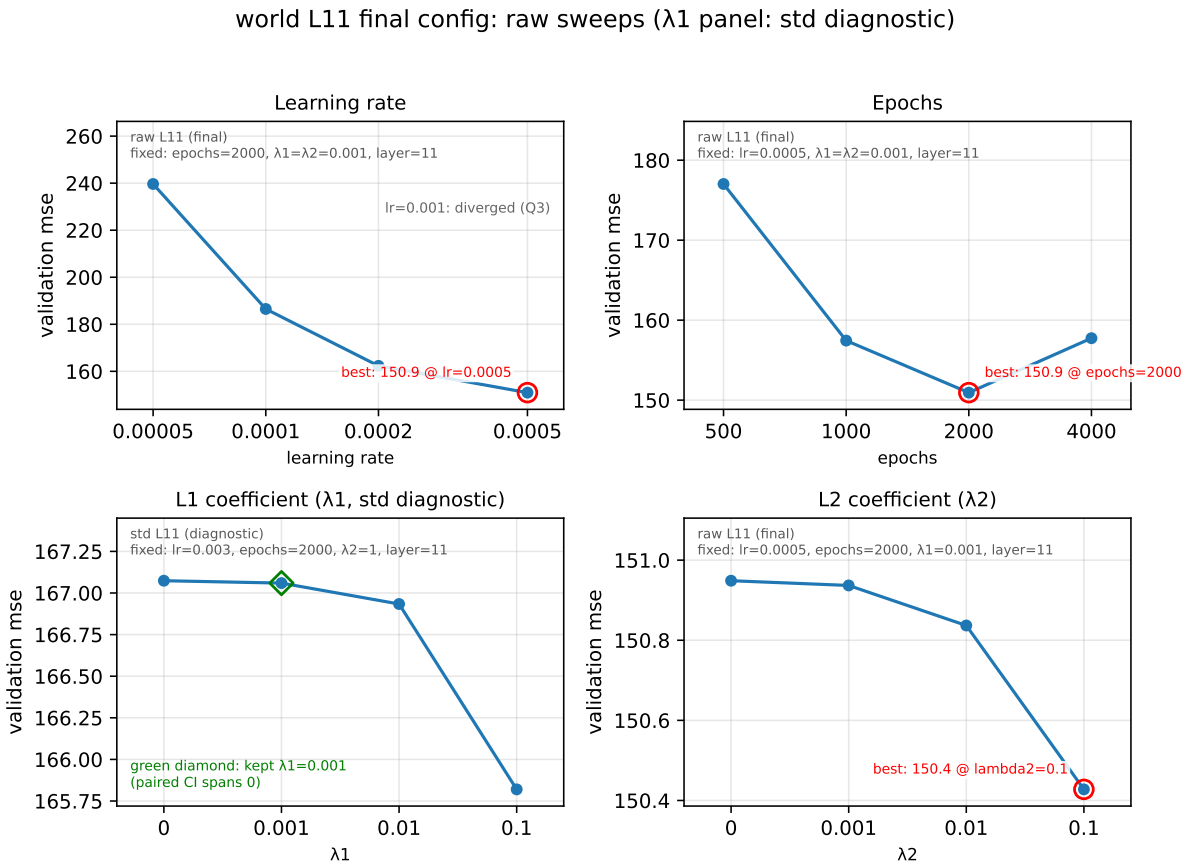


图 10: world 标准化重扫（20 次：原 16 次 + 补扫 λ_1 4 次；layer 组已在第 4 题讨论）：lr、epochs、λ_1、λ_2 对 valid MSE 的影响（$\lambda_1 = 0.1$ 点估计最低但配对不显著）；lr$= 5 \times 10^{-3}$ 被正确标记为发散（finite=False）。

6. 验证集预测的地图可视化

题面：给出你的模型在验证集上的预测结果，并可视化在地图上（推荐不含国界线）。（提示：此题推荐使用 AI 工具辅助可视化程序的编写。）

（1）绘图数据来源。图和读数都基于最终提交的 world raw L11 探针（`world_layer11_extra0/weights.npz`，权重已折回原始特征空间，推理就是 $x@w^\top + b$）。本地复算把 valid MSE 还原为 150.4277（与训练记录逐位一致），$R^2 = 0.9545$，口径能对上。

（2）地图读数。130 个验证样本（78 国）画在世界地图上：灰空心圆是真值，彩点是预测，颜色表示单点误差 $\sqrt{\Delta lat^2 + \Delta lon^2}$。模型大致学到的是“大洲级”定位：平均误差 12.44°、中位 9.52°（大圆距离约 953.8 km），四分位 4.96/9.52/15.34°，误差超过 30° 的只有 7/130。

（3）误差结构。有两个特点。第一，方向不对称：纬度平均只差 4.25°，经度差 10.85°，约 2.5 倍——模型对“什么气候带”这类纬度线索敏感，精确定位需要的经度信息弱得多。第二，见过的地方准、偏僻的地方差：欧洲、东非、中美等训练密集区误差普遍小于 5°（最准 Denmark 0.79°）；失败集中高纬和孤立岛屿——两条南极样本排在最差前二（89.6°、73.8°，预测落到约 28–34°E 的南大洋），纽芬兰样本纬度几乎全对（差 0.23°），经度却差了 40.7°。图上只画 110m 海岸线，**不含任何国界线**。

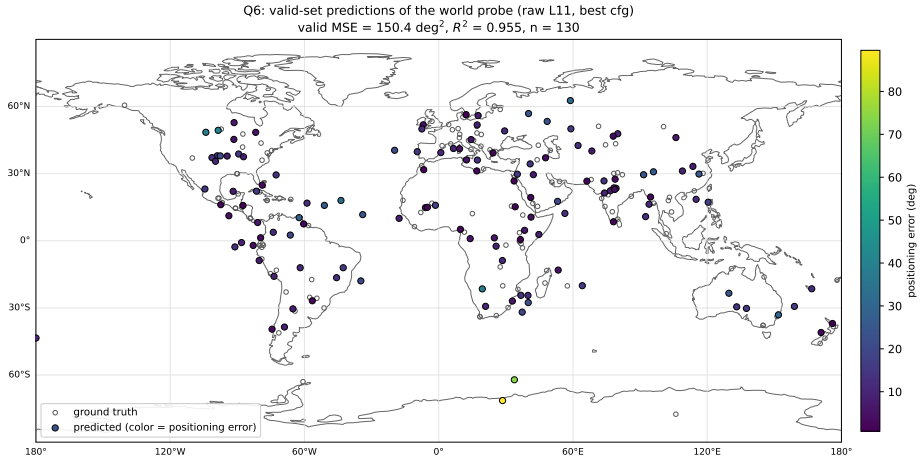


图 11: 130 个验证样本的定位：灰空心圆 = 真值，彩点 = 预测（颜色 = 单点定位误差）。valid MSE = 150.4（$R^2 = 0.955$）；中位误差 9.5°，纬度误差显著小于经度；高纬与孤立岛屿样本误差最大。仅海岸线，无国界线。

7. 是地理坐标表征，还是仅仅识别了国家？

题面：从训练集和验证集的表现，是否能够强烈说明模型内部存在地理坐标的表征，而不是仅仅识别了输入中的国家？对于该题可以参考原始论文 [3] 的部分结论和上一题的可视化结果；也可与按训练集国家分组的平均坐标基线比较，考察同一国家内不同地点的预测。

（1）怎么区分“坐标表征”和“只认国家”。思路很简单：如果模型只是认出了国家，那么把“国家平均坐标”直接告诉它，效果应该和模型差不多甚至更好。所以主基线用 **oracle 国家均值**：每条验证样本用真实国家标签，去查训练集里该国的坐标均值——这个基线是占便宜的（等于给了真标签 + 训练记忆）；训练没见过的国家退回全局均值，MSE 3311.27。improvement = 基线 − 模

型，正数表示模型更好，置信区间用 paired bootstrap。分层：all 130 / seen 110 / multi 73 / single 37 / unseen 20（19 个训练未见国家，共 20 条）。

（2）证据一：模型不只是认国家。unseen 的 20 条在训练里完全没出现，按国家查表原理上不可能答对；模型 MSE 158.90，全局均值基线 1182.83，improvement +**1023.93** [**513.94**, **1654.14**]。同一个国家内部也能看到一点定位能力：73 条多样本国家的样本相对本国训练均值的偏差中，纬度相关 $r = 0.201$ [0.021, 0.389]（弱显著，斜率 0.115），美国 8 条方向整体正确（中心化 $r = 0.69/0.60$）——模型确实带了超出国家身份的位置信息。

（3）证据二：但能力有限。只看训练见过的国家，oracle 反而反超：seen 110 条上模型 148.89，基线 **113.77**（imp −35.12 [−60.90, −7.08]，CI 不含 0）；multi 也一样显著（204.97 vs 159.58），single 不显著（38.24 vs 23.39）。有三点旁证说明 seen 上主要靠“国家身份 + 记住常见地点”：经度在国内几乎没有分辨力（$r = 0.046$，不显著）；两个坐标的斜率都远小于 1（0.115/0.027），模型把同国地点往国家中心拉；验证样本到同国最近训练点的距离中位只有 2.03°（40/130 < 1°、89/130 < 3°），oracle 基线相当于“查表 + 近邻插值”，Jamaica 基线 MSE 只有 0.01 就是地点几乎重合。稳健性：multi 去掉南极洲 2 条后结论不变（115.87 vs 65.24）。

（4）结论：中等强度。unseen 的 20 条预测整体落在对的区域（欧洲 → 欧洲、中美 → 中美），最差是 Mauritius 38.03°（经度从 57.50 掉到 19.49）、Estonia/Russia 31.60°、Finland 24.53°，最好 Denmark 0.79°——失败模式和 Q6 一致。对 +1024 要客观看：全局均值基线本身很弱，它只能说明“模型远不止一个全局平均”，不能说明“模型很精确”。所以综合判断是**中等强度**：强于“纯国家分类器”，弱于论文 [3] §5 那种神经元 + 干预级别的证据（超出本实验范围）；与论文 §4.1 的“weak evidence”自评、课程 README “可解码 ≠ 生成时一定使用”的提醒一致。Q6 地图上经度和岛屿的大误差，正是“relative position correct, absolute position often wrong”的具体表现。

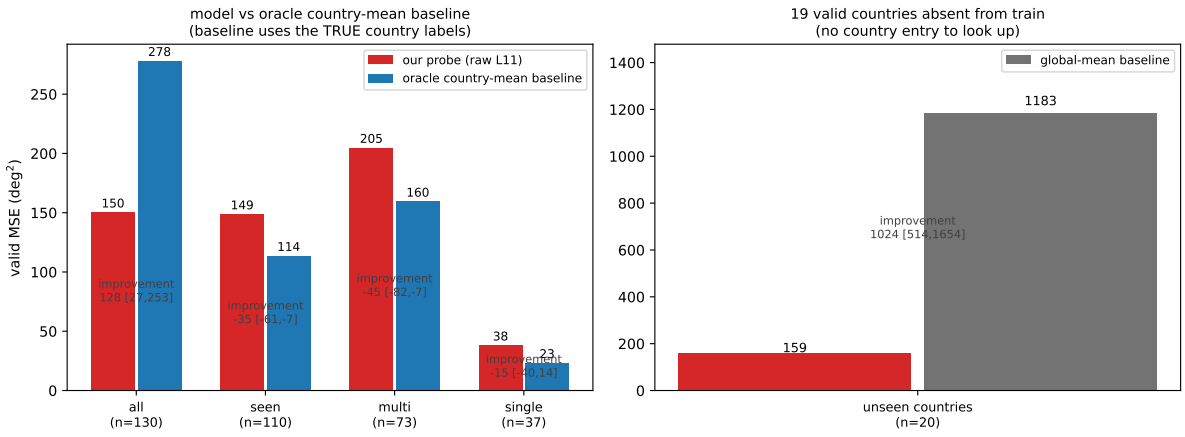


图 12: 模型 vs oracle 国家均值基线的分层 valid MSE。左：seen 国家按样本数分层；右：19 个训练未见国家。improvement = 基线 − 模型；误差棒为 paired bootstrap 95% CI。

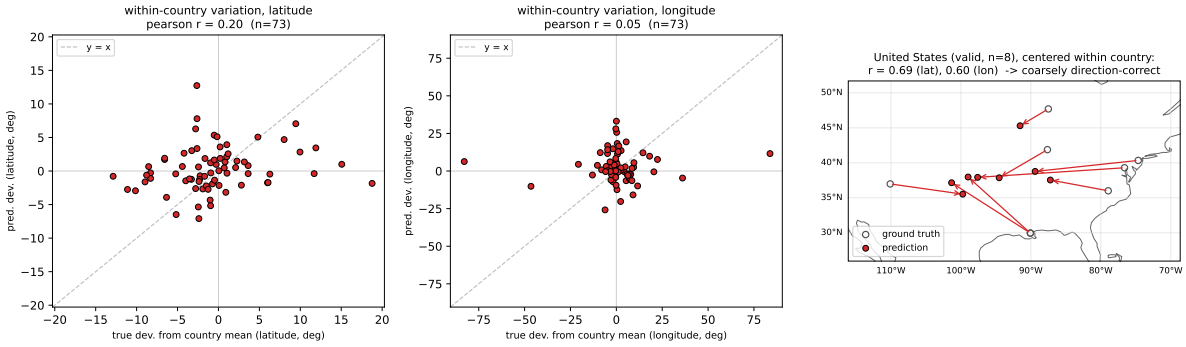


图 13: 同国内分辨力：73 条多样本国家样本相对该国训练均值的偏差（纬度 $r = 0.20$ 弱显著，经度 $r = 0.05$ ns）；右：美国 8 条样本真值 → 预测箭头（方向大体正确、幅度收缩）。

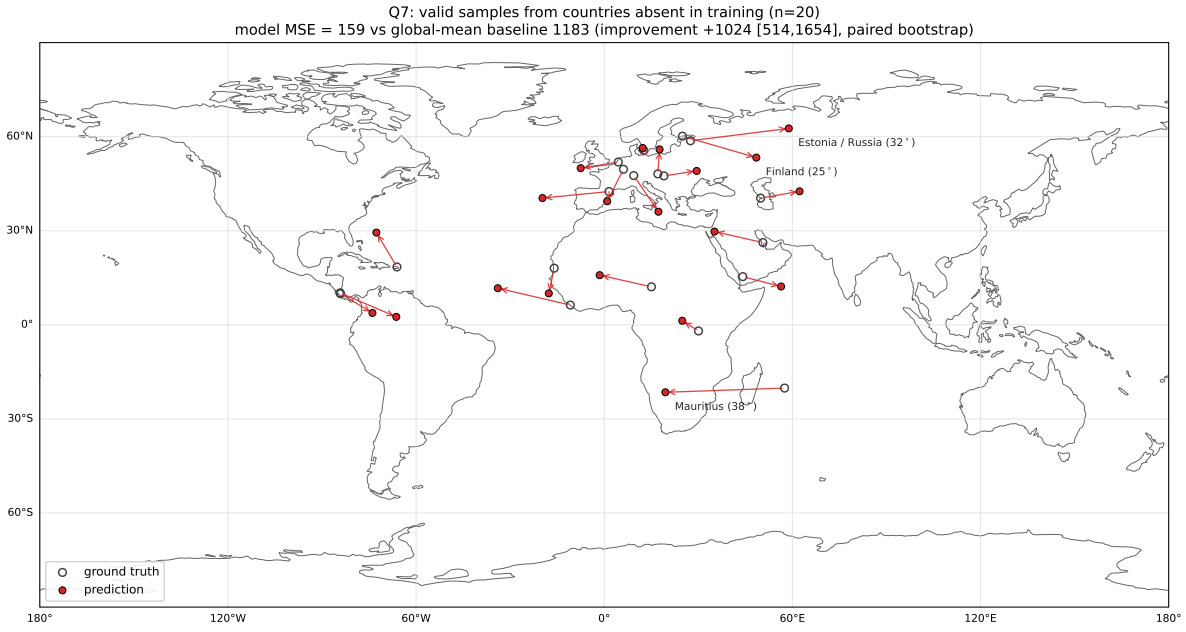


图 14: 19 个未见国家 20 条样本：模型 MSE 159 vs 全局均值基线 1183（imp +1024）。预测整体落对区域（欧洲 → 欧洲、中美 → 中美），最差 Mauritius 38.0°。仅海岸线，无国界线。

8. truth：训练集/验证集的分布差异与应对

题面：仔细阅读训练集和验证集，模型的训练集和验证集存在哪些分布上的差异？你是如何应对的？

（1）差异①：拼写噪声。错误是形近错（mkaes→makes 这种）。train 里有 7.0%（354/5088）的句子带相邻字母交换型错拼，valid 有 24.7%（74/300），约为 train 的 3.5 倍。但在两类标签内都均衡（valid 25.3%/24.0%、train 7.1%/6.8%）。

（2）差异②：新出现的实体 valid 的 300 条里有 212 条能识别出首实体，其中 164 条（**77.4%**）在 train 里没出现过。高频新实体比如 Dave Grohl（×8）、Dwyane Wade（×7）、The Offspring（×6），在 train 都未出现。

（3）差异③④：模板/长度 train 特有的情态否定句式在 valid 几乎消失：“One can”129 条（2.5%）对 valid 2 条，“If one”24 条对 0 条，合计约 3.0% 对 0.7%；valid 的长句被截断（最长 162 对 487 字符）。valid 有 20/130 条来自 19 个没见过的国家，126/130 条地点字符串没在 train 出现，但多数在空间上仍然很近（89/130 距同国最近训练点 $< 3°$），真正“又新又远”（$\geq 3°$）的只有 41 条——**字符串新不等于位置新**。truth 难在噪声 + 新主体。

（4）对模型的影响。L20 探针总体 0.8967。带错拼的子集 0.932 $[0.865, 0.986]$，不比干净子集 0.885 $[0.841, 0.925]$ 差，差 -0.047 $[-0.115, +0.024]$（CI 含 0）；主体 seen 0.917 $[0.833, 0.979]$ 对 unseen 0.884 $[0.835, 0.933]$，差 $+0.033$ $[-0.063, +0.119]$，同样不显著。typo× 主体四格的点估计排序是 clean×unseen < clean×seen < typo×unseen < typo×seen，两个“难组”都没有明显掉分。稳健性：去掉 Grohl/Wade 两个重复家族后，typo 组仍有 0.935（$n = 62$）；typo 子集的主体构成和 clean 接近。逐层看，错拼只在浅层造成伤害——L5–L11 的干净 − 错拼差为 $+5 \sim 7$pp，L17 起转负（L17 -6.1、L20 -4.7、L29 -4.2pp），说明文本噪声在中深层被平滑吸收了。小格子别过度解读：label= 0 的 typo 组 0.972、typo×seen 1.000 的 n 只有 8–36，CI 很宽。

（5）应对。第一，读数方式：子集比较都配 bootstrap 95% CI（$n = 300$ 的单点差异约 ±3.5pp、30 条子集约 ±10pp），CI 跨 0 就不用来选层/选参；分层报告，不只看总 acc。第二，不向 valid 泄漏：层和超参来自扫描、分层训练报告和配对检验，训练预算固定，不按 valid 早停。第三，文本不清洗：特征直接从原始文本（含错拼）前向——如果清洗 train 侧的错拼，train（7.0%）和 valid（24.7%）的口径反而更不一致，而且部署时同样要面对噪声；选深层本身就是抗噪手段。所以 valid 指标是“OOD + 加噪”的保守口径。作为同分布对照，train 内部做了 3 折 CV（L20、和仓库 `model.py` 同配置、$n = 3785$）：随机划分 acc 0.869（std ≈ 0.010），按主体分组 0.877（std ≈ 0.004，测试折主体 100% 未见对随机 38%），差 -0.8pp，在折间噪声内——说明 **L20 探针不依赖“记住主体”**，valid 的 0.8967 没有被主体新颖度注水（CV 每折训练量比最终模型少、测试折来自 train 分布，不能和 valid 直接相减）。

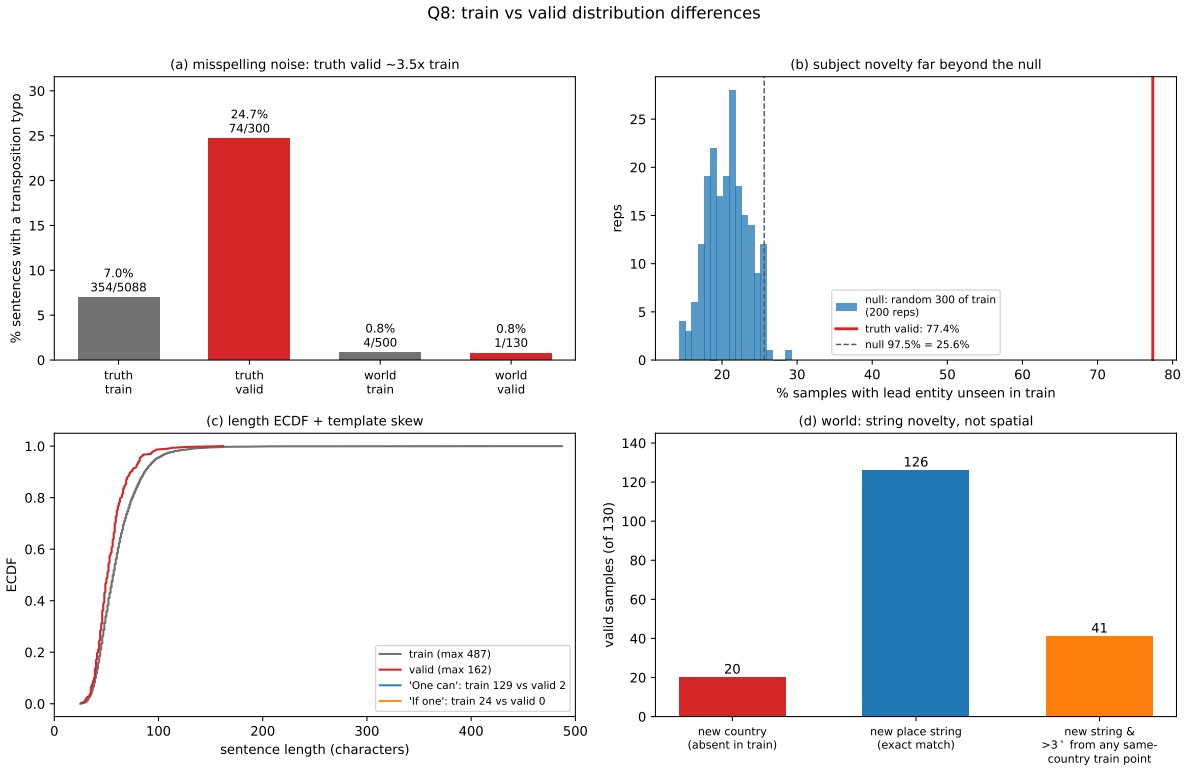


图 15: 分布差异总览：(a) 拼写噪声 valid ≈3.5× train；(b) 主体新颖度 77.4% 远在零假设分布之外；(c) 长度 ECDF 与模板差异；(d) world 对照——字符串新颖而非空间新颖。

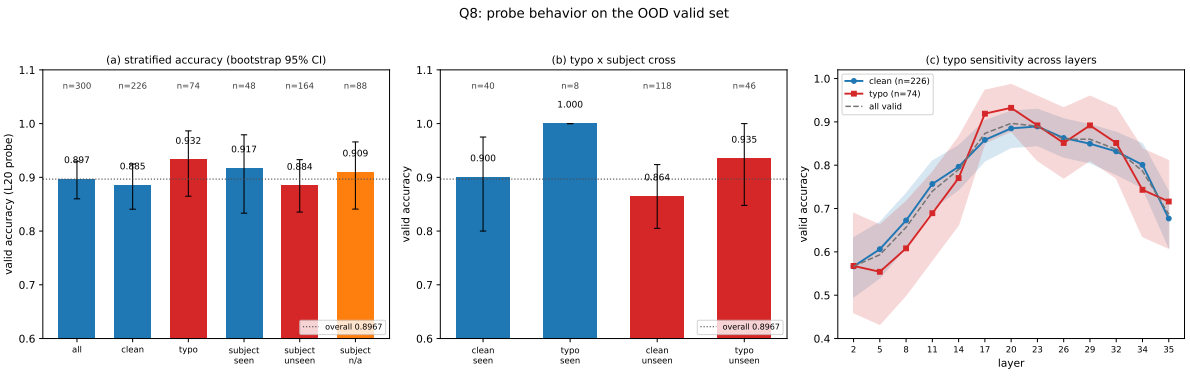


图 16: L20 探针在 OOD valid 上的分层表现：(a) 主分层准确率；(b) typo × 主体交叉；(c) 13 层探针的 typo 敏感度。

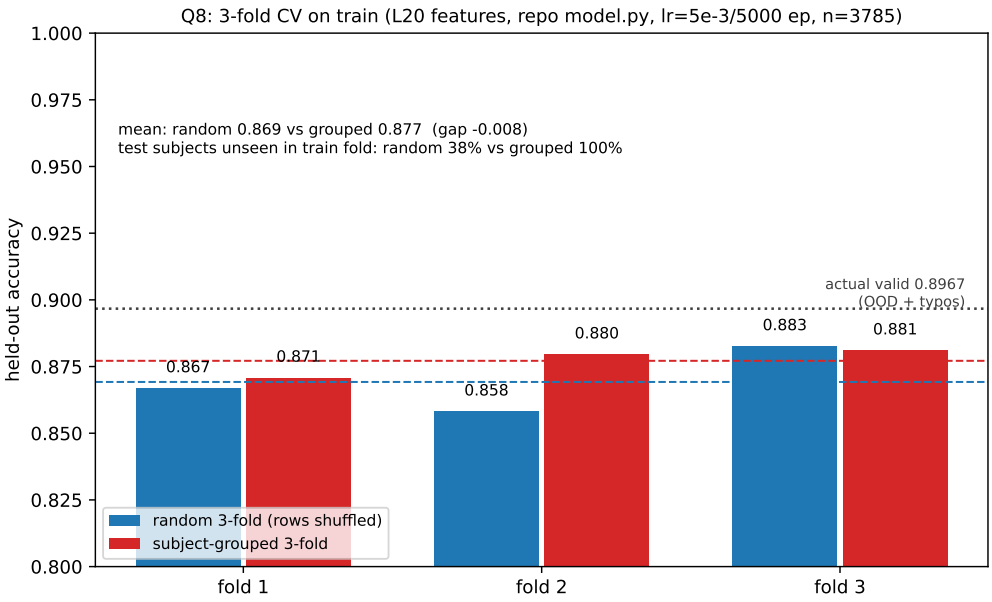


图 17: train 内部 3 折 CV 对照（L20、仓库 model.py 同配置、n=3785）：随机 vs 按主体分组划分（测试折主体未见比例 38% vs 100%）的 held-out 准确率——均值 0.869 vs 0.877（差 −0.8pp，在折间噪声内）；灰点线为实际 valid 0.8967。两种划分口径几乎无差 ⇒ L20 探针不依赖主体记忆。

9. truth：选层与正则化的理由

题面：你在最终模型提交中是怎么选择特征选取层次和正则化的？请说明理由。

（1）实验设置。和 world 一样扫 13 层，统一配置：lr$= 5 \times 10^{-3}$、5000 轮、$\lambda_1 = \lambda_2 = 10^{-3}$，truth 用原始特征，得到完整曲线。

（2）结果分析。truth 的曲线是清晰的**倒 U 形**：中间高、两边低。选 L20，因为它最高，而且峰位居中、两侧比较对称。解释：真假判断靠语义级信息，这些信息在 L17–L23 对线性探针最可读；浅层还是词法和局部特征，深层经过非线性重整后线索被稀释。这和 world 的最优层正好相反，说明不同深度装的是不同类型的信息。

（3）正则化。结果显示 λ_1 有害：$0 \to 70.0\%$、$10^{-3} \to 68.7\%$、$10^{-2} \to 67.0\%$、$0.1 \to$ **50.0**%（直接掉到随机）。原因是表征稠密，ℓ_1 把大量分量压成 0，反而对准确率有害；λ_2 则对准确率几乎无影响（四个取值都是 68.7%）。所以最终取 $\lambda_1 = \lambda_2 = 10^{-3}$，采用很弱的正则化。

（4）最终提交。raw L20，lr$= 5 \times 10^{-3}$，5000 轮，$\lambda_1 = \lambda_2 = 10^{-3}$，valid acc **0.8967**。

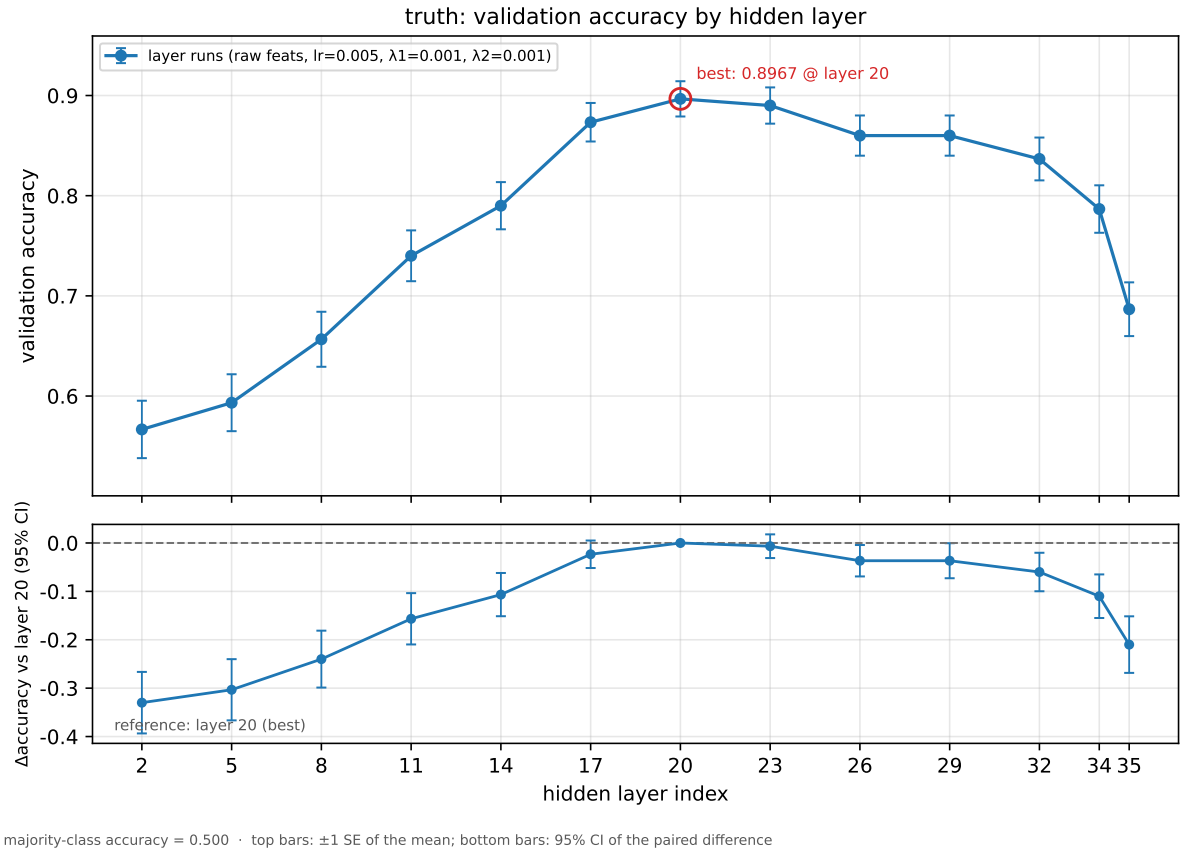


图 18: truth 各层验证准确率（上：±1 SE，红圈 = L20；下：与 L20 的配对差 95% CI）。倒 U 形、中层平台。随机水平 = 多数类 = 0.50。

层	acc	±SE	Δ vs L20（95% CI）/判定
2	0.5667	0.0287	−33.00pp ± 6.36pp 显著
5	0.5933	0.0284	−30.33pp ± 6.32pp 显著
8	0.6567	0.0275	−24.00pp ± 5.88pp 显著
11	0.7400	0.0254	−15.67pp ± 5.30pp 显著
14	0.7900	0.0236	−10.67pp ± 4.47pp 显著
17	0.8733	0.0192	−2.33pp ± 2.84pp 不显著
20	**0.8967**	0.0176	参考（最优）
23	0.8900	0.0181	−0.67pp ± 2.45pp 不显著
26	0.8600	0.0201	−3.67pp ± 3.25pp 刚好显著
29	0.8600	0.0201	−3.67pp ± 3.62pp 边缘
32	0.8367	0.0214	−6.00pp ± 3.98pp 显著
34	0.7867	0.0237	−11.00pp ± 4.50pp 显著
35	0.6867	0.0268	−21.00pp ± 5.84pp 显著

表 4: truth 13 层验证准确率全表（raw，lr= 5×10^{-3}，5000 轮，$n = 300$）。

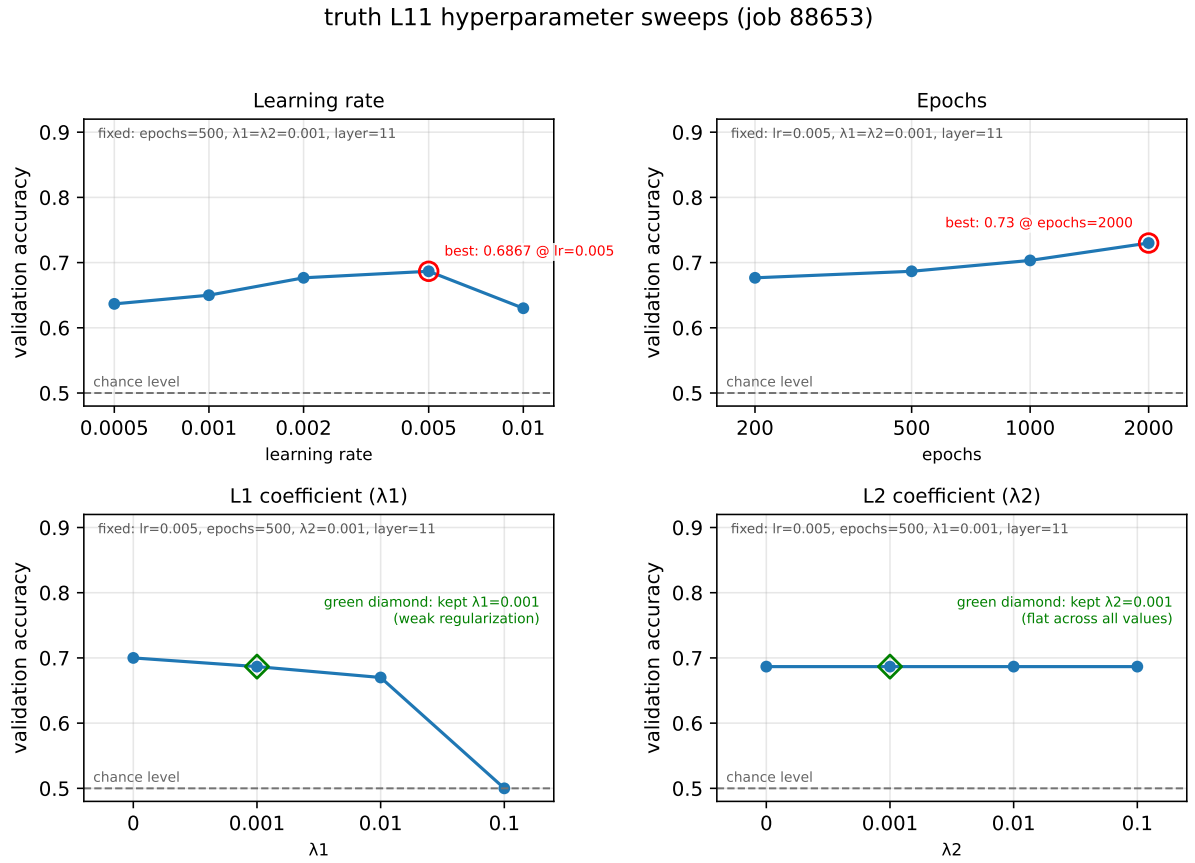


图 19: truth L11 超参数扫描（88653，原始特征，基线 lr$= 5 \times 10^{-3}$、500 轮、$\lambda_1 = \lambda_2 = 10^{-3}$，每格只变一个）：lr 呈倒 U，$5 \times 10^{-3}$ 最佳（68.7%），10^{-2} 回落到 63.0%；epochs 在扫描范围内单调升（2000 轮 73.0%，最终 13 层训练统一用 5000 轮）；λ_1 从 10^{-3} 增到 0.1 时由 68.7% 掉到随机水平 50.0%（0 时 70.0% 略高，但无正则不稳定，故不取）；λ_2 四个取值均为 68.7%、完全不敏感。红圈为该格扫描最优，绿菱形为提交采用的 $\lambda_1 = \lambda_2 = 10^{-3}$。

A 背景知识：线性探测、Qwen3-4B 与两个任务

线性探测（linear probing）[1] 是研究模型内部表征的一种回归分析手段：训练时冻结大语言模型，只在某一中间层的激活（隐表征）上训练一个简单模型——本实验中即手写实现的线性回归与逻辑回归；若该模型能在独立验证集上优于合理基线，说明相应信息以（近似）线性可分的形式编码于该层表征、可被“解码”。线性可解码是一个良好的性质：信息可用简单模型读出，也是激活引导（activation steering）等后续干预研究的前提；但需注意“可解码 $\neq$ 模型在生成时一定使用了该信息”。本实验考察 Qwen3-4B-Base 内部的两类表征：地理空间坐标（论文 [3] 实验的简化，用线性回归预测经纬度）与句子真假（论文 [4] 实验的简化，用逻辑回归预测真假标签）。

特征口径：Qwen3-4B-Base 共 36 个 decoder block（编号 0–35），隐藏维度 $D = 2560$；特征取指定词元在 block 输出处（最终 RMSNorm 之前）的隐状态，不使用聊天模板。词元选择随任务而定：world 取“国名最后一个词元”，truth 取“句子最后一个词元”。课程预提取了第 11、23、35 层；我们另按实验文档的算力平台教程提取了其余 10 层，凑成 13 层（从 2 到 35、步长约 3）以支撑层间对比（提取与训练的工程细节见附录 B）。特征文件以 float16 存储为 $(N, 2560)$ 数组，训练与评测时转为 float64。

两个任务的规模与角色不同。world 为回归任务（热身）：train 500 / valid 130，目标为（纬度, 经度）双输出（单位度，北纬、东经为正），按 MSE 评测；$N = 500 \ll D = 2560$ 为欠定问题，必须借助正则化与特征层选择获得泛化能力，课程对其效果赋权低于 truth。truth 为二分类任务（主考察）：train 5088 / valid 300，标签 1 为真、0 为假，两个集合内真假各半；样本数大于特征维度。两者的最终效果均在一个未公布的测试集上评测，且测试集分布更接近验证集而非训练集——因此不应以过拟合训练集的方式提分。

提交物为两份 `.npz` 权重（`float64`）：world 为 `weights` $(2, 2560)$（两行依次对应纬度、经度）与 `bias` $(2,)$；truth 为 `weights` $(2560,)$ 与零维 `bias`；另附所选特征层的层号（$[0, 35]$ 整数）。两个数据集均为课程自建、与论文原实验所用不同，构造细节未公布；关于它们的构造线索与训练/验证分布差异，见第 8 题。

B 有意思的实验：超参数扫描、稳定界与工程实践

在正式的分层训练之前，我们做了两轮系统性的超参数扫描（全部为全批量 GD、确定性代码，本地与集群数值一致）。首轮（job 88653）以单变量对照的形式跑了 9 组 35 次训练：两任务在 L11 上分别扫 lr、epochs、λ_1、λ_2，并以 L11/23/35 扫描层。扫描给出的主要结论与正文 Q5/Q9 一致，此不重复；这里值得记录的是扫描本身暴露出的形态：truth 的 lr 呈倒 U（0.005 最佳）、λ_1 有害、层间差异巨大（L23 84.3% 对 L11/L35 的 63% 上下）；world 则是 lr 越大越好但上限被锁死在 5×10^{-4}（150.94），layer 23/35 在 lr$= 2 \times 10^{-4}$ 下直接发散为 inf——同一份扫描在两个任务上呈现完全不同的数值面貌（logistic 有界梯度对 MSE 无界残差），由此引出了一整条“数值修复”支线。

world 的发散最初表现为一串极具误导性的日志与状态。日志写“Training converged at epoch 263, loss=inf”——收敛判据 `np.isclose(inf, inf)` 为真，把损失溢出误报成了收敛；实测权重并未变成 nan，而是有限的天文数字（$\max|w|$ 达 1.8×10^{151}、7.9×10^{152}），旧代码“权重是否有限”的检查因此误报通过；更隐蔽的是发散时预测出的 MSE 是有限大数（3.9×10^{305}）而非 inf——“只查权重”或“只查指标”都会漏检，必须引入独立的发散标志位。

修复分三处：`model.py` 新增 diverged 状态（梯度/权重/loss 非有限、或 loss 超过初始值 10^6 倍即中止训练并置位，与正常收敛严格区分）；`run_grid.py` 支持逐组 standardize（z-score 统计量只取 train split、验证集复用同一 μ/σ），并支持把标准化空间的权重精确折回原始特征空间（$w' = w/\sigma$、

$b' = b - \mu \cdot w'$，在原始特征上复算一致、误差 $\sim 10^{-14}$）。根因也随之明确：发散不是“深层没有信息”，而是 lr 越过了**按层稳定界**——未标准化时该界随深度暴跌 1800 倍（数学见附录 D）。

第二轮（job 89085，16 次训练）在 z-score 特征上重扫。标准化把各层稳定界拉平后，lr$= 3\times10^{-3}$ 对三层均安全、5×10^{-3} 的越界被 `finite=False` 正确标记为发散；λ_2 呈现出真实的 U 形（0.1 → 209.13——训练已收敛但验证严重过拟合；1.0 → 167.06 最优；3.0 → 184.57）；epochs ≥ 500 即到平台。layer 扫描（lr$= 3 \times 10^{-3}$）：L11 167.06 / L23 241.12 / L35 204.98。λ_1 另外补扫 4 点（同一 std L11 配置，$0, 10^{-3}, 10^{-2}, 0.1$）：MSE 分别为 $167.07, 167.06, 166.93, 165.82$，0.1 相对 10^{-3} 的配对差为 -1.24（95% CI $[-5.80, 3.33]$），不显著。至此三条独立路径——raw 冠军（L11 150.4）、raw 长训练（L23 在 lr$= 5 \times 10^{-5}$、20000 轮下 233.1）、标准化收敛（上列数字）——交叉印证了“L11 是 world 最优层、L23/35 在真正收敛后确实更差”，排除了“深层只是训不动”的假象。

工程方面，truth 的“13 层 × 5000 轮”在 4h 平台上限内跑不完（首跑 89700 超时），我们把它拆成 4 个分块作业（90243-90246）并实现断点续跑：`--skip-existing` 复用已完成层、`python -u` 实时日志、BLAS 线程钉定避免共享节点抢占。四个作业全部成功、零发散；L5 撞上慢节点跑了 3390.5s（约 15 倍于正常耗时）仍被分块设计吸收、零进度损失。统计方法上，层间比较统一使用同批验证样本的**配对 bootstrap 95% CI**：world 的 MSE 重尾，单层 SE 达 40+，配对后 CI 显著收窄（25-77）；truth 单样本值 0.33pp。

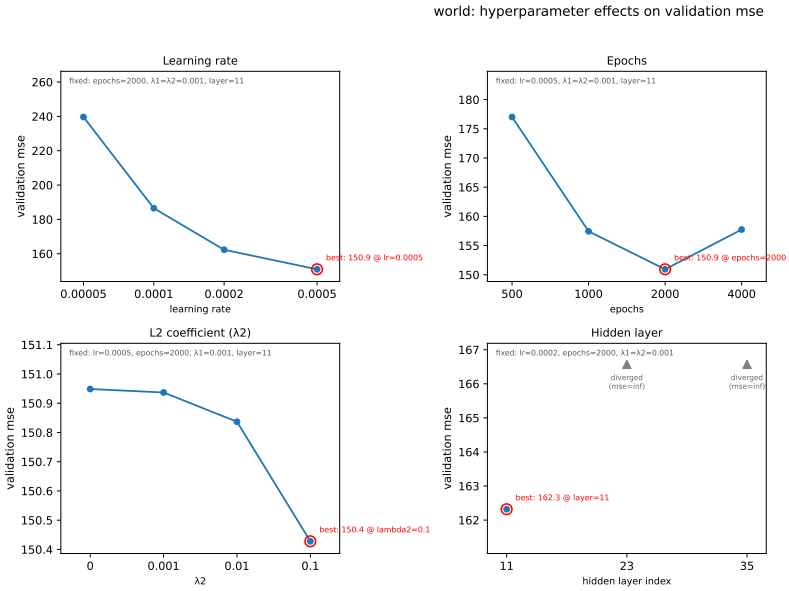


图 20: 首轮 world 超参数扫描（88653，未标准化特征）：lr 越大越好但上限被困在 5×10^{-4}（更大即发散）；layer 23/35 的“inf”由数值问题造成，而非“深层无信息”。

C 有趣的表征：跨任务对照与现象观察

本附录收集正文放不下的跨任务表征观察与现象汇总。第一，两任务的**最优层带完全不同**：world 在浅层 L2-L11（157.6-167.0 的平台），truth 在中层 L17-L23（0.8733-0.8967 的平台），且两者都在 L32-L35 变差——位置/坐标信息与真假语义的“可线性解码深度”不同，说明不同类型的信息写在表征的不同深度上。一处与论文的差异如实报告：论文 [3] 在 LLaMA-70B 上报告 world 表征约在 60% 深度处最佳，而我们在 Qwen3-4B 上的 world 最优却在很浅的层——模型、数据集与特征口径均不同，我们不做进一步归因。

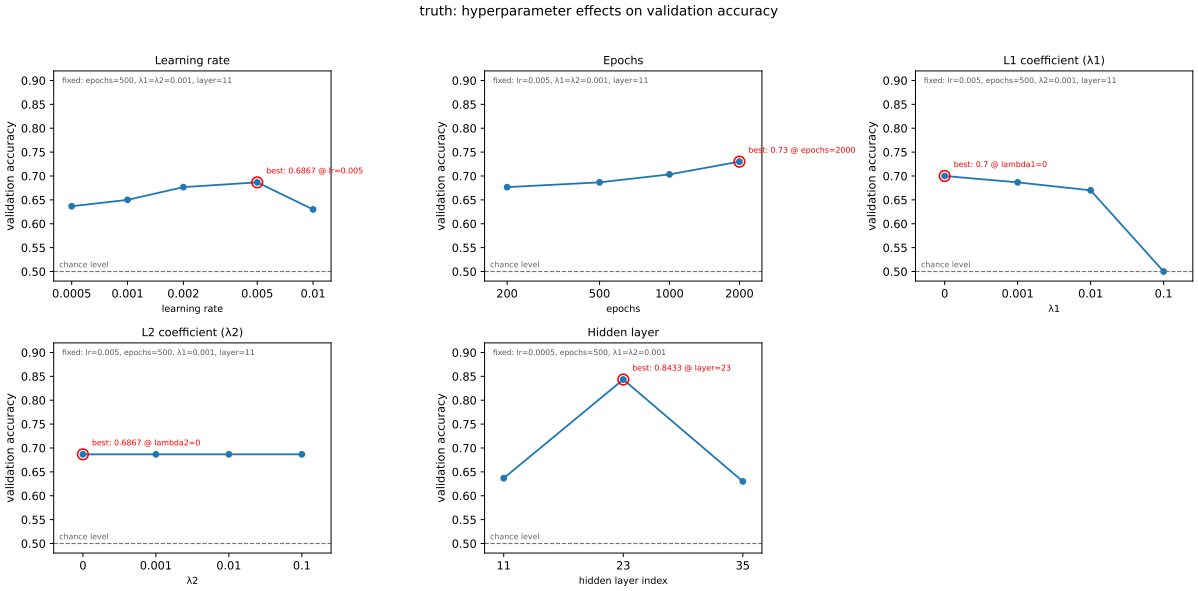


图 21: 首轮 truth 超参数扫描（88653）：lr、epochs、layer 的效应；λ_1 增大有害、λ_2 无差异。

第二，raw 与 z-score 的相互作用是一个非平凡的观察：raw 特征的增益并非“浅层普遍更好”，而是 L11 特有的组合——raw L11 全场最低（150.43），但 raw L2 探针反而显著更差（198.78）；z-score 的意义也不是“提点”，而是**解锁深层**——把按层稳定界拉平（1800 倍差距缩到 1.5 倍）让深层可训，同时 L2 的浅层优势本身也依赖标准化解锁（raw 198.8 → std 157.6）。

第三，一个只报告、暂不归因的现象：world 的曲线在深层**回升**——从 L20/L23 的低谷（≈ 241）回到 L32 的 180.3、与浅层统计不可区分（L11 vs L32：t= −0.46；而 L23 vs L32 的回升在配对意义上显著）；truth 则没有这个现象，L26 起单调下降（L32 的 0.8367 → L35 的 0.6867）。两任务在尾部层的表现分化，其机制（残差流叠加读出、语义抽象稀释等解释）都在本实验证据之外，我们只报告观察。

第四，把 Q6–Q8 的表征现象汇总：坐标信息以超越国家身份的形式存在——unseen 20 条上 improvement +1023.93 [513.94, 1654.14]（这些国家按表查询在原理上不可能）；同国内纬度弱可解码（$r = 0.201$）、经度近乎不可解码（$r = 0.046$），与 Q6 地图上“经度误差 $\gg$ 纬度”（MAE 10.85° vs 4.25°）相互印证，共同指向“气候带式”的粗粒度空间信息与有限的地名知识。噪声维度上，中深层表征对字符级扰动不敏感（typo 子集 acc 不低于 clean，浅层 L5–L11 才有 5–7pp 的差距）——与“表征是分布式语义编码”的直觉一致。

第五，一条 token 口径备注：world 探针读的是“国名最后一个词元”处的激活——写入位置即国家实体本身的状态；结果表明该状态同时编码了超越国名的坐标信息（否则 unseen 国家上不可能大幅胜过全局基线）。这也可能与 Q7 观察到的“国家中心收缩”有关：从国名词元状态读出的位置天然带有国家先验，探针只能部分解出个体地点的偏移。

D 数学原理：稳定界、闭式解与 KKT

world 用均方误差 $L = \|Xw + b\mathbf{1} - y\|^2/N$（与 `model.py` 一致），它是关于参数的凸二次函数，Hessian $H = 2X^\top X/N$。全批量梯度下降的误差传播为 $e_{t+1} = (I - \mathrm{lr}\, H)e_t$（$e$ 为参数误差），收敛当且仅当谱半径小于 1，即 $\mathrm{lr} < \dfrac{2}{\lambda_{\max}(H)} = \dfrac{N}{\|X\|_2^2}$——只依赖特征矩阵、与 y 无关，每层各有一个值（N 为该任务训练样本数）。越界后，误差沿最大特征方向每轮乘以 $|1 - \mathrm{lr}\,\lambda_{\max}| > 1$ 指数放大

——这正是 world 未标准化时 loss 奔向 inf 的机制。

truth 用交叉熵，其 Hessian 为 $X^\top \mathrm{diag}(p(1-p))X/N \preceq X^\top X/(4N)$，最坏情形（$p=1/2$）的充分稳定界放宽到约 $8N/\|X\|_2^2$（二次界的 8 倍）；更重要的是 logistic 的梯度有界（$p-y\in[-1,1]$），没有 MSE“残差随 w 线性增长”的正反馈，越界一般表现为震荡/饱和、准确率下降，而不是爆炸——这是 truth 可以不标准化、直接用 raw 特征配 lr$=5\times10^{-3}$ 的原因。

下表给出 13 层 × 两任务 × raw/z-score 的全部稳定界，两个读法。其一，**raw 界随深度暴跌**——world 从 L2 的 4.95×10^{-3} 降到 L35 的 2.77×10^{-6}，跨约 1800 倍；激活幅度逐层增大（残差流行范数从 51 到 623，约 12 倍，平方进入 $\|X\|_2^2$ 就是两个数量级），固定 lr 必然在深层越界。其二，**z-score 把界“拉平”**到 3.1–4.8×10^{-3}（仅 1.5 倍差距）——z-score 只归一化每列尺度，剩下的差异来自特征间的相关结构；正因为拉平了，同一个 lr 才能对所有层公平。truth 的 raw 界同样随深度收缩，但如上所述 logistic 对越界是“软”的，其配置不依赖这把尺子。

层	world raw	world z-score	truth raw	truth z-score
2	4.95×10^{-3}	4.07×10^{-3}	6.51×10^{-3}	2.67×10^{-3}
5	1.14×10^{-3}	$\mathbf{3.08\times10^{-3}}$	1.14×10^{-3}	4.85×10^{-3}
8	6.90×10^{-4}	3.15×10^{-3}	1.09×10^{-3}	9.20×10^{-3}
11	5.45×10^{-4}	3.59×10^{-3}	7.37×10^{-4}	9.74×10^{-3}
14	4.47×10^{-4}	3.40×10^{-3}	6.10×10^{-4}	1.05×10^{-2}
17	3.19×10^{-4}	3.48×10^{-3}	5.01×10^{-4}	1.03×10^{-2}
20	1.93×10^{-4}	3.42×10^{-3}	3.04×10^{-4}	7.00×10^{-3}
23	8.37×10^{-5}	3.16×10^{-3}	1.33×10^{-4}	5.38×10^{-3}
26	3.94×10^{-5}	3.16×10^{-3}	4.08×10^{-5}	4.72×10^{-3}
29	1.89×10^{-5}	3.46×10^{-3}	1.63×10^{-5}	5.42×10^{-3}
32	7.48×10^{-6}	3.92×10^{-3}	6.17×10^{-6}	6.70×10^{-3}
34	3.02×10^{-6}	4.40×10^{-3}	2.93×10^{-6}	7.25×10^{-3}
35	2.77×10^{-6}	$\mathbf{4.77\times10^{-3}}$	1.68×10^{-6}	5.84×10^{-3}

表 5: 13 层稳定界 $N/\|X\|_2^2$ 全表（SVD 精确值；raw 界随深度跨 1800×，z-score 后压至 1.5×）。

理论与实测逐条吻合：raw L11 界 5.4×10^{-4}——lr$=5\times10^{-4}$ 稳定（贴线，MSE 150.9），10^{-3} 直接溢出；raw L23 界 8.4×10^{-5}——实测 2×10^{-4}（超 2.4 倍）收敛前爆炸；raw L35 界 2.8×10^{-6}——实测超 72 倍、71 轮即炸；std L11 界 3.6×10^{-3}——lr$=3\times10^{-3}$（0.83 倍）得 167.06、5×10^{-3}（1.39 倍）发散；std L35 界 4.8×10^{-3}——lr$=4\times10^{-3}$（0.84 倍）冒烟 300 轮稳定、8×10^{-3}（1.68 倍）第 9 轮爆炸。反向一例：truth raw L35 用 lr$=5\times10^{-4}$ 已超二次界约 300 倍，训练仍然有限（acc 63.0%）——logistic 的非爆炸性由此得到实证。

Q1/Q2 的实现用到两条精确算法。其一，Ridge 的 SVD 闭式解：$X=U\Sigma V^\top$ 时 $\hat{w}=V\,\mathrm{diag}\big(\sigma_i/(\sigma_i^2+\lambda)\big)\,U^\top y$，$\lambda=0$ 退化为伪逆的最小范数最小二乘解；系数路径即由它精确计算（与 sklearn 对拍 10^{-9}）。其二，Lasso 的 KKT/软阈值：驻点条件 $\partial L/\partial w_j=\frac{2}{N}[X^\top(Xw-y)]_j+\lambda_1\,\mathrm{sgn}(w_j)+2\lambda_2 w_j=0$ 由坐标下降 + warm start 求解；精确零来自优化几何本身、零集沿 λ 嵌套——这正是 Q2 中“阈值化 ridge 无法复现 lasso 零集”对照的数学背景。逻辑回归的梯度（`model.py` 实现）为 $\nabla_w L=\frac{1}{N}X^\top(\hat{y}-y)+\lambda_1\,\mathrm{sgn}(w)+2\lambda_2 w$；数值上用 $\log(1+e^{-z})=\mathrm{logaddexp}(0,-z)$ 稳定计算。sklearn 换算表（Q3 对拍用）：Ridge $\alpha=N\lambda_2$；Lasso $\alpha=\lambda_1/2$；ElasticNet $\alpha\rho=\lambda_1/2$、$\alpha(1-\rho)=\lambda_2$；Logistic $C=1/(2N\lambda_2)$——注意 sklearn 的正则量纲是“平方误差总和”口径，直接对比会差一个 N 倍。最后是基线口径：train 均值基线的元素平均口径 MSE $=3311.27$（与模型指标同口径），坐标求和口径 $=6622.54$；两者混用会把 R^2 抬高

约 2.3pp。统一口径后，world 最佳 $R^2 = 0.9546$（RMSE $\approx 12.3°$）。

E 复现清单与文件结构

本报告的仓库结构与产物分布如下。根目录的 `model.py` 是提交的手写模型（线性/逻辑回归，全批量梯度下降）；`datasets/` 存放两任务各 13 层的特征数组与标签 csv；`experiments/` 是训练与分析的执行器与配置（`train_layers.py`、`run_grid.py`、`plot_layers.py`、`stability_bound.py` 及配置 json）；`scripts/` 是集群 sbatch 与分块提交脚本；`question/code` 是思考题 Q1–Q8 的复现脚本；`results/` 汇总全部扫描/分层训练/提取的结果与图；`report/` 为本报告源文件。

环境方面，本地与集群统一使用 ai26 环境（numpy / sklearn / matplotlib / cartopy / pyspellchecker）；集群跑在 Students 分区，且必须钉 A100（`--gres=gpu:A100:1`）——RTX5090 节点与当前 torch 驱动不兼容，需避开。关键复现命令：训练 13 层 `python experiments/train_layers.py --skip-existing`；稳定界全表 `python experiments/stability_bound.py`；Q1 系数路径 `python question/code/q1_coefficient_paths.py`；Q6 地图 `python question/code/q6_valid_map.py`；其余思考题脚本同构（入口在 `question/code` 下）。

提交产物（首选/备选）：world——raw L11 探针（`results/slurm_layers/world/weights/world_layer11_extra0/weights.npz`，MSE 150.43），备选 z-score L2（157.57）；truth——raw L20（`results/slurm_layers/truth_b/weights/truth_layer20/weights.npz`，acc 0.8967），备选 L23（0.8900）。所有权重均已折回原始特征空间，推理时不需再做标准化。

追溯与归档：KC 房价数据（Q1/Q2）与 OpenML 全表的逐格对拍记录在 `question/execution_log.md` §1.2；truth 数据集的来源指纹见第 8 题；每轮集群运行的全部日志按时间戳归档在 `results/slurm_*` 对应目录下。

F 实验反馈与建议

全程做下来，我们对课程设计有几点想反馈。数据集构造不公布反而促成了本报告中最有意思的一段工作——Q8 的“反推/对拍”（用统计指纹识别出 valid 是构造性 OOD 挑战集）。我们建议在指南中明确鼓励这类来源调查：它把“调参竞赛”变成了真正的研究过程。报告要求“思考题回答为主、背景进附录、不设长度限制”的设定也很好，让扫描、稳定性分析等附加内容可以放进附录而不挤压正文；提示中“推荐 AI 工具辅助可视化”明确而友好，建议再补充一句“AI 辅助内容需能讲清原理”（验收提示已有类似要求）。

算力平台方面有两个具体的坑与建议。其一，Students 分区混部 RTX5090 与 A100，当前 torch 与 RTX5090 驱动不兼容（CUDA error 804），曾让整批特征提取全部 FAIL；建议在附录 B 的教程里明确写“钉 A100”。其二，4h 作业时限对“13 层 × 5000 轮”级别的实验需要分块 + 断点续跑设计——这本身是一次很好的工程训练（我们靠它吸收了慢节点 15 倍的抖动），但建议指南给出各量级实验的时间预算参考，避免每个小组都从超时失败学起。