FAIML Lab1 实验报告

常志强
PB25030753

2026 年 10 月 21 日

1 思考题

1. 复现 ℓ_1 / ℓ_2 系数路径与数据来源

题面：重现课件（第 42、48 页）中 ℓ_1、ℓ_2 正则化的“系数路径”，并解释数据来源。

（1）数据来源。课件 p42/p49 的 8 个特征列（bedrooms、bathrooms、sqft_living、sqft_lot、floors、yr_built、yr_renovated、waterfront）与 Kaggle 数据集 House Sales in King County, USA（`https://www.kaggle.com/datasets/harlfoxem/housesalesprediction`，CC0 许可）的列名完全一致，由此判定课件图的数据来源即该数据集。本实验下载自该数据集的 GitHub 镜像（`https://raw.githubusercontent.com/Willie-Conway/House-Sales-Price-Prediction-King-County-USA-Project/main/House-Sales-Price-Prediction/housing.csv`）

（2）数据处理（根据讲义）。课件 p20 批注“all features normalized so coeff. on same scale”，于是笔者对 8 个特征做了标准化，使各特征系数处于同一尺度。同时剔除数据集中含缺失的 16 行（21613 → 21597，占 0.07%）。λ 取 0 至 2×10^5 共 201 个等距点，与课件一致。

（3）复现结果与简单分析。$\lambda = 0$ 处的最小二乘解（单位：美元/σ）为 sqft_living 268 160、waterfront 63 307、bathrooms 49 137、floors 28 399、yr_renovated 3 397、sqft_lot −12 378、bedrooms −56 868、yr_built −92 382，与课件量级一致。ℓ_2（Ridge）路径**只缩不归零**，其中 bedrooms 与 bathrooms 在 $\lambda \lesssim 2\times10^4$ 先升后降。ℓ_1（Lasso）路径随 λ 增大**精确归零**，归零顺序为 sqft_lot (9k) → yr_renovated (13k) → bedrooms (21k) → floors (23k) → bathrooms (26k) → yr_built (45k) → waterfront (79k)，至 $\lambda = 2\times10^5$ 只剩 sqft_living（57.7k）。综上，两条路径的趋势与量级均与课件一致。

2. 用案例说明 ℓ_2 阈值化做特征选择为什么不好

题面：请用案例说明 ℓ_2 正则化在回归中将很小的系数设为 0 进行特征选择是不好的（相比 ℓ_1 正则化，课件第 44 页）。

我们在 Q1 的 8 列基础上加入 sqft_above 构成 9 特征（它与 sqft_living 的 Pearson 相关 $r = 0.876$，是主共线对；次强对 bathrooms∼sqft_living 为 $r = 0.756$），经 z-score 与 price 中心化后，考察“$|w_j| < \tau$ 视为 0”的阈值化特征选择，主阈值取 $\tau = 10^4$（单位同前，美元/σ）。

其一，选择结果高度依赖阈值 τ。同一个 Ridge 拟合（$\lambda = 2\times10^4$）下，$\tau = 10^4 \to 2\times10^4 \to 5\times10^4 \to 10^5$ 对应选中特征数 $7 \to 5 \to 2 \to 0$——$\tau = 10^5$ 时“全删”，sqft_living 也不例外。沿 λ 方向看（固定 $\tau = 10^4$），保留集跳变 11 次、含 3 次“回升”：yr_renovated 于 $\lambda = 4$k 升入（$\lambda = 0$ 时它只有 3 324、本在带内“该删”，随 λ 增大反而涨出带外才被选中）、floors 于 9k 回归、

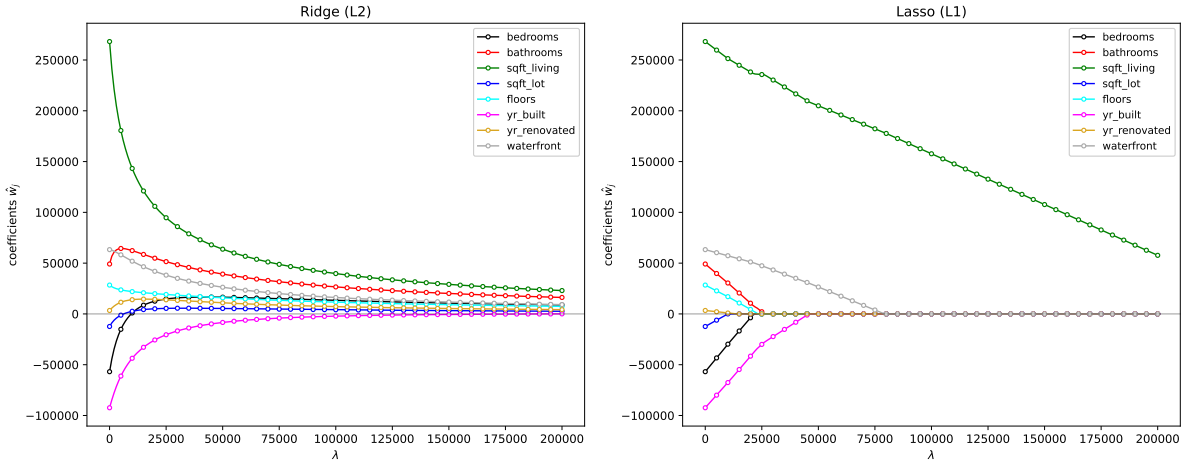


图 1: King County 数据（8 特征 z-score、price 中心化）的系数路径。左：Ridge（ℓ_2）——只缩不归零；右：Lasso（ℓ_1）——精确归零，sqft_living 保留到最后。

bedrooms 于 27k 回归——后两者都是先离开、后又回来。作为对照，Lasso 的零模式沿 λ 严格嵌套（违例 0 次）。bootstrap 稳定性检查（40 次半样本重抽）中，边界特征 yr_renovated 仅 92% 保持选中；$\tau = 10^5$ 下 40 次全部“选空”。

其二，也是核心机制：共线组内的“平摊”会让整组被删除。sqft_living 单独进入 Ridge（$\lambda = 2 \times 10^4$）时系数为 133 791；加入兄弟特征 sqft_above 后，两者变为 86 578 与 59 449——近似对半切，且两者之和（146 027）与单特征值相当：预测只依赖组内系数之和，Ridge 的最小范数解把权重平摊到共线方向上。于是在保守阈值 $\tau = 10^5$ 下，单特征模型保留（$133\,791 > 10^5$），而 9 特征模型两个成员（86 578、59 449）都低于阈值、双双被删——整个 living-area 组从“必选”变成“全删”。合成数据把机制推到极限（$x_2 \equiv x_1$ 的精确复制特征）：Ridge 解精确对半为 (88 067, 88 067)，任何 $\tau \in (88\,067,\ 176\,134)$ 都会删掉整组；而 Lasso 保留一个代表 (237 689, 0)，组信号完整无损。这正是课件第 45 页“Nothing measuring bathrooms!”的同款机制。

其三，阈值化的预测代价可观。按 7:3 划分 train/valid、对选出的特征子集重新拟合 OLS，验证集 R^2 为：全 9 特征 0.5972；$\tau = 10^4$（7 特征）0.5806；$\tau = 5 \times 10^4$（2 特征）0.5032；$\tau = 10^5$（0 特征，退化为常数模型）-0.0003。对照之下，Lasso 在 $\lambda = 10^5$ 只保留 sqft_living 一个代表，R^2 仍有 0.5033——同一组信号，阈值化 Ridge 删得一个不剩，Lasso 完整保留。

原因可以归纳为四点。其一，Ridge 的解没有稀疏性：$\hat{w}(\lambda)$ 恒非零、随 λ 连续收缩，“系数小”只说明收缩得强（大 λ 下全体都小），不代表不重要——阈值化把“收缩量”误当成了“重要性”。其二，共线时 $|w_j|$ 不是可识别的重要性度量：权重可在组内任意重分配而拟合不变，Ridge 的最小范数解把权重平摊（复制 k 份则每份 $\approx w/k$），多录一个共线兄弟就能把每个系数压到阈值之下、把整组从选择集中删除。其三，阈值 τ 是人为引入的第二个超参数，没有目标函数可供优化：选择集随 τ、λ 与数据扰动跳变（本例沿 λ 跳 11 次，bootstrap 下边界特征进进出出），“先阈值选择、后重新拟合”的两阶段流程也失去原估计的名义统计保证。其四（对照），ℓ_1 的零来自优化本身：KKT 条件与软阈值给出精确零，零集沿 λ 单调嵌套、仅由单一超参数控制，对相关组通常保留一个代表（本例 sqft_above 在 $\lambda^* = 17$k 归零、sqft_living 一直保留），组信号不丢。这些性质都是阈值化 Ridge 不具备的。

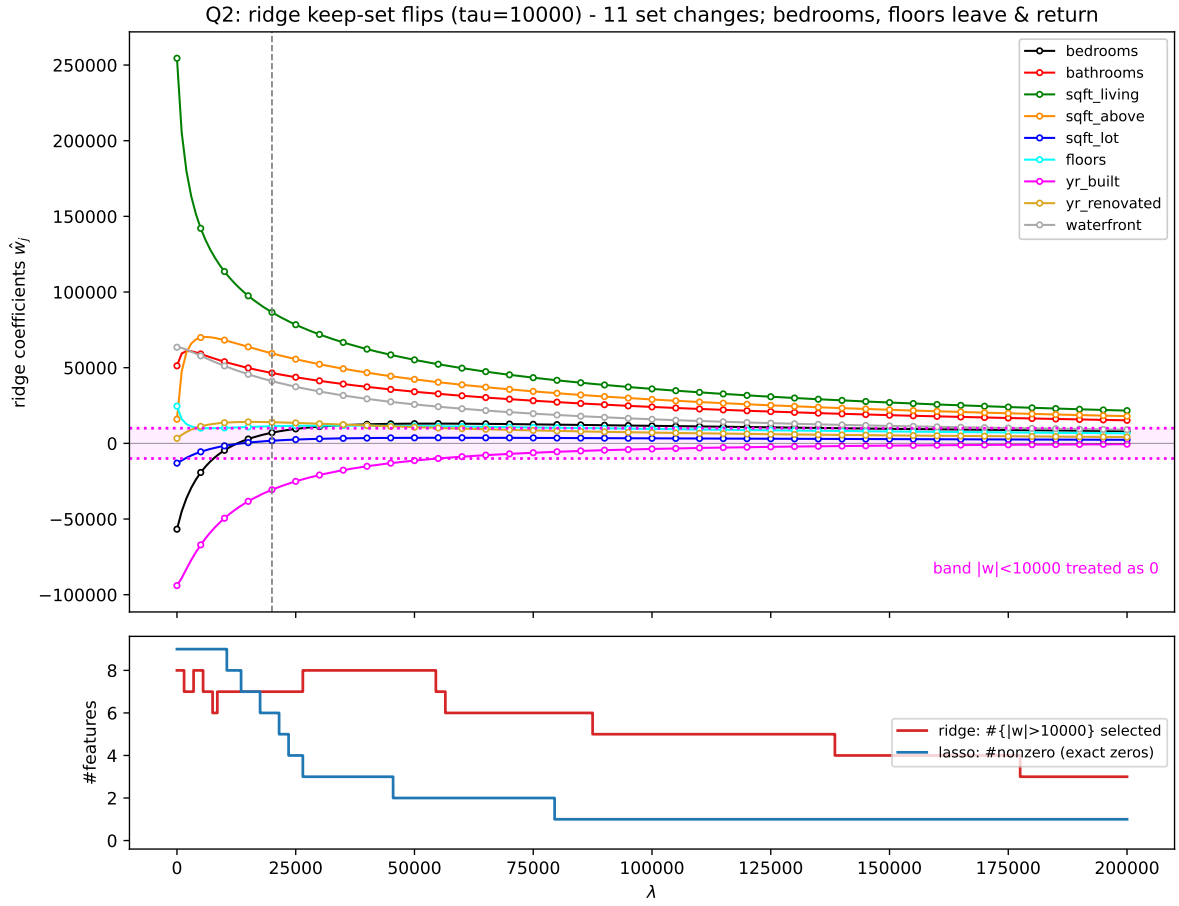


图 2: 阈值化 ridge 的“选择路径”连单调性都不满足：$\tau = 10^4$ 时保留计数沿 λ 跳变 11 次（含 3 次回归）；lasso 非零数严格单调。

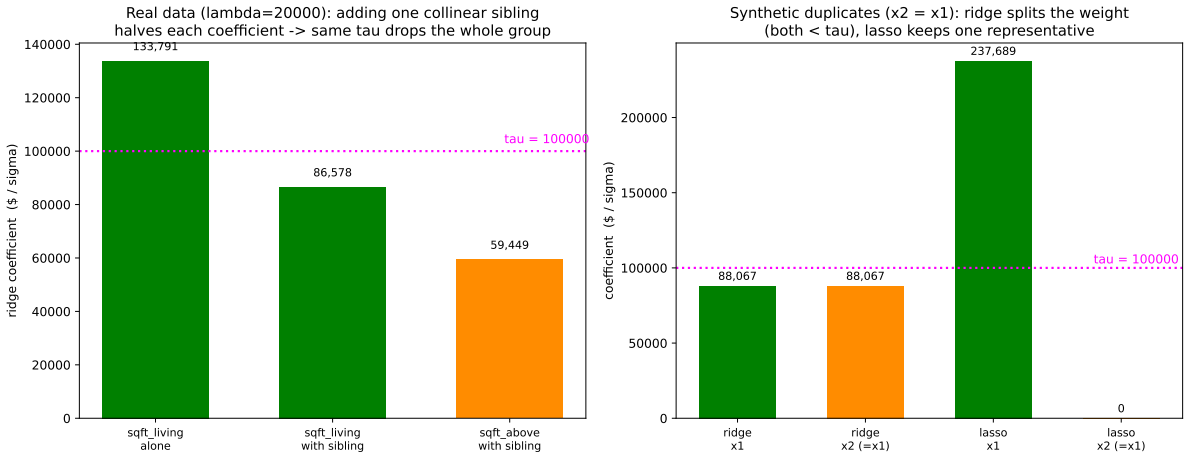


图 3: 共线案例：加入一个共线兄弟即可让每个系数减半、$\tau = 10^5$ 下整组被删（133 791 → 86 578 + 59 449）；lasso 组内保留一个代表（237 689, 0）。

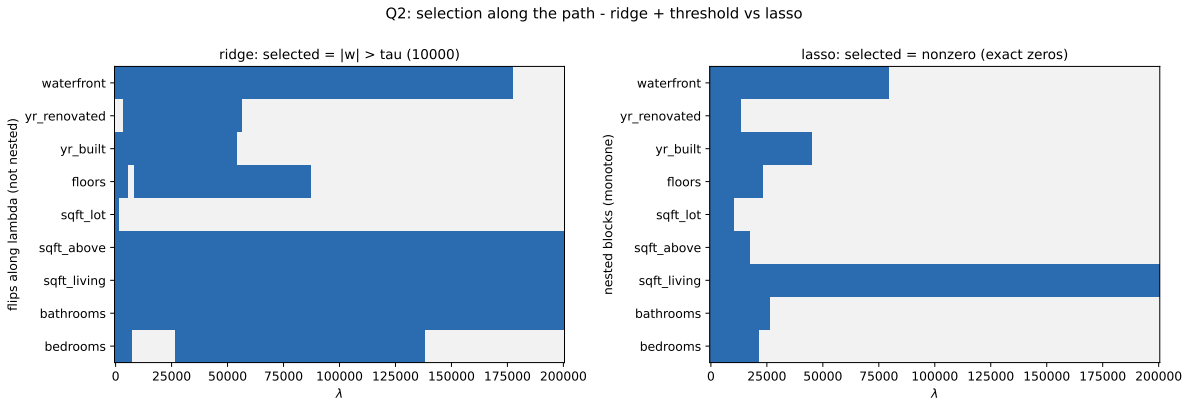


图 4: 结构判据：ridge 阈值化选择集不嵌套（bedrooms、floors 离而复返）；lasso 零模式严格嵌套，每特征仅一个连续非零窗口 $[0, \lambda^*]$。

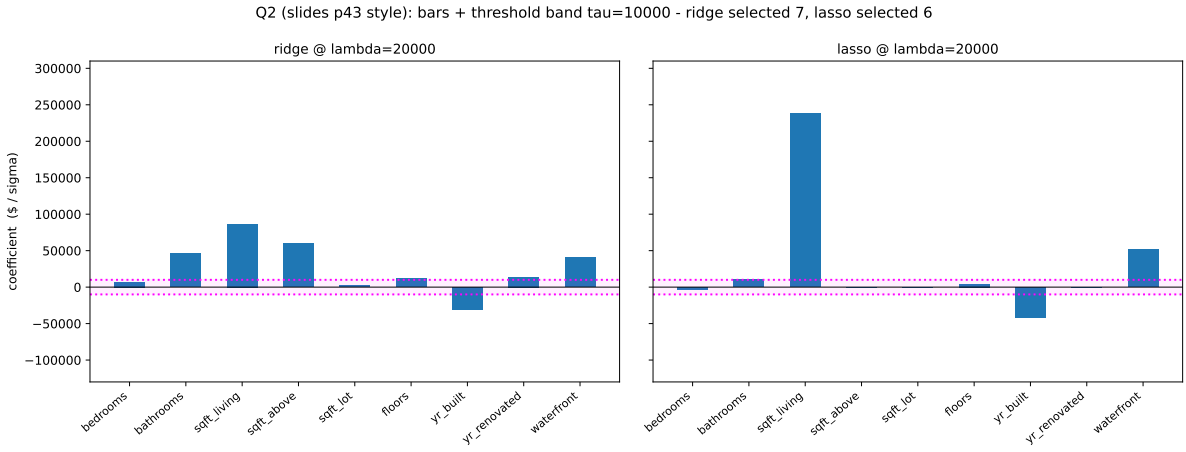


图 5: 同一 $\lambda = 2\times10^4$ 截面（p43 画风）：阈值化 ridge 与 lasso 的保留集在 bedrooms、yr_renovated、sqft_above 三个特征上互相矛盾；τ 从 10^4 扫到 10^5，ridge 保留数 $7 \to 5 \to 2 \to 0$。

3. 与 sklearn 实现有拟合效果差异吗

题面：你的模型相比于 sklearn 的实现有拟合效果上的差异吗？（简要说明即可）（提示：可以在做完后两项实验后回答该题。）

比较前必须先对齐正则口径，否则比较的是两个不同的目标函数：本仓库目标为 $(1/N)\cdot\text{loss}+\lambda_1\|w\|_1+\lambda_2\|w\|_2^2$，换算关系为 Ridge $\alpha=N\lambda_2$、Lasso $\alpha=\lambda_1/2$、ElasticNet $\alpha\rho=\lambda_1/2$ 且 $\alpha(1-\rho)=\lambda_2$、逻辑回归 $C=1/(2N\lambda_2)$（truth $N=5088$、$\lambda_2=10^{-3}$ 对应 $C\approx0.098$；注意 sklearn 默认 $C=1$ 是另一个正则强度）。对比数据取 world 第 11 层（z-score 与原始特征两组，$N=500$）与 truth 第 20 层（原始特征，$N=5088$）；最终指标取自提交用 `model.py` 的真实实现，收敛曲线用与其更新式一致的仪器化副本，不改动提交代码。

结论先行：**没有本质差异**。同一目标函数加充分收敛时两者同解（A2/A4 行 cos = 1.00000、relL2 = 0.002；B2b 行 cos 0.997），观察到的拟合差异全部可归为三类非模型因素——优化器机制、收敛预算（≈ 隐式早停正则）与正则口径，逐条说明如下。

world 的逐配置对比如下表。首先是**优化器机制**的差异：固定步长全批量 GD 受稳定界约束——raw L11 无正则、lr= 10^{-3}（界 $\approx5.4\times10^{-4}$）时训练第 8 轮 loss 即爆炸（1.14×10^{10} vs 初始 2.4×10^{3}）并被自动中止；sklearn 用精确求解器，没有步长问题。

其次是**收敛预算**，它近似一种隐式早停正则：有限轮 GD 停在更小范数点，验证指标反而更好（A1 306.55 < 311.56；B1 223.58 < 395.02；T2 ours 0.8867 > 0.8600）；延长训练会向 sklearn 解靠拢（cos 0.897 → 0.997），但验证可能回落（B2b 162.4 vs B2 150.4）。收敛曲线印证了这一点：world（$p\gg n$ 病态）GD 20000 轮仅把训练 MSE 降到 0.0047（精确最小二乘为 0）；truth GD 5000 轮停于训练 logloss 0.181，未达 lbfgs 最优的 0.066。

truth 的对比见下表。其中 T1 行是一个反例：sklearn 在无正则（`penalty=None`）下 valid 对数损失高达 27.77——可分数据上 MLE 在无穷远，精确求解没有“早停”可依靠。最后是**正则口径**陷阱：sklearn 默认 $C=1$（更强正则）时 valid 准确率 0.8500，不换算直接比较会把“超参不同”误读成“实现差异”。

一句话总结：两者差异是**优化差异**（步长/求解器/预算/早停），不是模型或实现差异。

行	设置（ours 口径）	sklearn 等价	ours valid	sk valid	cos	relL2
A1	world z-score，无正则，ep20000	LinearRegression	306.55	311.56	0.99929	0.039
A2	world z-score，$\lambda_2=1.0$	Ridge $\alpha=500$	167.06	167.17	1.00000	0.002
A3	world z-score，$\lambda_1=10^{-3}$	Lasso $\alpha=5\times10^{-4}$[a]	238.36	598.47	0.594	0.814
A4	world z-score，$\lambda_1=10^{-3}+\lambda_2=1.0$	ElasticNet	167.04	167.16	1.00000	0.002
B1	world raw，无正则，ep20000	LinearRegression	223.58	395.02	0.871	0.573
B2	world raw，历史最优，ep2000	ElasticNet	150.43	165.34	0.897	0.475
B2b	world raw，历史最优，ep20000	ElasticNet	162.36	165.34	0.997	0.082

表 1: world（L11，valid MSE；小者好）与 sklearn 逐配置对比。[a]：A3 的 sklearn Lasso 未收敛到 tol（dual gap ≫ tol），数值仅供参考。

4. world：不同层中间表征的预测效果对比与选层

题面：对比不同层中间表征的预测效果，并分析原因；你在最终模型提交中是如何选择特征选取层次的？

本节的考察设置是：13 个层（$2,5,8,\ldots,35$，步长 3）在统一配置下训练——特征 z-score（统计量只取 train）、lr= 0.002、2000 轮、$\lambda_2=1.0$——外加一条 raw L11 的历史最优配置（extra）。

行	设置	ours acc	sk acc	ours ll	sk ll	cos
T1	无正则，ep4000	0.8867	0.8533	0.255	27.77	0.772
T2	$\lambda_2 = 10^{-3}$（sk $C \approx 0.098$），ep5000	0.8867	0.8600	0.257	0.383	0.802
T2b	同 T2，ep10000	0.8733	0.8600	0.269	0.383	0.883
T3	最优配置 $\lambda_1 = \lambda_2 = 10^{-3}$，ep5000	0.8967	0.8600	0.259	0.383	0.712

表 2: truth（L20，valid 准确率；大者好）与 sklearn 对比。T1 行 sklearn 无正则的 ll= 27.77 灾难：可分数据上 MLE 在无穷远。参考：sklearn 默认 $C = 1$（更强正则）→ valid 0.8500。

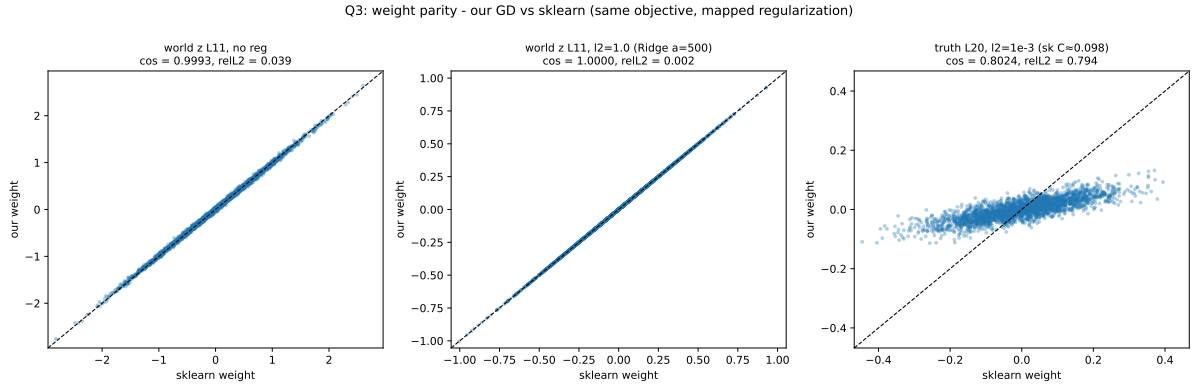


图 6: 对齐正则口径后权重逐点比对：world（$\lambda_2 = 1.0$）落在对角线上（cos = 1.00000）——同一目标函数充分收敛 ⇒ 同解；truth 未充分收敛时权重整体压向 0（relL2 = 0.794）。

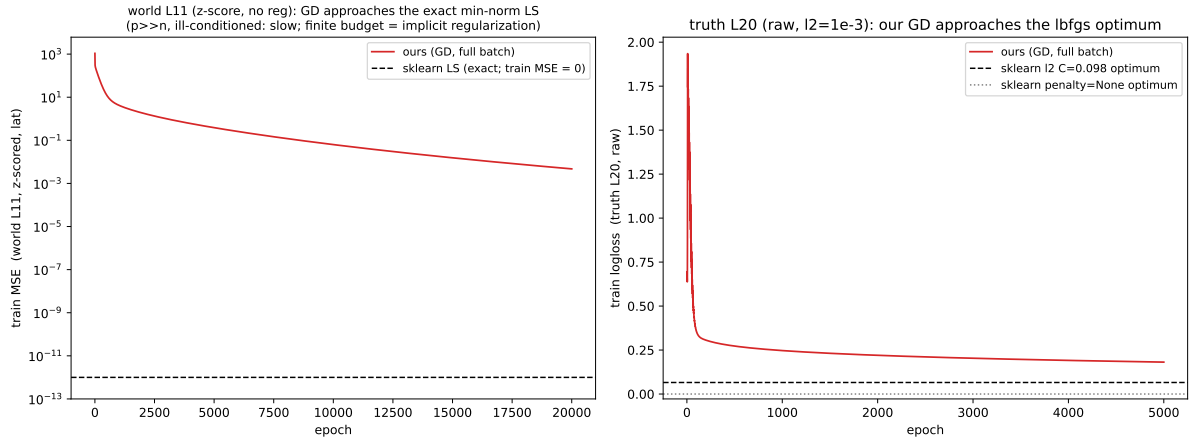


图 7: 收敛曲线：world（$p \gg n$ 病态）GD 20000 轮仅到 0.0047（精确 LS= 0）；truth GD 5000 轮停于 0.181，未达 lbfgs 最优 0.066——有限预算 GD 天然早停、起正则化作用。

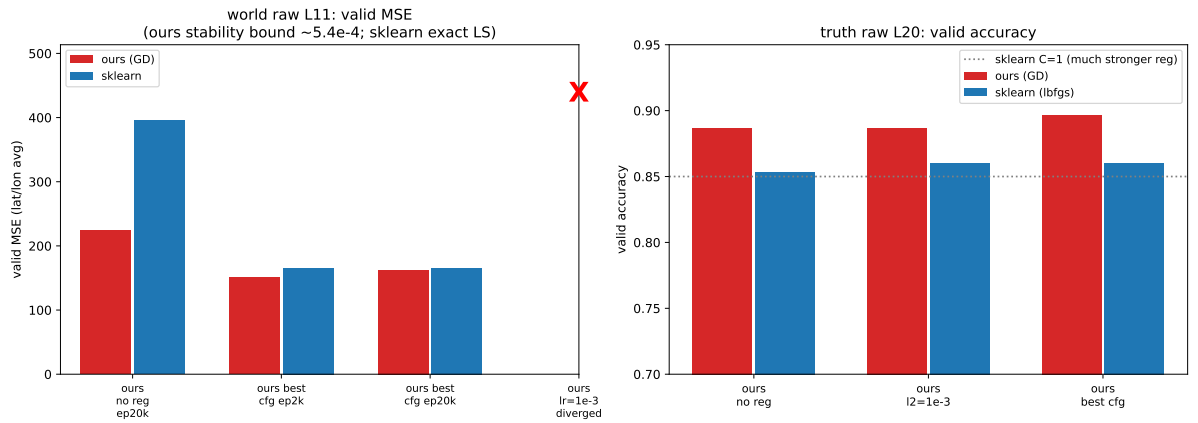


图 8: valid 指标总览：world raw 早停的 223.6 ≪ 精确 LS 的 395.0；lr= 10^{-3} 超稳定界第 8 轮发散（红叉）。truth：ours 全面不低于 lbfgs；灰线为 $C = 1$ 口径陷阱。

统计上报单层 ±1 SE（world 的 MSE 重尾，单层 SE 达 40+）；层间比较用同批验证样本的配对差 95% CI（配对后 CI 缩到 25–77）。

曲线呈 U 形（见下图与全表）。浅层 L2–L11 构成平台（157.6/163.0/159.1/167.0，两两配对差均不显著，最大 $+9.5 \pm 41.1$）；中层 L14–L29 是低谷，L17/L20/L23 显著更差（最差 +84.3，谷底在 L20/L23 约 241）；深层则出现回升——L32 回到 180.3、与浅层持平（L11 vs L32：-13.3 ± 56.2，t= -0.46），且“回升”在配对意义上真实存在（L23 vs L32：$+60.8 \pm 46.6$，L29 vs L32：$+29.7 \pm 24.4$，均显著）。全场最低仍是 raw L11（150.43），但它与 std L2（157.57）只差 7.1、不显著（对 std L20 差 91.4 才显著）——world 的水平就此锁定在 150–167（$R^2 \approx 0.955$，RMSE≈ 12.3°），继续调参不会有显著收益。

如何解释这种形状？world 的目标是位置与坐标，这类信息在浅层表征中最接近线性可分；随层深增加，表征经过更多非线性变换、语义抽象增强，坐标的线性可读性下降，中层出现低谷。深层（L32 起）的“回升”在配对意义上为真，但机制尚无定论，本实验范围内无法归因，我们如实报告为观察。跨任务对照见下一节与 § 附录 C。

最终提交选中 **raw L11**（层号 11）：点估计最低（150.43），且与 std L2/L5/L8/L11 统计上不可区分（平台内部的少量差异在重尾 MSE 下不可信），同时 11 层是课程预提取层、无须自行补提特征。备选 std L2（157.57）。**不要用** L14–L29。一个负结果值得记录：raw L2 探针（198.78）显著差于 raw L11（差 48.4）与 std L2（差 41.2）——raw 的增益是 L11 特有的组合，不是“浅层普遍现象”；L2 的浅层优势本身也依赖标准化解锁（raw 198.8 → std 157.6）。

5. world：正则化与学习率的选择

题面：你在最终模型提交中是怎么选择正则化的？请说明理由；

world 有两点先决约束：一是 $N = 500 \ll D = 2560$ 的欠定问题，必须借助正则化获得泛化；二是原始特征尺度不齐，固定学习率的稳定界随层深暴跌（跨 1800×，详见 § 附录 D）——不先解决数值问题，扫正则没有意义。

因此第一步是做特征标准化（z-score，统计量只取 train）：把各层的稳定界拉平到 $3.1\text{–}4.8 \times 10^{-3}$（只剩 1.5 倍差距），同一个 lr 对所有层公平，层间对比才成立；更关键的是，λ_2 的真实作用只有在标准化之后才会显形。

第二步扫 λ_2（固定 lr= 3×10^{-3}）：$\lambda_2 = 0.1$ 时训练残差已经很小（≈ 3）但 valid MSE 达 209

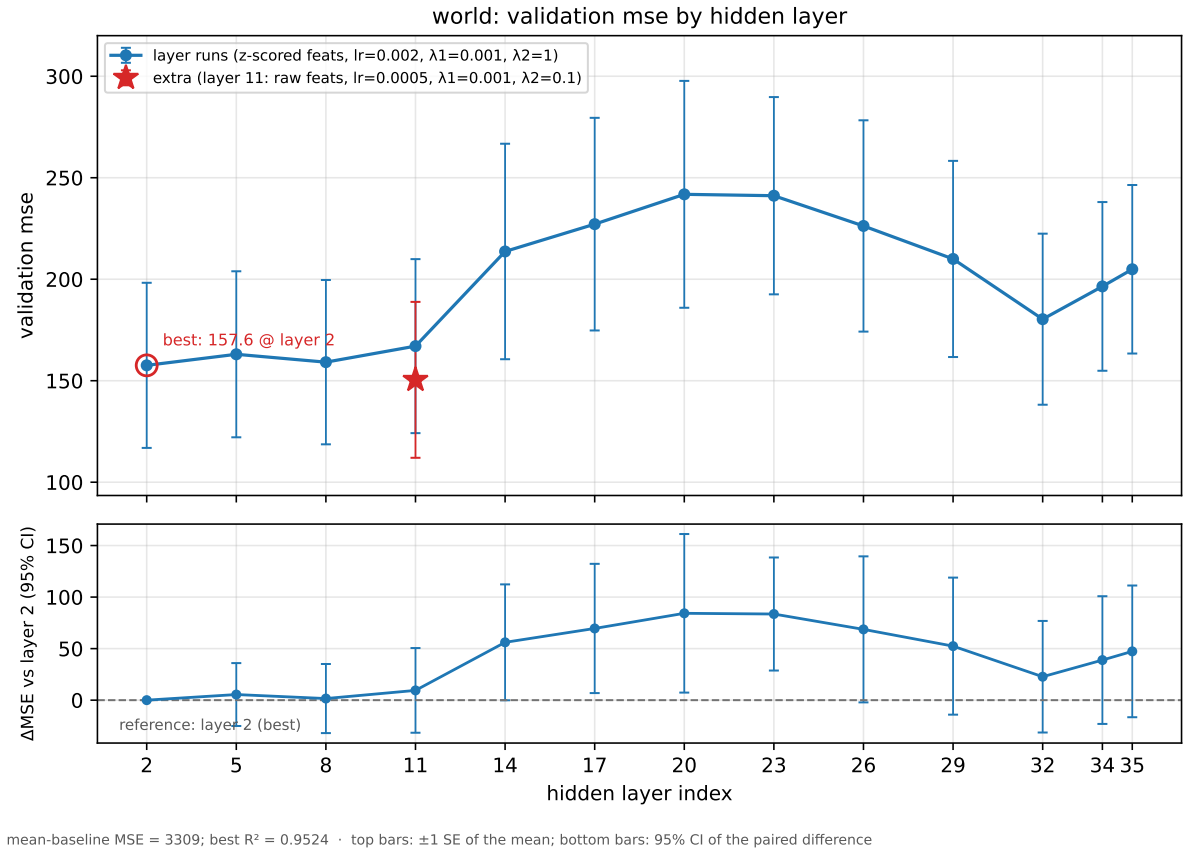


图 9: world 各层验证 MSE（上：±1 SE，红圈 = 最优 std 层，红星 = raw L11 extra；下：与 L2 的配对差 95% CI）。浅层平台—中层低谷—深层回升的 U 形。

层	配置	MSE	±SE	Δ vs L2（95% CI）	判定
2	std	**157.57**	40.7	参考	最优
5	std	163.02	40.9	+5.4 ± 30.5	不显著
8	std	159.14	40.5	+1.6 ± 33.5	不显著
11	std	167.04	42.9	+9.5 ± 41.1	不显著
14	std	213.67	53.1	+56.1 ± 56.2	边缘
17	std	227.13	52.4	+69.6 ± 62.7	显著
20	std	241.83	55.9	+84.3 ± 76.9	显著
23	std	241.14	48.6	+83.6 ± 54.8	显著
26	std	226.25	52.0	+68.7 ± 70.8	边缘
29	std	209.99	48.3	+52.4 ± 66.5	不显著
32	std	180.31	42.1	+22.7 ± 54.1	不显著
34	std	196.46	41.6	+38.9 ± 61.9	不显著
35	std	204.91	41.5	+47.3 ± 63.9	不显著
11	raw（extra）	**150.43**	38.4	—	全场最低

表 3: world 13 层验证 MSE 全表（含 raw extra）。

——严重过拟合；$\lambda_2 = 1.0$ 最优（167.06）；3.0 时收缩过强、回升到 184.57。于是 1.0 成为 z-score 版的推荐值。

λ_1 方面：truth 上的扫描显示 λ_1 对大表征有害（稠密表征下稀疏化摧毁可分方向，见第 9 题）；world 提交沿用一个小量 $\lambda_1 = 0.001$（与扫描一致，未观察到收益）。

最后把学习率放在稳定界内选取，并用训练行为双向验证：raw L11 的界为 5.4×10^{-4}，取 lr$= 5 \times 10^{-4}$ 贴线运行（MSE 150.43），lr$= 10^{-3}$ 直接溢出；z-score 版 L11 的界为 3.6×10^{-3}，取 lr$= 3 \times 10^{-3}$（0.83 倍余量，MSE 167.06），lr$= 5 \times 10^{-3}$ 越界发散。训练脚本另有发散兜底（lr 减半重试至多 4 次），处理理论之外的情况。

最终选择：**raw L11**，lr$= 5 \times 10^{-4}$，2000 轮，$\lambda_2 = 0.1$（MSE **150.43**）；备选为 z-score L11，lr$= 3 \times 10^{-3}$，$\lambda_2 = 1.0$（167.06）。两行差异 16.6、不显著（t$= -1.52$），按简单性（权重已折回原始特征空间、推理无须再标准化）选 raw。论据链：稳定界公式与对拍表见 § 附录 D，扫描全表见 § 附录 B。

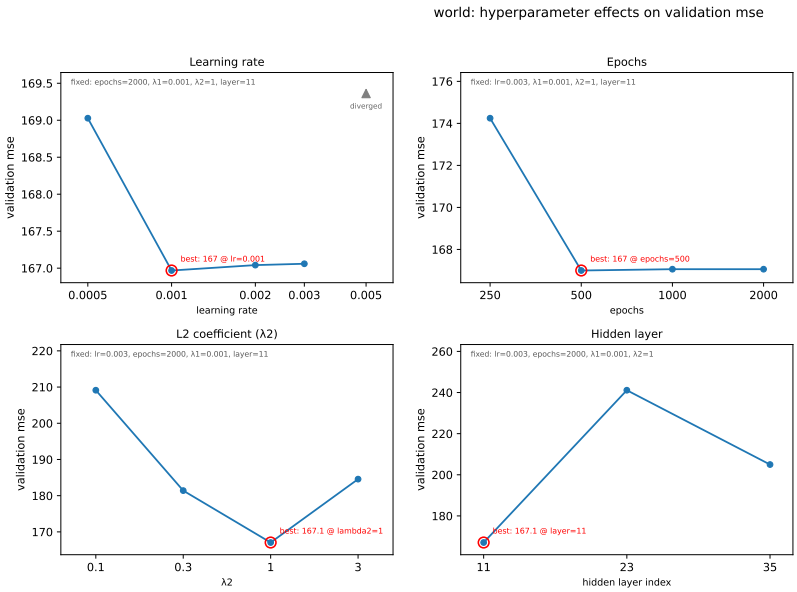


图 10: world 修复重扫（标准化后 16 次）：lr、epochs、λ_2、layer 四组超参数对 valid MSE 的影响；lr$= 5 \times 10^{-3}$ 被正确标记为发散（finite=False）。

6. 验证集预测的地图可视化

题面：给出你的模型在验证集上的预测结果，并可视化在地图上（推荐不含国界线）。（提示：此题推荐使用 AI 工具辅助可视化程序的编写。）

本节的作图与读数全部基于最终提交的 world raw L11 探针（`world_layer11_extra0/weights.npz`；权重已折回原始特征空间，推理直接 $x@w^\top + b$）。本地推理复算把 valid MSE 精确还原为 150.4277（与训练记录逐位一致），$R^2 = 0.9545$——口径闭环，为后续所有讨论提供了可靠基准。

下图把 130 个验证样本（覆盖 78 个国家）画到全球地图上：灰空心圆为真值、彩点为预测（颜色 = 单点定位误差 $\sqrt{\Delta lat^2 + \Delta lon^2}$）。模型学到的是“大洲级”定位：单点误差平均 12.44°、中位 9.52°（对应大圆距离中位 953.8 km），四分位 4.96/9.52/15.34°，超过 30° 的仅 7/130。

误差结构有两个显著特点。其一是方向不对称：纬度 MAE 仅 4.25°，经度 MAE 达 10.85°（约 2.5 倍）——模型对“气候带式”的纬度线索（tropical、desert 等词面信息）敏感，而精确定位所

需的经度信息弱得多。其二是覆盖决定精度：欧洲、东非、中美等训练覆盖密集区的误差普遍小于5°（最准的 Denmark 仅 0.79°）；失败案例集中在高纬与孤立岛屿——valid 中仅有的两条南极样本全部进入最差 top-2（89.6°、73.8°，预测都落到约 28–34°E 的南大洋），加拿大纽芬兰样本纬度几乎完美（Δ0.23°）但经度差了 40.7°。

可视化本身遵守课程红线：只绘 110m 海岸线、**不含任何国界线**。

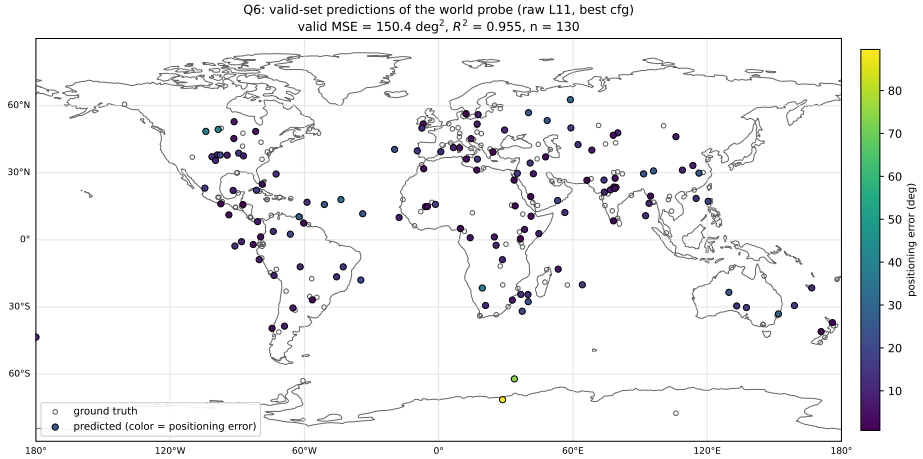


图 11: 130 个验证样本的定位：灰空心圆 = 真值，彩点 = 预测（颜色 = 单点定位误差）。valid MSE = 150.4（$R^2 = 0.955$）；中位误差 9.5°，纬度误差显著小于经度；高纬与孤立岛屿样本误差最大。仅海岸线，无国界线。

7. 是地理坐标表征，还是仅仅识别了国家？

题面：从训练集和验证集的表现，是否能够强烈说明模型内部存在地理坐标的表征，而不是仅仅识别了输入中的国家？对于该题可以参考原始论文 [3] 的部分结论和上一题的可视化结果；也可与按训练集国家分组的平均坐标基线比较，考察同一国家内不同地点的预测。

为回答“坐标表征还是仅仅识别国家”，我们设计了三层证据与两类均值基线（per-country oracle 与全局均值回退）。主基线取 **oracle 国家均值**：每国用**训练集**该国坐标均值、以**真实国家标签**查找——这一设定对基线有利，相当于给基线配了“真国家标签 + 训练记忆”两个外挂；训练未见国家回落全局均值，其 MSE 为 3311.27。improvement = 基线 − 模型（正表示模型更好），全部 CI 为 paired bootstrap。集合分层：all 130 / seen 110（训练出现过的国家）/ multi 73（同国 ≥ 2 条）/ single 37（独苗）/ unseen 20（19 个训练未见国家）。

证据 I ——“不是仅仅识别国家”。最直接的判别集是 unseen 的 20 条：这些国家在训练集中完全没有出现，**按国家查表在原理上不可能**；模型 MSE 158.90 对全局均值基线 1182.83，improvement **+1023.93** [**513.94**, **1654.14**]。同一国家内部也有弱的定位痕迹：73 条多样本国家样本相对该国训练均值的偏差中，纬度相关 $r = 0.201$ [0.021, 0.389]（弱显著，slope 0.115）；美国 8 条样本的方向整体正确（中心化 $r = 0.69/0.60$，lat/lon）。模型确实携带了超出国家身份的位置信息。

证据 II ——限度。一旦把集合限定到训练见过的国家，oracle 反而反超：seen 110 上模型 148.89 对 **113.77**（imp −35.12 [−60.90, −7.08]，CI 不含 0），multi 上同样显著（204.97 vs 159.58），single 上差距不显著（38.24 vs 23.39）且双方都不差。三点佐证说明“国家身份 + 记住常见地点”是模型

在 seen 国家上的主要得分来源：其一，经度在国内几乎无分辨力（$r = 0.046$，ns）；其二，两坐标斜率都远小于 1（0.115/0.027），模型强烈地把同国地点拉向“国家中心”——与 Q6 的“大洲级精度”一致；其三，数据重叠大——valid 样本到同国最近训练点的距离中位仅 2.03°（40/130 < 1°、89/130 < 3°），oracle 基线由此相当于“查表 + 近邻插值”，其强度有相当部分来自地点重叠（极端例 Jamaica：基线 MSE = 0.01，valid 地点与训练地点几乎同点）。稳健性：multi 去掉南极洲 2 条后方向不变（115.87 vs 65.24）。

回到 unseen 地图：20 条的预测整体落在正确区域（欧洲 → 欧洲、中美 → 中美），最差 3 例为 Mauritius 38.03°（经度从 57.50 掉到 19.49、落到非洲大陆）、Estonia/Russia 31.60°、Finland 24.53°，最好 Denmark 0.79°——失败模式与 Q6 一致，误差集中在经度与孤立岛屿。对 +1024 需要诚实解读：该比较的基线（全局均值）本身很弱，它证明的是“模型远不止于一个全局平均”，而非“模型精确”；精确度仍受 Q6 与同国分析的中等误差约束。

综合定性为**中等强度**：强于“纯国家分类器”——unseen 上查表原理上不可能、却大胜全局基线；弱于论文 [3] §5 的神经元 + 干预级证据（需要模型内部访问与激活干预，超出本实验范围，只能在报告中引用）；与论文 §4.1 对同类 block-holdout 实验的自评“weak evidence”、以及本课 README §1.2“可解码 ≠ 生成时一定使用”的警示一致。我们的“方向对、幅度收缩”与论文术语“relative position correct, absolute position often wrong”是同一现象——Q6 地图上的经度/小岛屿误差集中正是它的可视化表现。

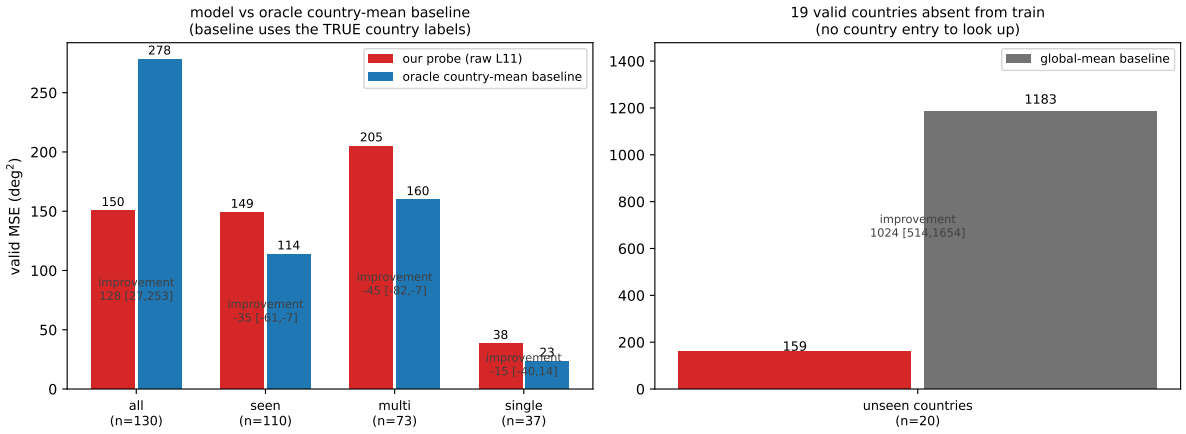


图 12: 模型 vs oracle 国家均值基线的分层 valid MSE。左：seen 国家按样本数分层；右：19 个训练未见国家。improvement = 基线 − 模型；误差棒为 paired bootstrap 95% CI。

8. truth：训练集/验证集的分布差异与应对

题面：仔细阅读训练集和验证集，模型的训练集和验证集存在哪些分布上的差异？你是如何应对的？

先给结论：truth 的训练集与验证集存在**系统性、构造性的分布差异**——验证集更像一个“设计过的 OOD 挑战集”，而不是同分布的随机留出；而我们的最终探针对这些差异是稳健的，应对的核心是评估方法论。下面按四个差异维度（以 world 为对照）依次报告，并给出探针在差异上的实测表现。

第一，拼写噪声（差异①）。相邻字母交换型错拼句在 train 中占 7.0%（354/5088），在 valid 中高达 24.7%（74/300），约为 train 的 3.5 倍；两侧标签内均衡（valid 25.3%/24.0%，train 7.1%/6.8%），不是“假句才加噪”；错误类型为形近错（mkaes→makes、connectiuct→connecticut 等）。作为对

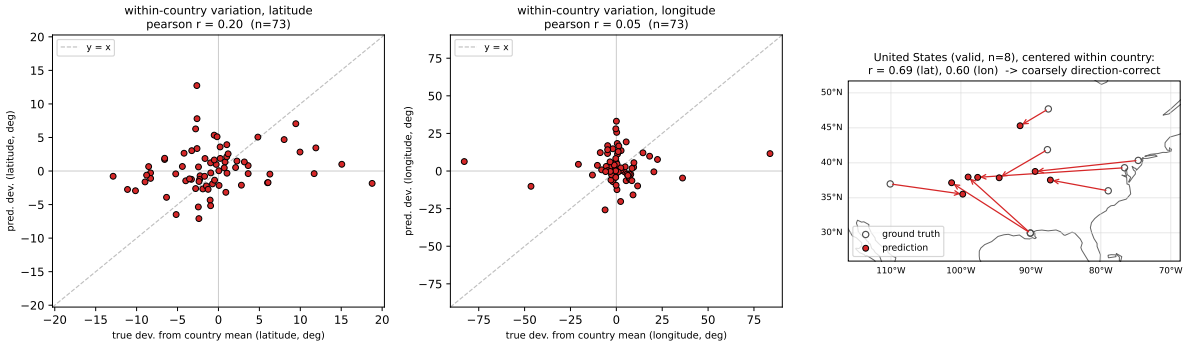


图 13: 同国内分辨力：73 条多样本国家样本相对该国训练均值的偏差（纬度 $r = 0.20$ 弱显著，经度 $r = 0.05$ ns）；右：美国 8 条样本真值 → 预测箭头（方向大体正确、幅度收缩）。

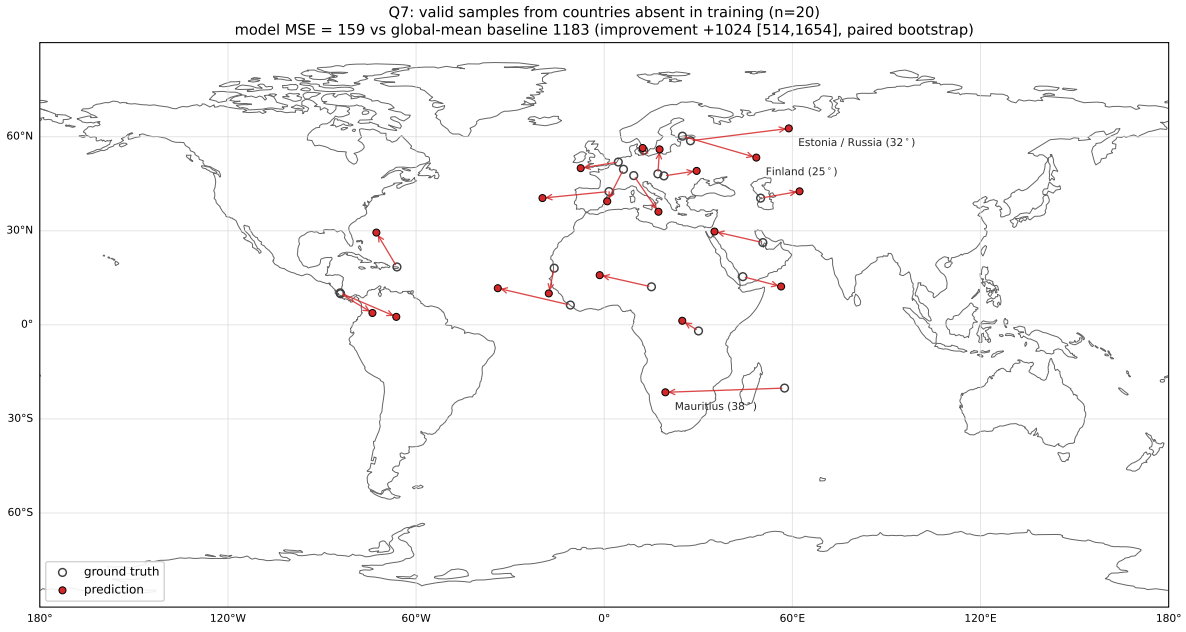


图 14: 19 个未见国家 20 条样本：模型 MSE 159 vs 全局均值基线 1183（imp +1024）。预测整体落对区域（欧洲 → 欧洲、中美 → 中美），最差 Mauritius 38.0°。仅海岸线，无国界线。

照，world 两侧均为 0.8% 且全部为地名假阳性（centre、rila 等）——错拼噪声是 truth 特有、且只在 valid 侧加重。第三，模板与长度（差异③）：train 特有的情态否定句式在 valid 几乎消失——“One can”train 129 条（2.5%）对 valid 2 条，“If one”24 条对 0，合计约 3.0% 对 0.7%；valid 的句长长尾也被截断（上界 162 对 487 字符）。

第二，主体新颖度（差异②）。valid 的 300 条中 212 条首实体可识别，其中 164 条（**77.4%**）未在 train 出现；若 valid 是从 train 随机留出的，该比例应落在零假设分布内——从 train 随机抽 300 条、200 次重抽得到的均值为 20.8% [15.6, 25.6]，77.4% 远远出界。高频新主体如 Dave Grohl（×8）、Dwyane Wade（×7）、The Offspring（×6）在 train 中计数为 0。稳健性核查：错拼恰好落在主体内部的仅 8 条（如 Paula Deen→Paula Eden、Dwyane Wade→Dwayne Wade），逐条修正后全部仍为“train 未见”——77.4% 不受错拼污染。第四，world 对照（差异④）：world 没有噪声差异，差异在实体/字符串层面——valid 有 20/130 条来自 19 个未见国家、126/130 条地点字符串未在 train 出现；但其中大多数空间上仍邻近（全部 130 条中 89 条距同国最近训练点 $< 3°$），真正“既新又远”（$\geq 3°$）的只有 41 条——**字符串新颖 $\neq$ 空间新颖**。两题 valid 的“难”来源不同：truth 难在噪声 + 新主体，world 难在地理外推。

这些差异对最终模型的实际影响有多大？在 L20 探针（总体 0.8967，anchor 复算逐位一致）上看：带错拼子集 0.932 [0.865, 0.986] 不低于干净子集 0.885 [0.841, 0.925]，干净 − 错拼差 −0.047 [−0.115, +0.024]（CI 含 0——错拼不伤害）；主体 seen 0.917 [0.833, 0.979] 对 unseen 0.884 [0.835, 0.933]，差 +0.033 [−0.063, +0.119] 同样不显著。错拼 × 主体四格交叉的四个点估计排序为 clean×unseen < clean×seen < typo×unseen < typo×seen，即两类“难组”都没有受到明显惩罚。三个稳健性核查支持该结论：剔除 Dave Grohl / Dwyane Wade 两个重复家族后 typo 组仍 0.935（$n = 62$），非重复句假象不成立；typo 子集的主体构成与 clean 接近；逐层看，错拼的伤害只在浅层——L5–L11 的干净 − 错拼差为 $+5 \sim 7$pp（浅层接近词面特征、字符扰动直接改变激活），而 L17 及以后转负（L17 −6.1pp、L20 −4.7pp、L29 −4.2pp），文本级噪声在中深层被表征“平滑吸收”。这为“选深层探针”提供了又一条独立理由——与 Q4/Q9 的选层结论在噪声鲁棒性维度上互相印证。小格子不可过度解读：label= 0 的 typo 组 0.972、typo×seen 1.000 的点估计虽高，n 仅为 8–36、CI 极宽，只应作为“未见惩罚”的证据。

我们的应对分三层。其一，读数方式：一切子集比较配 bootstrap 95% CI（$n = 300$ 的单点差异约 ±3.5pp、30 条子集约 ±10pp），CI 跨 0 的差异不当作选层/选参依据；分层报告（typo / 主体 / 标签）而不是只看总 acc。其二，不向 valid 泄漏：层与超参的选择来自扫描与分层训练报告 + 配对检验口径；训练用固定预算、不按 valid 早停——避免在 300 条 OOD 样本上反复挑选。其三，文本不做清洗：特征提取对原始文本（含错拼）直接前向——若清洗 train 侧错拼，train（7.0% 噪声）与 valid（24.7%）的口径反而更不一致，且部署时模型同样要面对噪声；分层证据也显示选深层本身就是天然的抗噪手段。valid 指标因此是“OOD + 加噪”的保守口径，报告中如实标注。

作为“同分布口径”的对照，我们在 train 内部做了 3 折 CV（L20 特征、仓库 model.py 同配置、$n = 3785$ 条可识别主体行）：随机划分 held-out acc 均值 0.869（折间 std ≈ 0.010）对有主体分组划分 0.877（std ≈ 0.004，测试折主体 100% 未见对随机的 38%），差 −0.8pp 在折间噪声内。诚实地说，该实验没有证实“随机划分高估泛化”的假设；但正因如此，它给出了一个有信息量的结论：**L20 探针不依赖“记住主体”**，valid 的 0.8967 没有被主体新颖度注水——与分层结果（seen vs unseen 不显著）从两条独立路径得出同一结论。（口径注意：CV 每折训练量小于最终模型、测试折来自 train 分布，不能把 CV 均值与 valid 0.8967 直接相减。）综合而言：train/valid 的差异真实存在——拼写扰动与主体轮换的构造性 OOD，此判断由差异①②两项统计指纹直接支持；但最终模型对它们是稳健的。

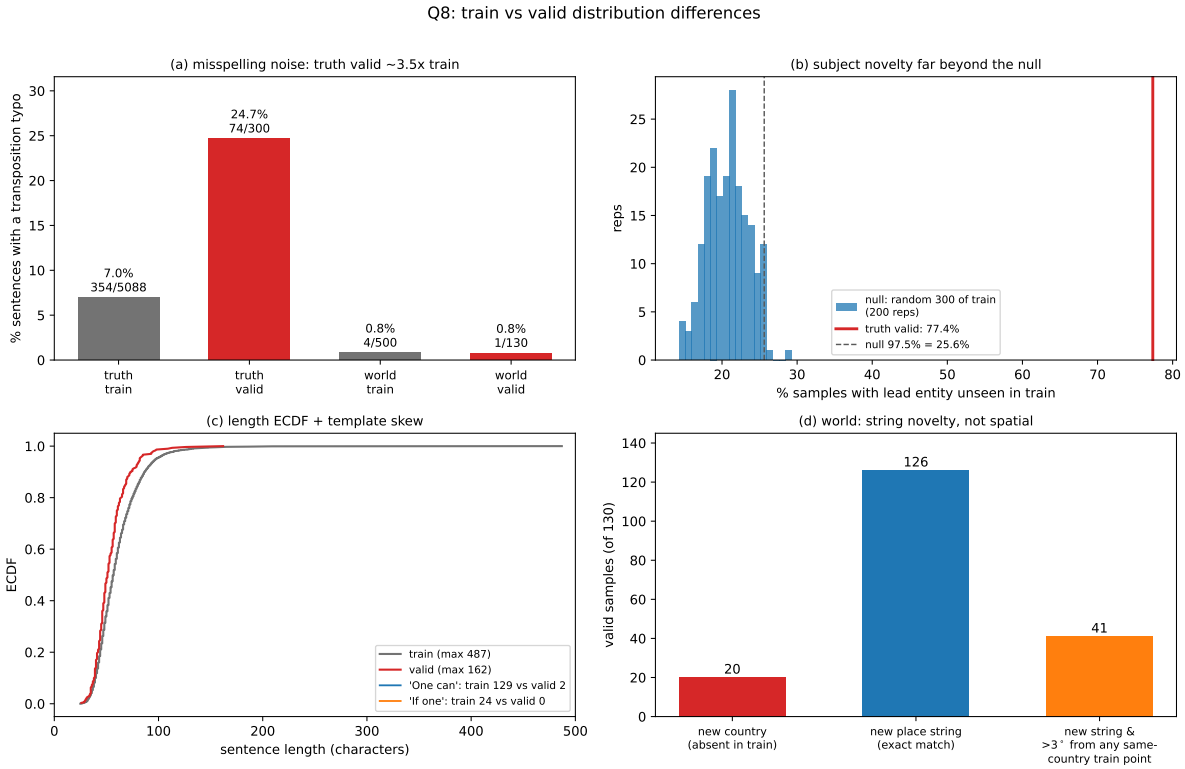


图 15: 分布差异总览：(a) 拼写噪声 valid ≈3.5× train；(b) 主体新颖度 77.4% 远在零假设分布之外；(c) 长度 ECDF 与模板差异；(d) world 对照——字符串新颖而非空间新颖。

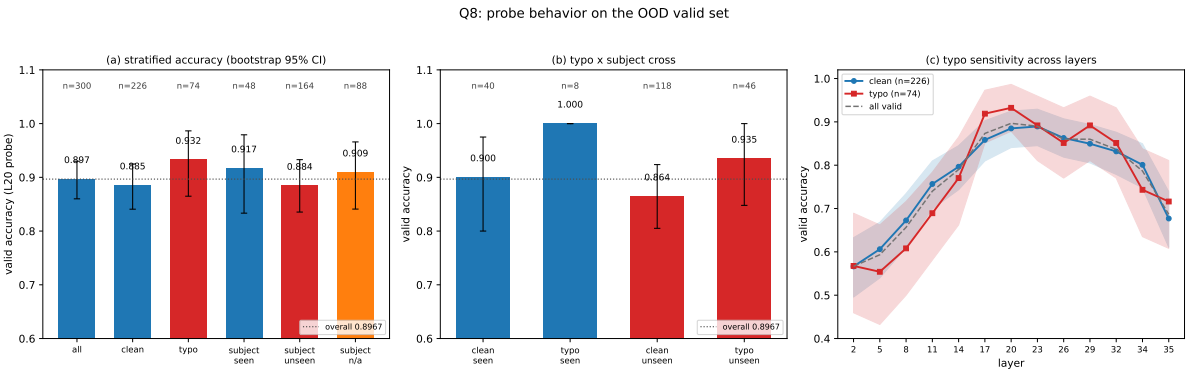


图 16: L20 探针在 OOD valid 上的分层表现：(a) 主分层准确率；(b) typo × 主体交叉；(c) 13 层探针的 typo 敏感度。

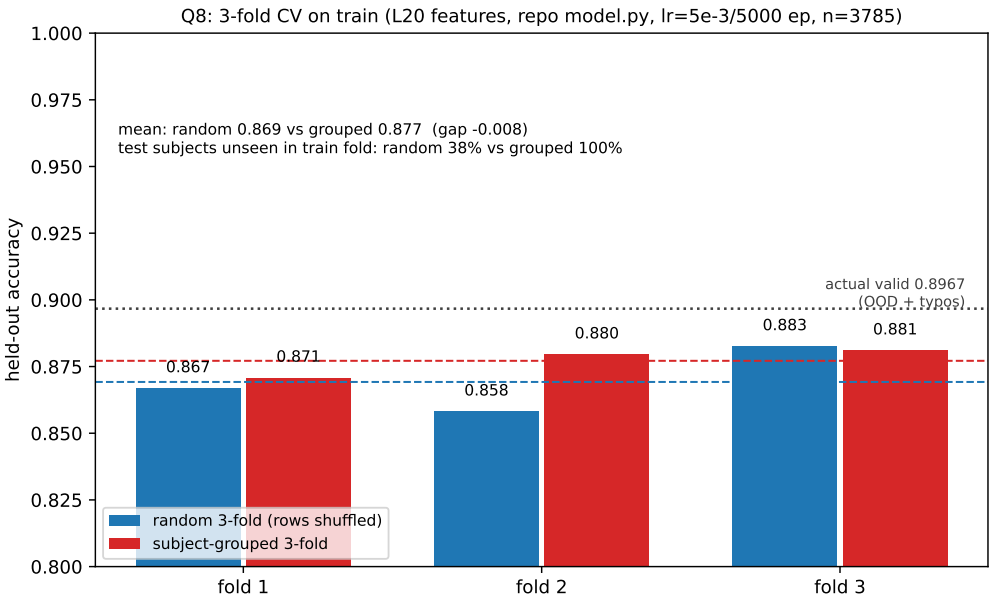


图 17: train 内部 3 折 CV 对照（L20、仓库 model.py 同配置、n=3785）：随机 vs 按主体分组划分（测试折主体未见比例 38% vs 100%）的 held-out 准确率——均值 0.869 vs 0.877（差 −0.8pp，在折间噪声内）；灰点线为实际 valid 0.8967。两种划分口径几乎无差 ⇒ L20 探针不依赖主体记忆。

9. truth：选层与正则化的理由

题面：你在最终模型提交中是怎么选择特征选取层次和正则化的？请说明理由。

选层方面，我们沿用与 world 相同的做法，把 13 层放在统一配置（raw 特征、lr= 5×10^{-3}、5000 轮、$\lambda_1 = \lambda_2 = 10^{-3}$）下扫出完整曲线。truth 呈清晰的**倒 U 形**：从 L2 的 0.5667 单调爬升，到 **L20 峰值 0.8967**（随机水平 = 多数类 = 0.50），L26 起显著回落，L35 只剩 0.6867。统计上，L17（−2.33pp ± 2.84pp）与 L23（−0.67pp ± 2.45pp）相对 L20 的配对差均不显著——**L17-L23 构成统计等价的“中层平台”**。我们建议不要过度解读 0.67pp 的峰差，但取 L20 为首选：数值最高、峰位居中、两侧对称性最好；L23 为备选（0.8900，与 L20 统计等价）。

如何解释这一形状？真假判断依赖“语义级”信息，它在 **L17-L23 的中层**对线性探针最可读；浅层还停留在词法与局部特征（L2 仅 0.5667、L11 0.7400），深层经过更多非线性重整后线索反而被稀释（L32 起显著下跌，L35 只剩 0.6867）。对照 world——它的最优层带在浅层 L2-L11——**两个任务的最优层带截然不同**：位置坐标信息在浅层最线性可分，“真假”语义在中层最线性可分，说明表征的不同深度承载不同类型的信息。选层的收益是实打实的：truth 中层比浅层高 15.7-33pp。一处结论修正值得记录：88653 的三层扫描（lr= 5×10^{-4}、500 轮的受限配置）曾给出“L23 一枝独秀（84.3%）”；13 层全扫后修正为“中层平台、峰位 L20”——层间顺序一致（同三层在两次配置下的 63.7%/84.3%/63.0% 分别升至 74.0%/89.0%/68.7%），但受限配置会低估各层水平，“一枝独秀”的形态随之修正为平台。

正则化的选择同样来自扫描（88653，L11 口径）：λ_1 有害——$0 \to 70.0\%$、$10^{-3} \to 68.7\%$、$10^{-2} \to 67.0\%$、$0.1 \to$ **50.0**%（崩到随机水平）。原因在于表征是稠密的（2560 维几乎全非零），ℓ_1 会把大量权重分量精确压到零，直接摧毁可分方向所需的权重；相比之下 λ_2 完全不敏感（$0/10^{-3}/10^{-2}/0.1$ 全部 68.7%）。最终取 $\lambda_1 = \lambda_2 = 10^{-3}$：弱正则、给两侧都留余量。

为什么不干脆无正则？truth 在训练集上近似线性可分，无正则的逻辑回归 MLE 会沿可分方向把权重推往无穷远——Q3 的 T1 实测确认了这个灾难（sklearn penalty=None 的 valid 对数损失

27.77），而手写 GD 靠“有限轮预算”隐式早停（valid 对数损失 0.255），无正则反而稳健。也就是说我们同时依赖两个机制：**弱正则 + 有限的轮预算**共同起稳定作用。收敛预算定为 5000 轮；13 层中仅 L2/L32 触发早停、其余全部跑满——单层在 lr×epochs 联合空间中再精调或有 1–3pp 的空间，但单层训练 220–590s、收益/代价比一般，我们如实保留这个提升空间。

最终提交：**raw L20**，lr$= 5 \times 10^{-3}$，5000 轮，$\lambda_1 = \lambda_2 = 10^{-3}$，valid acc **0.8967**；备选 L23（0.8900，与 L20 统计等价）。**不要用** L14 及以下（≤ 0.79）或 L26 及以上（显著回落）。lr$= 5 \times 10^{-3}$ 来自 88653 的倒 U 扫描（L11 口径：0.01 开始震荡 63.0%、0.005 峰值 68.7%、0.0005 欠拟合 63.7%），而在 logistic 损失下它没有任何数值风险——有界梯度使 truth 的稳定界比二次界宽松约 8 倍（详见 § 附录 D），与 world 必须贴着稳定界取 lr 的处境完全不同。

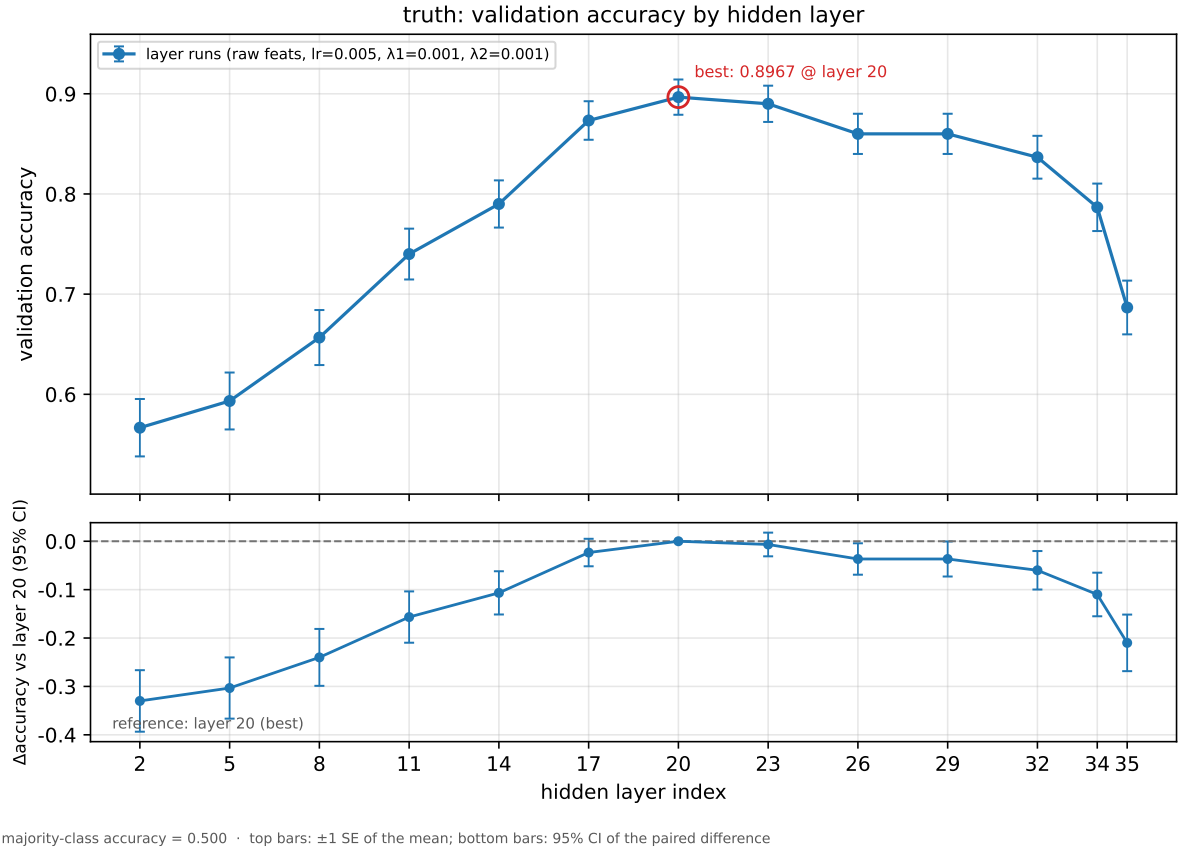


图 18: truth 各层验证准确率（上：±1 SE，红圈 = L20；下：与 L20 的配对差 95% CI）。倒 U 形、中层平台。随机水平 = 多数类 = 0.50。

层	acc	±SE	Δ vs L20（95% CI）/判定
2	0.5667	0.0287	−33.00pp ± 6.36pp 显著
5	0.5933	0.0284	−30.33pp ± 6.32pp 显著
8	0.6567	0.0275	−24.00pp ± 5.88pp 显著
11	0.7400	0.0254	−15.67pp ± 5.30pp 显著
14	0.7900	0.0236	−10.67pp ± 4.47pp 显著
17	0.8733	0.0192	−2.33pp ± 2.84pp 不显著
20	**0.8967**	0.0176	参考（最优）
23	0.8900	0.0181	−0.67pp ± 2.45pp 不显著
26	0.8600	0.0201	−3.67pp ± 3.25pp 刚好显著
29	0.8600	0.0201	−3.67pp ± 3.62pp 边缘
32	0.8367	0.0214	−6.00pp ± 3.98pp 显著
34	0.7867	0.0237	−11.00pp ± 4.50pp 显著
35	0.6867	0.0268	−21.00pp ± 5.84pp 显著

表 4: truth 13 层验证准确率全表（raw，lr$= 5 \times 10^{-3}$，5000 轮，$n = 300$）。

A 背景知识：线性探测、Qwen3-4B 与两个任务

线性探测（linear probing）[1] 是研究模型内部表征的一种回归分析手段：训练时冻结大语言模型，只在某一中间层的激活（隐表征）上训练一个简单模型——本实验中即手写实现的线性回归与逻辑回归；若该模型能在独立验证集上优于合理基线，说明相应信息以（近似）线性可分的形式编码于该层表征、可被“解码”。线性可解码是一个良好的性质：信息可用简单模型读出，也是激活引导（activation steering）等后续干预研究的前提；但需注意“可解码 $\neq$ 模型在生成时一定使用了该信息”。本实验考察 Qwen3-4B-Base 内部的两类表征：地理空间坐标（论文 [3] 实验的简化，用线性回归预测经纬度）与句子真假（论文 [4] 实验的简化，用逻辑回归预测真假标签）。

特征口径：Qwen3-4B-Base 共 36 个 decoder block（编号 0–35），隐藏维度 $D = 2560$；特征取指定词元在 block 输出处（最终 RMSNorm 之前）的隐状态，不使用聊天模板。词元选择随任务而定：world 取“国名最后一个词元”，truth 取“句子最后一个词元”。课程预提取了第 11、23、35 层；我们另按实验文档的算力平台教程提取了其余 10 层，凑成 13 层（从 2 到 35、步长约 3）以支撑层间对比（提取与训练的工程细节见附录 B）。特征文件以 float16 存储为 $(N, 2560)$ 数组，训练与评测时转为 float64。

两个任务的规模与角色不同。world 为回归任务（热身）：train 500 / valid 130，目标为（纬度, 经度）双输出（单位度，北纬、东经为正），按 MSE 评测；$N = 500 \ll D = 2560$ 为欠定问题，必须借助正则化与特征层选择获得泛化能力，课程对其效果赋权低于 truth。truth 为二分类任务（主考察）：train 5088 / valid 300，标签 1 为真、0 为假，两个集合内真假各半；样本数大于特征维度。两者的最终效果均在一个未公布的测试集上评测，且测试集分布更接近验证集而非训练集——因此不应以过拟合训练集的方式提分。

提交物为两份 `.npz` 权重（`float64`）：world 为 `weights` $(2, 2560)$（两行依次对应纬度、经度）与 `bias` $(2,)$；truth 为 `weights` $(2560,)$ 与零维 `bias`；另附所选特征层的层号（$[0, 35]$ 整数）。两个数据集均为课程自建、与论文原实验所用不同，构造细节未公布；关于它们的构造线索与训练/验证分布差异，见第 8 题。

B 有意思的实验：超参数扫描、稳定界与工程实践

在正式的分层训练之前，我们做了两轮系统性的超参数扫描（全部为全批量 GD、确定性代码，本地与集群数值一致）。首轮（job 88653）以单变量对照的形式跑了 9 组 35 次训练：两任务在 L11 上分别扫 lr、epochs、λ_1、λ_2，并以 L11/23/35 扫描层。扫描给出的主要结论与正文 Q5/Q9 一致，此不重复；这里值得记录的是扫描本身暴露出的形态：truth 的 lr 呈倒 U（0.005 最佳）、λ_1 有害、层间差异巨大（L23 84.3% 对 L11/L35 的 63% 上下）；world 则是 lr 越大越好但上限被锁死在 5×10^{-4}（150.94），layer 23/35 在 lr$=2\times10^{-4}$ 下直接发散为 inf——同一份扫描在两个任务上呈现完全不同的数值面貌（logistic 有界梯度对 MSE 无界残差），由此引出了一整条“数值修复”支线。

world 的发散最初表现为一串极具误导性的日志与状态。日志写“Training converged at epoch 263, loss=inf”——收敛判据 `np.isclose(inf, inf)` 为真，把损失溢出误报成了收敛；实测权重并未变成 nan，而是有限的天文数字（max$|w|$ 达 1.8×10^{151}、7.9×10^{152}），旧代码“权重是否有限”的检查因此误报通过；更隐蔽的是发散时预测出的 MSE 是有限大数（3.9×10^{305}）而非 inf——“只查权重”或“只查指标”都会漏检，必须引入独立的发散标志位。

修复分三处：`model.py` 新增 diverged 状态（梯度/权重/loss 非有限、或 loss 超过初始值 10^6 倍即中止训练并置位，与正常收敛严格区分）；`run_grid.py` 支持逐组 standardize（z-score 统计量只取 train split、验证集复用同一 μ/σ），并支持把标准化空间的权重精确折回原始特征空间（$w'=w/\sigma$、$b'=b-\mu\cdot w'$，在原始特征上复算一致、误差 $\sim10^{-14}$）。根因也随之明确：发散不是“深层没有信息”，而是 lr 越过了**按层稳定界**——未标准化时该界随深度暴跌 1800 倍（数学见附录 D）。

第二轮（job 89085，16 次训练）在 z-score 特征上重扫。标准化把各层稳定界拉平后，lr$=3\times10^{-3}$ 对三层均安全、5×10^{-3} 的越界被 `finite=False` 正确标记为发散；λ_2 呈现出真实的 U 形（$0.1\to209.13$——训练已收敛但验证严重过拟合；$1.0\to167.06$ 最优；$3.0\to184.57$）；epochs ≥500 即到平台。layer 扫描（lr$=3\times10^{-3}$）：L11 167.06 / L23 241.12 / L35 204.98。至此三条独立路径——raw 冠军（L11 150.4）、raw 长训练（L23 在 lr$=5\times10^{-5}$、20000 轮下 233.1）、标准化收敛（上列数字）——交叉印证了“L11 是 world 最优层、L23/35 在真正收敛后确实更差”，排除了“深层只是训不动”的假象。

工程方面，truth 的“13 层 × 5000 轮”在 4h 平台上限内跑不完（首跑 89700 超时），我们把它拆成 4 个分块作业（90243–90246）并实现断点续跑：`--skip-existing` 复用已完成层、`python -u` 实时日志、BLAS 线程钉定避免共享节点抢占。四个作业全部成功、零发散；L5 撞上慢节点跑了 3390.5s（约 15 倍于正常耗时）仍被分块设计吸收、零进度损失。统计方法上，层间比较统一使用同批验证样本的**配对 bootstrap 95% CI**：world 的 MSE 重尾，单层 SE 达 40+，配对后 CI 显著收窄（25–77）；truth 单样本值 0.33pp。

C 有趣的表征：跨任务对照与现象观察

本附录收集正文放不下的跨任务表征观察与现象汇总。第一，两任务的**最优层带完全不同**：world 在浅层 L2–L11（157.6–167.0 的平台），truth 在中层 L17–L23（0.8733–0.8967 的平台），且两者都在 L32–L35 变差——位置/坐标信息与真假语义的“可线性解码深度”不同，说明不同类型的信息写在表征的不同深度上。一处与论文的差异如实报告：论文 [3] 在 LLaMA-70B 上报告 world 表征约在 60% 深度处最佳，而我们在 Qwen3-4B 上的 world 最优却在很浅的层——模型、数据集与特征口径均不同，我们不做进一步归因。

第二，raw 与 z-score 的相互作用是一个非平凡的观察：raw 特征的增益并非“浅层普遍更好”，而是 L11 特有的组合——raw L11 全场最低（150.43），但 raw L2 探针反而显著更差（198.78）；

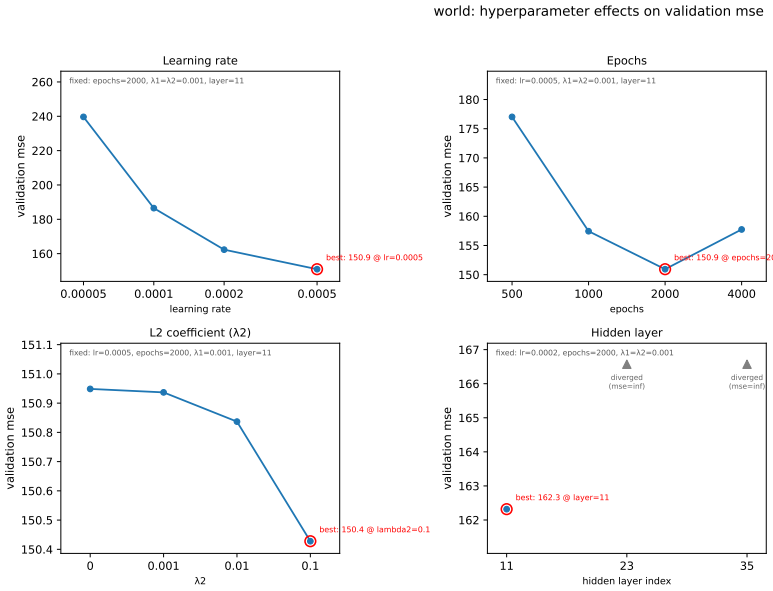


图 19: 首轮 world 超参数扫描（88653，未标准化特征）：lr 越大越好但上限被困在 5×10^{-4}（更大即发散）；layer 23/35 的“inf”由数值问题造成，而非“深层无信息”。

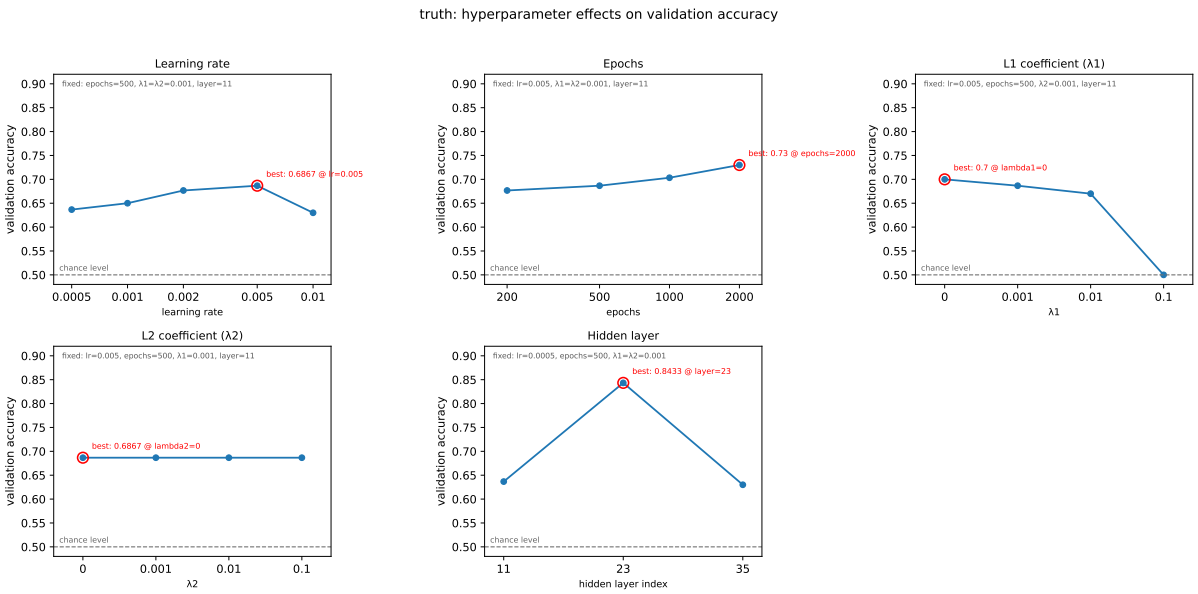


图 20: 首轮 truth 超参数扫描（88653）：lr、epochs、layer 的效应；λ_1 增大有害、λ_2 无差异。

z-score 的意义也不是“提点”，而是**解锁深层**——把按层稳定界拉平（1800 倍差距缩到 1.5 倍）让深层可训，同时 L2 的浅层优势本身也依赖标准化解锁（raw 198.8 → std 157.6）。

第三，一个只报告、暂不归因的现象：world 的曲线在深层**回升**——从 L20/L23 的低谷（≈ 241）回到 L32 的 180.3、与浅层统计不可区分（L11 vs L32：t= -0.46；而 L23 vs L32 的回升在配对意义上显著）；truth 则没有这个现象，L26 起单调下降（L32 的 0.8367 → L35 的 0.6867）。两任务在尾部层的表现分化，其机制（残差流叠加读出、语义抽象稀释等解释）都在本实验证据之外，我们只报告观察。

第四，把 Q6–Q8 的表征现象汇总：坐标信息以超越国家身份的形式存在——unseen 20 条上 improvement +1023.93 [513.94, 1654.14]（这些国家按表查询在原理上不可能）；同国内纬度弱可解码（$r = 0.201$）、经度近乎不可解码（$r = 0.046$），与 Q6 地图上“经度误差 $\gg$ 纬度”（MAE 10.85° vs 4.25°）相互印证，共同指向“气候带式”的粗粒度空间信息与有限的地名知识。噪声维度上，中深层表征对字符级扰动不敏感（typo 子集 acc 不低于 clean，浅层 L5–L11 才有 5–7pp 的差距）——与“表征是分布式语义编码”的直觉一致。

第五，一条 token 口径备注：world 探针读的是“国名最后一个词元”处的激活——写入位置即国家实体本身的状态；结果表明该状态同时编码了超越国名的坐标信息（否则 unseen 国家上不可能大幅胜过全局基线）。这也可能与 Q7 观察到的“国家中心收缩”有关：从国名词元状态读出的位置天然带有国家先验，探针只能部分解出个体地点的偏移。

D 数学原理：稳定界、闭式解与 KKT

world 用均方误差 $L = \|Xw + b\mathbf{1} - y\|^2/N$（与 `model.py` 一致），它是关于参数的凸二次函数，Hessian $H = 2X^\top X/N$。全批量梯度下降的误差传播为 $e_{t+1} = (I - \mathrm{lr}\, H)e_t$（$e$ 为参数误差），收敛当且仅当谱半径小于 1，即 $\mathrm{lr} < \dfrac{2}{\lambda_{\max}(H)} = \dfrac{N}{\|X\|_2^2}$——只依赖特征矩阵、与 y 无关，每层各有一个值（N 为该任务训练样本数）。越界后，误差沿最大特征方向每轮乘以 $|1 - \mathrm{lr}\,\lambda_{\max}| > 1$ 指数放大——这正是 world 未标准化时 loss 奔向 inf 的机制。

truth 用交叉熵，其 Hessian 为 $X^\top \mathrm{diag}(p(1-p))X/N \preceq X^\top X/(4N)$，最坏情形（$p = 1/2$）的充分稳定界放宽到约 $8N/\|X\|_2^2$（二次界的 8 倍）；更重要的是 logistic 的梯度有界（$p - y \in [-1, 1]$），没有 MSE“残差随 w 线性增长”的正反馈，越界一般表现为震荡/饱和、准确率下降，而不是爆炸——这是 truth 可以不标准化、直接用 raw 特征配 lr= 5×10^{-3} 的原因。

下表给出 13 层 × 两任务 × raw/z-score 的全部稳定界，两个读法。其一，**raw 界随深度暴跌**——world 从 L2 的 4.95×10^{-3} 降到 L35 的 2.77×10^{-6}，跨约 1800 倍；激活幅度逐层增大（残差流行范数从 51 到 623，约 12 倍，平方进入 $\|X\|_2^2$ 就是两个数量级），固定 lr 必然在深层越界。其二，**z-score 把界“拉平”**到 3.1–4.8×10^{-3}（仅 1.5 倍差距）——z-score 只归一化每列尺度，剩下的差异来自特征间的相关结构；正因为拉平了，同一个 lr 才能对所有层公平。truth 的 raw 界同样随深度收缩，但如上所述 logistic 对越界是“软”的，其配置不依赖这把尺子。

理论与实测逐条吻合：raw L11 界 5.4×10^{-4}——lr= 5×10^{-4} 稳定（贴线，MSE 150.9），10^{-3} 直接溢出；raw L23 界 8.4×10^{-5}——实测 2×10^{-4}（超 2.4 倍）收敛前爆炸；raw L35 界 2.8×10^{-6}——实测超 72 倍、71 轮即炸；std L11 界 3.6×10^{-3}——lr= 3×10^{-3}（0.83 倍）得 167.06、5×10^{-3}（1.39 倍）发散；std L35 界 4.8×10^{-3}——lr= 4×10^{-3}（0.84 倍）冒烟 300 轮稳定、8×10^{-3}（1.68 倍）第 9 轮爆炸。反向一例：truth raw L35 用 lr= 5×10^{-4} 已超二次界约 300 倍，训练仍然有限（acc 63.0%）——logistic 的非爆炸性由此得到实证。

Q1/Q2 的实现用到两条精确算法。其一，Ridge 的 SVD 闭式解：$X = U\Sigma V^\top$ 时

层	world raw	world z-score	truth raw	truth z-score
2	4.95×10^{-3}	4.07×10^{-3}	6.51×10^{-3}	2.67×10^{-3}
5	1.14×10^{-3}	$\mathbf{3.08 \times 10^{-3}}$	1.14×10^{-3}	4.85×10^{-3}
8	6.90×10^{-4}	3.15×10^{-3}	1.09×10^{-3}	9.20×10^{-3}
11	5.45×10^{-4}	3.59×10^{-3}	7.37×10^{-4}	9.74×10^{-3}
14	4.47×10^{-4}	3.40×10^{-3}	6.10×10^{-4}	1.05×10^{-2}
17	3.19×10^{-4}	3.48×10^{-3}	5.01×10^{-4}	1.03×10^{-2}
20	1.93×10^{-4}	3.42×10^{-3}	3.04×10^{-4}	7.00×10^{-3}
23	8.37×10^{-5}	3.16×10^{-3}	1.33×10^{-4}	5.38×10^{-3}
26	3.94×10^{-5}	3.16×10^{-3}	4.08×10^{-5}	4.72×10^{-3}
29	1.89×10^{-5}	3.46×10^{-3}	1.63×10^{-5}	5.42×10^{-3}
32	7.48×10^{-6}	3.92×10^{-3}	6.17×10^{-6}	6.70×10^{-3}
34	3.02×10^{-6}	4.40×10^{-3}	2.93×10^{-6}	7.25×10^{-3}
35	2.77×10^{-6}	$\mathbf{4.77 \times 10^{-3}}$	1.68×10^{-6}	5.84×10^{-3}

表 5: 13 层稳定界 $N/\|X\|_2^2$ 全表（SVD 精确值；raw 界随深度跨 1800×，z-score 后压至 1.5×）。

$\hat{w} = V\,\mathrm{diag}\big(\sigma_i/(\sigma_i^2+\lambda)\big)\,U^\top y$，$\lambda = 0$ 退化为伪逆的最小范数最小二乘解；系数路径即由它精确计算（与 sklearn 对拍 10^{-9}）。其二，Lasso 的 KKT/软阈值：驻点条件 $\partial L/\partial w_j = \frac{2}{N}[X^\top(Xw-y)]_j + \lambda_1\,\mathrm{sgn}(w_j) + 2\lambda_2 w_j = 0$ 由坐标下降 + warm start 求解；精确零来自优化几何本身、零集沿 λ 嵌套——这正是 Q2 中“阈值化 ridge 无法复现 lasso 零集”对照的数学背景。逻辑回归的梯度（`model.py` 实现）为 $\nabla_w L = \frac{1}{N}X^\top(\hat{y}-y) + \lambda_1\,\mathrm{sgn}(w) + 2\lambda_2 w$；数值上用 $\log(1+e^{-z}) = \mathrm{logaddexp}(0,-z)$ 稳定计算。sklearn 换算表（Q3 对拍用）：Ridge $\alpha = N\lambda_2$；Lasso $\alpha = \lambda_1/2$；ElasticNet $\alpha\rho = \lambda_1/2$、$\alpha(1-\rho) = \lambda_2$；Logistic $C = 1/(2N\lambda_2)$——注意 sklearn 的正则量纲是“平方误差总和”口径，直接对比会差一个 N 倍。最后是基线口径：train 均值基线的元素平均口径 MSE = 3311.27（与模型指标同口径），坐标求和口径 = 6622.54；两者混用会把 R^2 抬高约 2.3pp。统一口径后，world 最佳 $R^2 = 0.9546$（RMSE $\approx 12.3°$）。

E 复现清单与文件结构

本报告的仓库结构与产物分布如下。根目录的 `model.py` 是提交的手写模型（线性/逻辑回归，全批量梯度下降）；`datasets/` 存放两任务各 13 层的特征数组与标签 csv；`experiments/` 是训练与分析的执行器与配置（`train_layers.py`、`run_grid.py`、`plot_layers.py`、`stability_bound.py` 及配置 json）；`scripts/` 是集群 sbatch 与分块提交脚本；`question/code` 是思考题 Q1–Q8 的复现脚本；`results/` 汇总全部扫描/分层训练/提取的结果与图；`report/` 为本报告源文件。

环境方面，本地与集群统一使用 ai26 环境（numpy / sklearn / matplotlib / cartopy / pyspellchecker）；集群跑在 Students 分区，且必须钉 A100（`--gres=gpu:A100:1`）——RTX5090 节点与当前 torch 驱动不兼容，需避开。关键复现命令：训练 13 层 `python experiments/train_layers.py --skip-existing`；稳定界全表 `python experiments/stability_bound.py`；Q1 系数路径 `python question/code/q1_coefficient_paths.py`；Q6 地图 `python question/code/q6_valid_map.py`；其余思考题脚本同构（入口在 `question/code` 下）。

提交产物（首选/备选）：world——raw L11 探针（`results/slurm_layers/world/weights/world_layer11_extra0/weights.npz`，MSE 150.43），备选 z-score L2（157.57）；truth——raw L20（`results/slurm_layers/truth_b/weights/truth_layer20/weights.npz`，acc 0.8967），备

选 L23（0.8900）。所有权重均已折回原始特征空间，推理时不需再做标准化。

追溯与归档:KC 房价数据（Q1/Q2）与 OpenML 全表的逐格对拍记录在 `question/execution_log.md` §1.2;truth 数据集的来源指纹见第 8 题;每轮集群运行的全部日志按时间戳归档在 `results/slurm_*` 对应目录下。

F 实验反馈与建议

全程做下来，我们对课程设计有几点想反馈。数据集构造不公布反而促成了本报告中最有意思的一段工作——Q8 的“反推/对拍”（用统计指纹识别出 valid 是构造性 OOD 挑战集）。我们建议在指南中明确鼓励这类来源调查：它把“调参竞赛”变成了真正的研究过程。报告要求“思考题回答为主、背景进附录、不设长度限制”的设定也很好，让扫描、稳定性分析等附加内容可以放进附录而不挤压正文；提示中“推荐 AI 工具辅助可视化”明确而友好，建议再补充一句“AI 辅助内容需能讲清原理”（验收提示已有类似要求）。

算力平台方面有两个具体的坑与建议。其一，Students 分区混部 RTX5090 与 A100，当前 torch 与 RTX5090 驱动不兼容（CUDA error 804），曾让整批特征提取全部 FAIL；建议在附录 B 的教程里明确写“钉 A100”。其二，4h 作业时限对“13 层 × 5000 轮”级别的实验需要分块 + 断点续跑设计——这本身是一次很好的工程训练（我们靠它吸收了慢节点 15 倍的抖动），但建议指南给出各量级实验的时间预算参考，避免每个小组都从超时失败学起。