FAIML Lab1 实验报告

常志强
PB25030753

2026 年 10 月 21 日

1 思考题

1. 复现 ℓ_1 / ℓ_2 系数路径与数据来源

题面：重现课件（第 42、48 页）中 ℓ_1、ℓ_2 正则化的“系数路径”，并解释数据来源。

（1）数据来源。课件 p42/p49 的 8 个特征列（bedrooms、bathrooms、sqft_living、sqft_lot、floors、yr_built、yr_renovated、waterfront）与 Kaggle 数据集 House Sales in King County, USA（`https://www.kaggle.com/datasets/harlfoxem/housesalesprediction`，CC0 许可）的列名完全一致，由此判定课件图的数据来源即该数据集。本实验下载自该数据集的 GitHub 镜像（`https://raw.githubusercontent.com/Willie-Conway/House-Sales-Price-Prediction-King-County-USA-Project/main/House-Sales-Price-Prediction/housing.csv`）。

（2）数据处理（根据讲义）。课件 p20 批注“all features normalized so coeff. on same scale”，于是笔者对 8 个特征做了标准化，使各特征系数处于同一尺度。同时剔除数据集中含缺失的 16 行（21613 → 21597，占 0.07%）。λ 取 0 至 2×10^5 共 201 个等距点，与课件一致。

（3）复现结果与简单分析。$\lambda = 0$ 处的最小二乘解（单位：美元/σ）为 sqft_living 268 160、waterfront 63 307、bathrooms 49 137、floors 28 399、yr_renovated 3 397、sqft_lot −12 378、bedrooms −56 868、yr_built −92 382，与课件量级一致。ℓ_2（Ridge）路径**只缩不归零**，其中 bedrooms 与 bathrooms 在 $\lambda \lesssim 2 \times 10^4$ 先升后降。ℓ_1（Lasso）路径随 λ 增大**精确归零**，归零顺序为 sqft_lot (9k) → yr_renovated (13k) → bedrooms (21k) → floors (23k) → bathrooms (26k) → yr_built (45k) → waterfront (79k)，至 $\lambda = 2 \times 10^5$ 只剩 sqft_living（57.7k）。综上，两条路径的趋势与量级均与课件一致（如图 1 所示）。

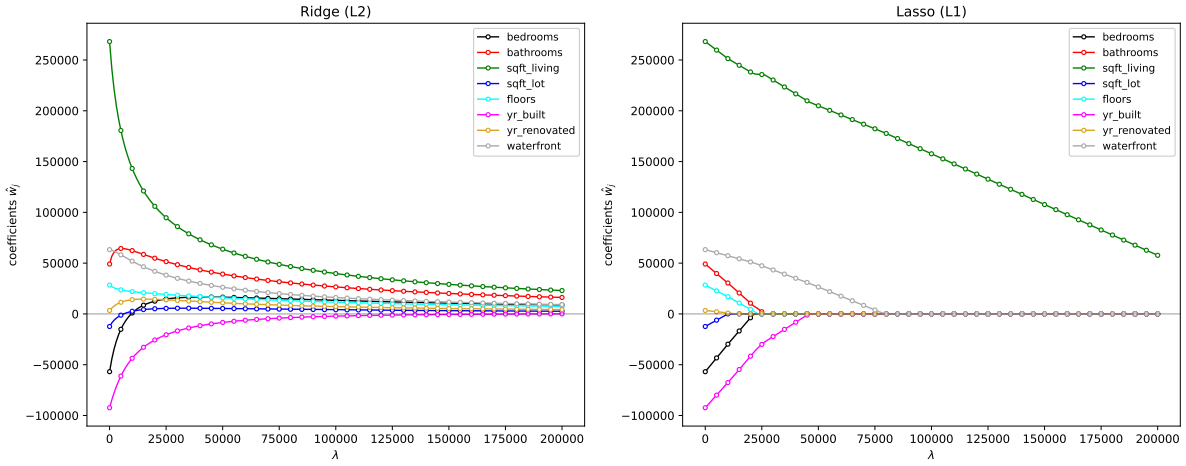


图 1: King County 8 特征的系数路径（左：Ridge；右：Lasso）。

2. 用案例说明 ℓ_2 阈值化做特征选择为什么不好

题面：请用案例说明 ℓ_2 正则化在回归中将很小的系数设为 0 进行特征选择是不好的（相比 ℓ_1 正则化，课件第 44 页）。

（1）案例设置。在 Q1 的 8 列基础上加入 sqft_above 构成 9 特征（它与 sqft_living 的相关 $r = 0.876$，是最强共线对，两者形成强共线性对），对数据进行标准化后，考察“$|w_j| < \tau$ 视为 0”的阈值化特征选择。

（2）阈值化 Ridge 的三个问题。第一，选择结果高度依赖阈值与路径：同一 Ridge 拟合（$\lambda = 2 \times 10^4$）下，$\tau = 10^4 \to 2 \times 10^4 \to 5 \times 10^4 \to 10^5$ 对应选中 $7 \to 5 \to 2 \to 0$ 个特征，$\tau = 10^5$ 时连 sqft_living 都被删空；固定 $\tau = 10^4$ 沿 λ 扫描，保留集跳变 11 次、含 3 次“回升”（如图 2、图 5 所示）。相比之下，Lasso 的零模式沿 λ 特征数逐渐减少。第二，笔者构造出的共线组被“平摊”后整组删除：预测依赖共线组内两个系数之和，多个系数可能都较小但总体权重较高。例如对于构造的共线组，在 $\tau = 10^5$ 下单特征模型保留、9 特征模型两个成员双双被删（如图 3 所示）。为了表现极端情况，笔者用了合成数据（其中两个特征 $x_2 \equiv x_1$）把机制推到极限：Ridge 精确对半，会被删掉整组，而 Lasso 保留一个代表 $(237\,689, 0)$。

（3）原因分析。阈值化把“收缩量”误当“重要性”：Ridge 的 $\hat{w}(\lambda)$ 恒非零且连续收缩，大 λ 下全体都小，但系数小并不代表不重要；共线时 $|w_j|$ 更不是重要性度量，共线的特征过多就能把每个系数压到阈值之下；τ 还是人为引入的第二个超参数，没有目标函数可供优化，选择集随 τ、λ 与数据扰动跳变。相反，ℓ_1 的零来自 KKT 条件与软阈值，特征数沿 λ 单调递减、仅由单一超参数控制，对共线组保留一个代表（如图 4 所示）。综上，ℓ_2 阈值化做特征选择是不好的，ℓ_1 才是合理的。

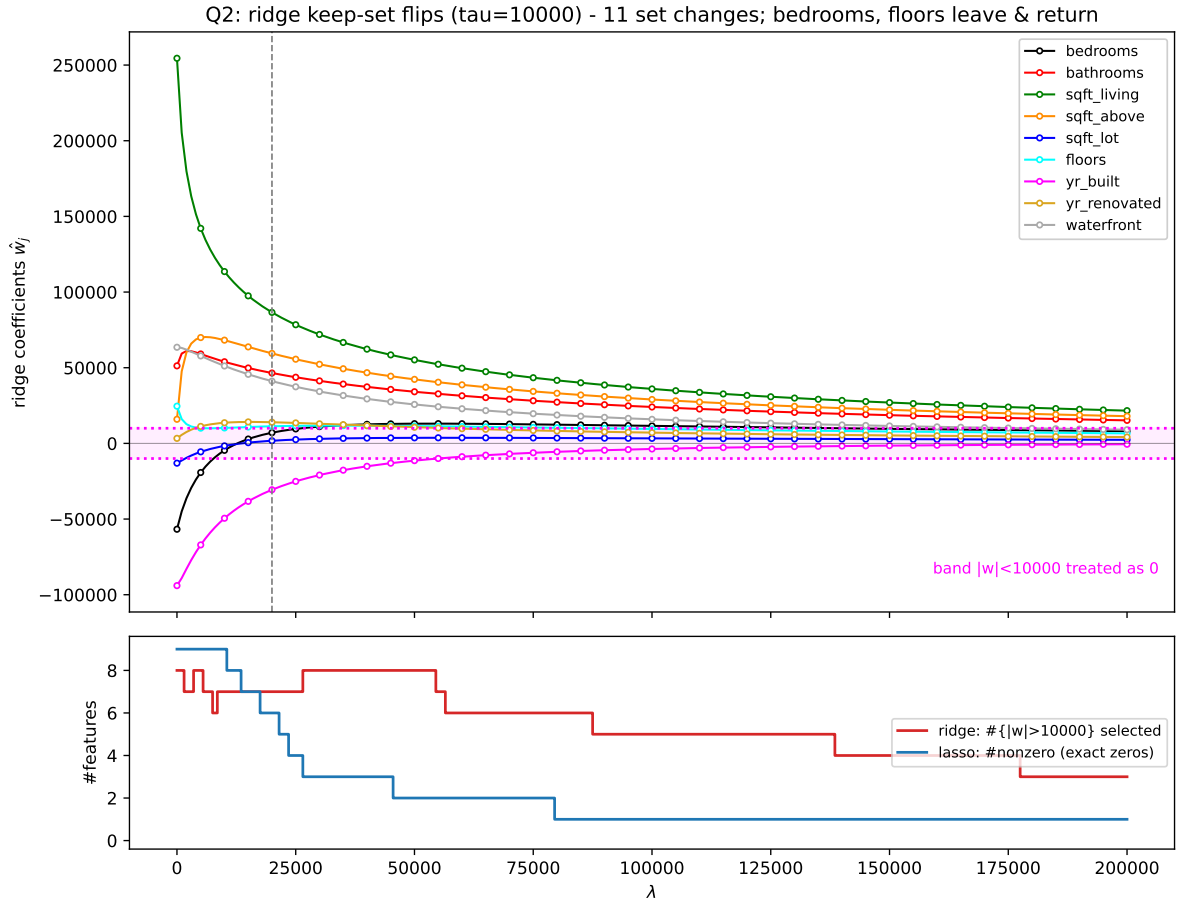


图 2: 阈值化 ridge 与 lasso 的保留特征数随 λ 的变化。

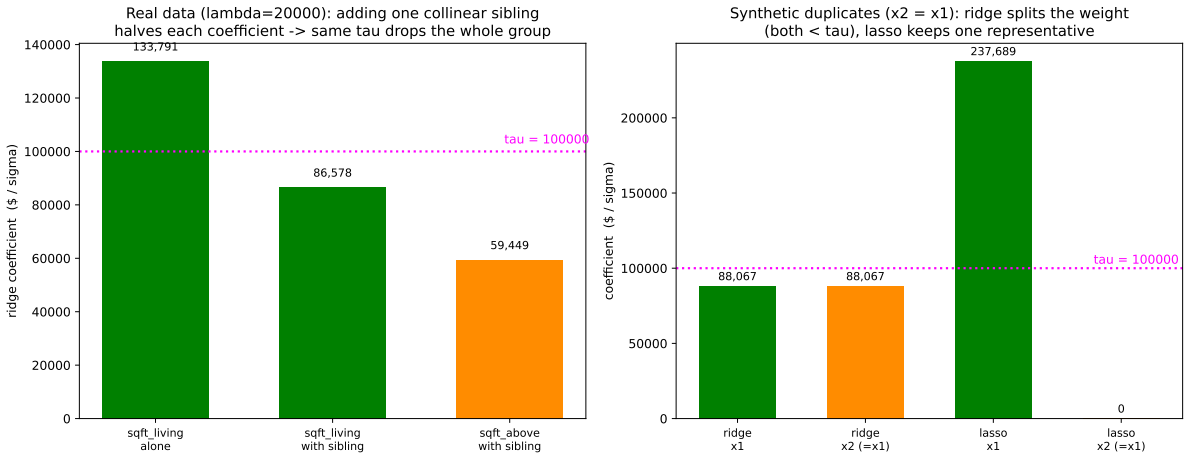


图 3: 共线案例：阈值化 ridge 整组删除，lasso 保留一个代表。

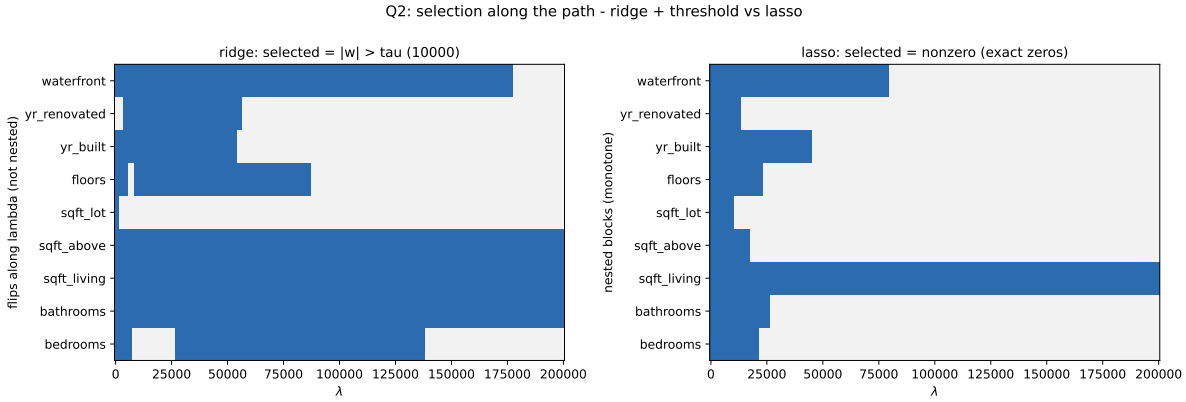


图 4: 两种方法的选择集结构：ridge 不嵌套，lasso 嵌套。

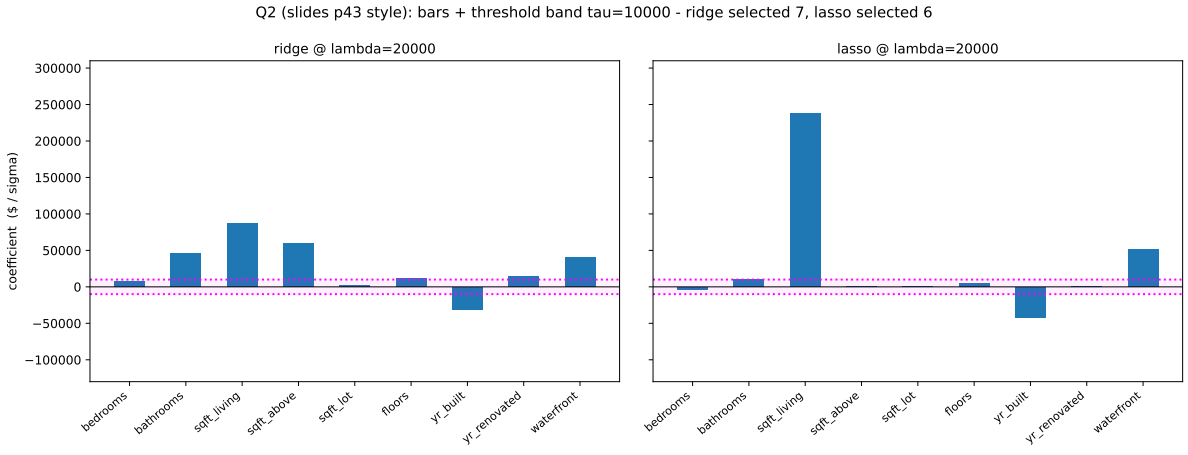


图 5: $\lambda = 2 \times 10^4$ 截面的保留集与 τ 扫描对比。

3. 与 sklearn 实现有拟合效果差异吗

题面：你的模型相比于 sklearn 的实现有拟合效果上的差异吗？（简要说明即可）（提示：可以在做完后两项实验后回答该题。）

（1）先把正则对齐。两边 λ 的定义不同，先换算：ours 的目标是 $(1/N)\cdot\text{loss}+\lambda_1\|w\|_1+\lambda_2\|w\|_2^2$；对应 sklearn 的 Ridge $\alpha = N\lambda_2$、Lasso $\alpha = \lambda_1/2$、ElasticNet $\alpha\rho = \lambda_1/2$ 且 $\alpha(1-\rho) = \lambda_2$、逻辑回归 $C = 1/(2N\lambda_2)$。不换算就会把“超参不同”当成“实现不同”。

（2）结论：没有本质差异，差异在于优化上。目标函数一样、都收敛后，两边就是同一个解：例如 world z-score 的 Ridge 对比 cos = 1.00000、relL2 = 0.002。差别都出在优化上：手写模型的学习率受稳定界限制，需要自行调整；sklearn 用精确求解器；手写的模型轮数有限相当于提前停住，继续训练会向 sklearn 靠拢（见表 1、图 6）。例如 truth 无正则时 sklearn 的 valid 对数损失为 27.77（ours 0.255），world 无正则时 sklearn 为精确解、ours 为有限轮早停。

设置（ours 口径）	ours valid	sklearn valid	cos
world（*L11*，*MSE*，小者好）			
z-score，$\lambda_2 = 1.0$	167.06	167.17	1.00000
raw，无正则，ep20000	223.58	395.02	0.871
raw，历史最优，ep2000	150.43	165.34	0.897
truth（*L20*，准确率，大者好）			
无正则，ep4000	0.8867	0.8533	0.772
$\lambda_1 = \lambda_2 = 10^{-3}$，ep5000	0.8967	0.8600	0.712

表 1: ours 与 sklearn 的代表性对比。

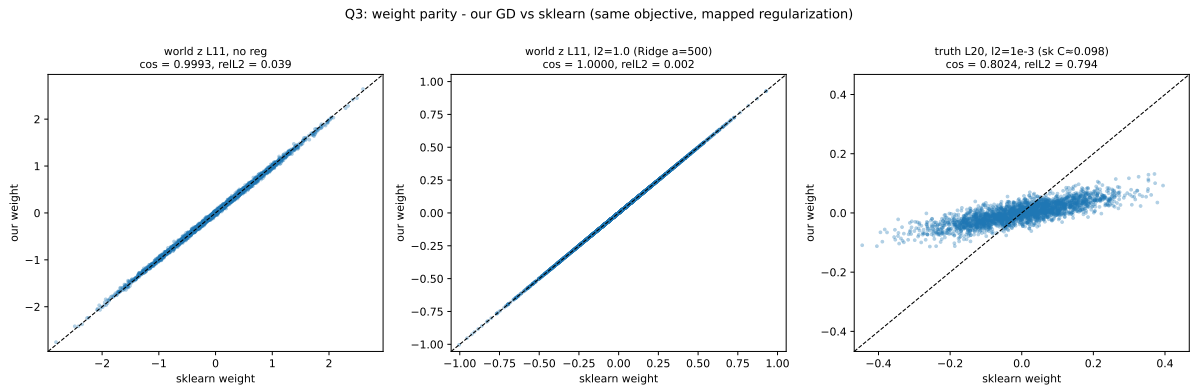


图 6: 对齐正则口径后的权重逐点比对。

4. world：不同层中间表征的预测效果对比与选层

题面：对比不同层中间表征的预测效果，并分析原因；你在最终模型提交中是如何选择特征选取层次的？

（1）实验设置。实验提供了 11，23，35 共 3 层，笔者以 3 为间隔提取了另外十层，共计 13 层（$2, 5, \ldots, 35$）。由于实测时发现不同层按照统一的超参数会出现 loss inf 现象，所以对数据做了标准化，最后再把权重折算回去。采用了同一套配置做对照：lr= 0.002、2000 轮、$\lambda_2 = 1.0$、$\lambda_1 = 10^{-3}$。

（2）结果分析。曲线呈 **倒 U 形**：浅层 L2–L11 差异不显著，中层 L14–L29 明显更差（L17/L20/L23 显著），深层 MSE 先降后升（如图 7、表 2 所示）。std 中最低为 L2（157.57），但与 L5/L8/L11

差异不显著；全场最低为 raw L11（150.43）——world 水平锁定在 150–167（$R^2 \approx 0.955$），继续调参并未发现显著收益。

（3）原因分析。world 的目标是位置坐标，这类信息在浅层表征中最接近线性可分；随层深增加，表征经过更多非线性变换、语义抽象增强，坐标的线性可读性下降，中层出现低谷。深层在 L29–L32 段 MSE 下降（L32 为局部最低 180.31），随后 L34/L35 又回升；下降的可能原因是深层把位置重新编码为更全局的线性方向。

（4）最终选层。提交选中 **L11**，有三个原因：一是 L11 与 L2/L5/L8 差异并不显著（见表 2），L2 虽然略微好一点但是与 L11 差异不大；二是 L11 是实验本身提供的，与实验本身关联性更好；三是标准化一定程度上影响了 2，5，8，11 四层之间细微的差距，例如笔者对 L2 和 L11 在不进行标准化、统一超参数做了训练，发现 L11 略微优于 L2。综上所述，笔者选择 11 层作为最终选层。

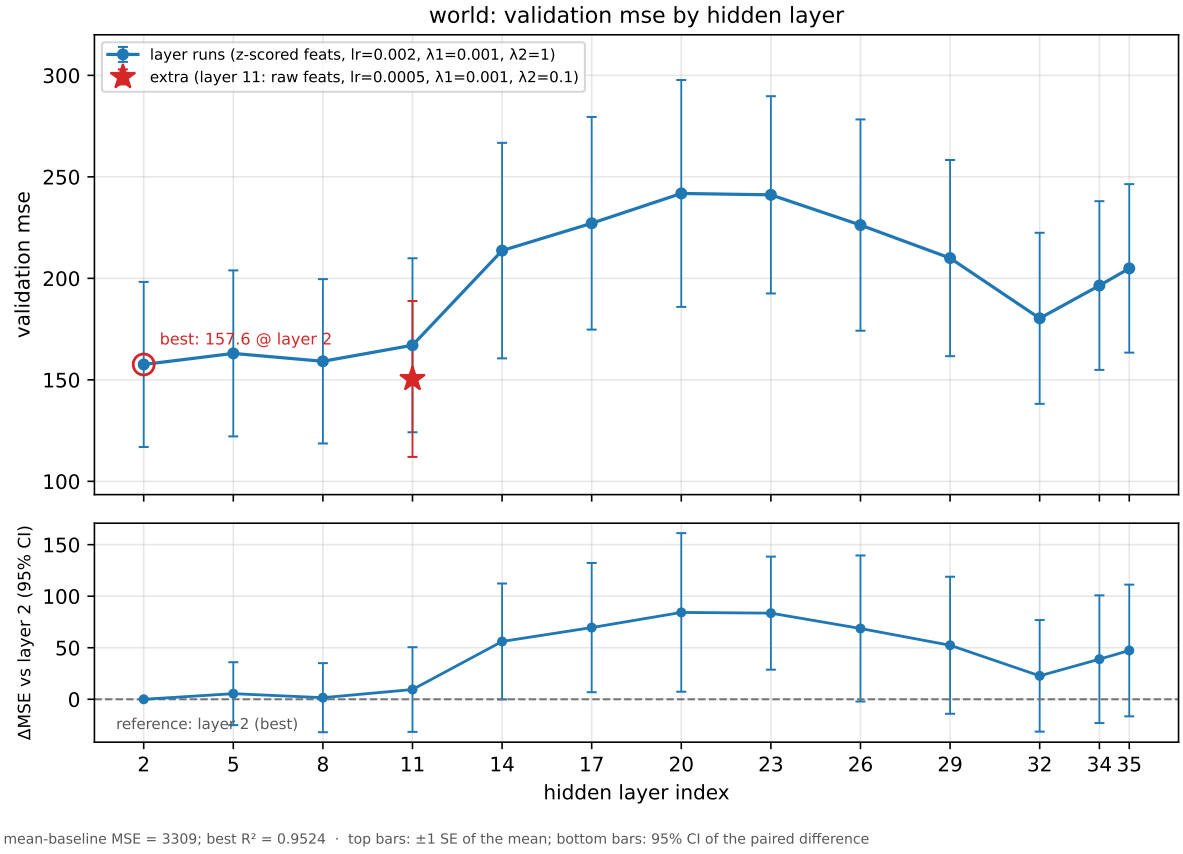


图 7: world 各层验证 MSE 与配对差。

层	配置	MSE	±SE	Δ vs L2（95% CI）	判定
2	std	**157.57**	40.7	参考	最优
5	std	163.02	40.9	$+5.4 \pm 30.5$	不显著
8	std	159.14	40.5	$+1.6 \pm 33.5$	不显著
11	std	167.04	42.9	$+9.5 \pm 41.1$	不显著
14	std	213.67	53.1	$+56.1 \pm 56.2$	边缘
17	std	227.13	52.4	$+69.6 \pm 62.7$	显著
20	std	241.83	55.9	$+84.3 \pm 76.9$	显著
23	std	241.14	48.6	$+83.6 \pm 54.8$	显著
26	std	226.25	52.0	$+68.7 \pm 70.8$	边缘
29	std	209.99	48.3	$+52.4 \pm 66.5$	不显著
32	std	180.31	42.1	$+22.7 \pm 54.1$	不显著
34	std	196.46	41.6	$+38.9 \pm 61.9$	不显著
35	std	204.91	41.5	$+47.3 \pm 63.9$	不显著
11	raw（extra）	**150.43**	38.4	—	全场最低

表 2: world 13 层验证 MSE（含 raw extra）。

5. world：正则化与学习率的选择

题面：你在最终模型提交中是怎么选择正则化的？请说明理由；

（1）为什么正则化？world 是 $N = 500$、$D = 2560$，样本远少于维度，本身是一个欠定问题，必须正则化。默认的对照设置为 lr=0.003, epochs=2000, $\lambda_1 = 0.001$，$\lambda_2 = 1$, layer=11。

（2）正则扫描。固定其他，扫 λ_2：0.1 时训练残差已经很小（≈ 3），但 valid MSE 209，明显过拟合；1.0 最好（167.06）；3.0 正则强度过高，MSE 回升到 184.57。把 λ_1 从 0 扫到 0.1，valid MSE 只从 167.07 降到 165.82，差异不显著，所以后续沿用 10^{-3}（如图 8 所示）。

（3）学习率扫描。学习率的稳定界约为 5.4×10^{-4}，高于这个值都会出现 loss inf 。取 lr= 5×10^{-5}，1×10^{-4}、2×10^{-4}、5×10^{-4}。结果来看 lr= 5×10^{-4} 最好（更大的学习率已越界发散），故选择 lr= 5×10^{-4}。

（4）最终提交。最终模型的提交是 **raw L11**，超参数为 lr= 5×10^{-4}、2000 轮、$\lambda_2 = 0.1$，valid MSE **150.43**。选择理由见上面的分析。

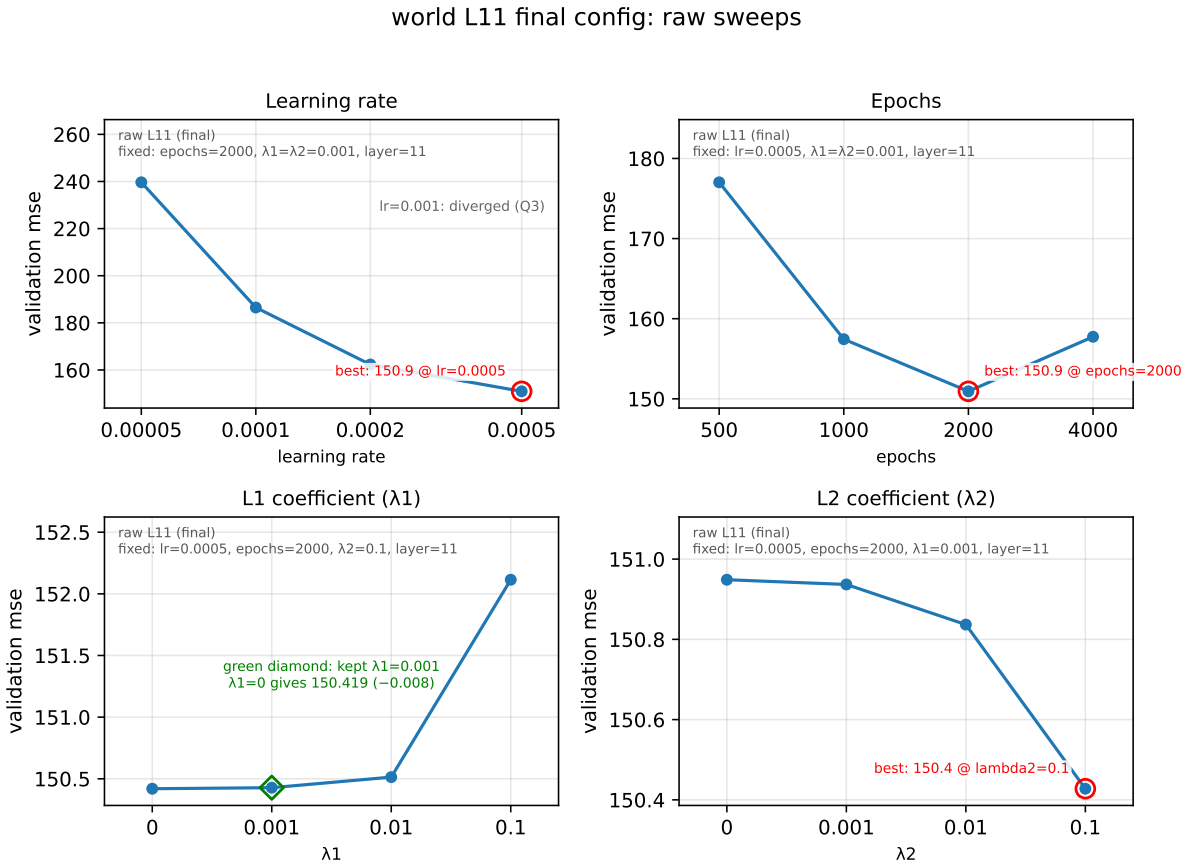


图 8: world L11 的 raw 单变量扫描。

6. 验证集预测的地图可视化

题面：给出你的模型在验证集上的预测结果，并可视化在地图上（推荐不含国界线）。（提示：此题推荐使用 AI 工具辅助可视化程序的编写。）

（1）绘图数据来源。图和读数都基于最终提交的 world raw L11 权重。

（2）地图读数。130 个验证样本（78 国）画在世界地图上：灰空心圆是真值，彩点是预测，颜色表示单点误差 $\sqrt{\Delta lat^2 + \Delta lon^2}$（如图 9 所示）。

（3）数据分析。模型大致学到的是“大洲级”定位：平均误差 12.44°、中位 9.52°（大圆距离约 953.8 km），四分位 4.96/9.52/15.34°，误差超过 30° 的只有 7/130。

（4）误差分析。误差呈现出两个特点。第一，方向不对称：纬度平均只差 4.25°，经度差 10.85°，约 2.5 倍。第二，见过的地方准、偏僻的地方差：欧洲、东非、中美等训练密集区误差普遍小于 5°（最准 Denmark 0.79°）；失败集中高纬和孤立岛屿——两条南极样本排在最差前二（89.6°、73.8°，预测落到约 28–34°E 的南大洋），纽芬兰样本纬度几乎全对（差 0.23°），经度却差了 40.7°。图上只画 110m 海岸线，**不含任何国界线**。

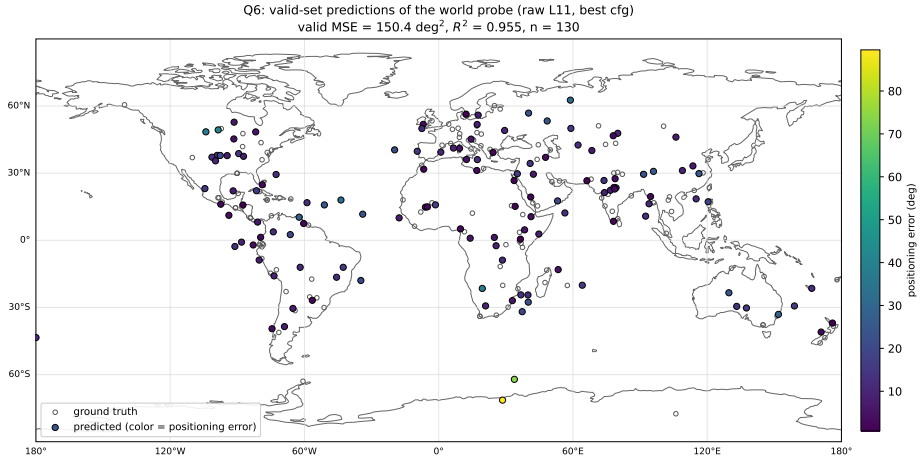


图 9: world valid 130 条预测位置（仅海岸线，无国界线）。

7. 是地理坐标表征，还是仅仅识别了国家？

题面：从训练集和验证集的表现，是否能够强烈说明模型内部存在地理坐标的表征，而不是仅仅识别了输入中的国家？对于该题可以参考原始论文 [3] 的部分结论和上一题的可视化结果；也可与按训练集国家分组的平均坐标基线比较，考察同一国家内不同地点的预测。

（1）判据与基线。如果模型只是认出了国家，那么把“该国平均坐标”直接告诉它，效果应不差于模型。所以基线用 **oracle 国家均值**：按真实国家标签查训练集里该国坐标的均值，如果是未见的国家则取全局均值；实验同时进行了分类，all 130 / seen 110 / unseen 20 / multi 73 / single 37 ，结果中的 improvement = 基线 − 模型。

（2）实验结果。第一点，unseen 的 20 条在训练中完全没出现，模型 MSE 158.90，全局均值基线 1182.83，improvement +**1023.93**，如果是只是国家查表是不可能有这样的提升的，这说明“模型远不止一个全局平均”，但不能说明“模型精确”。第二点，在 seen 组，oracle 反超模型，seen 110 条上模型 148.89 vs 基线 **113.77**（imp −35.12），multi 与 single 上都不如 oracle（如图 10 所示）。

（3）结论：有一点表征但不多。由 2 的结果可见，模型确实带了超出国家身份的位置信息，但精细定位能力有限，例如 unseen 的预测整体落对区域（比如说欧洲 → 欧洲、中美洲 → 中美洲），但细节上并不精准（如图 11 所示）。笔者认为，原因主要还是因为数据量不足，问题本身欠定，导致地理表征存在但是比较弱。

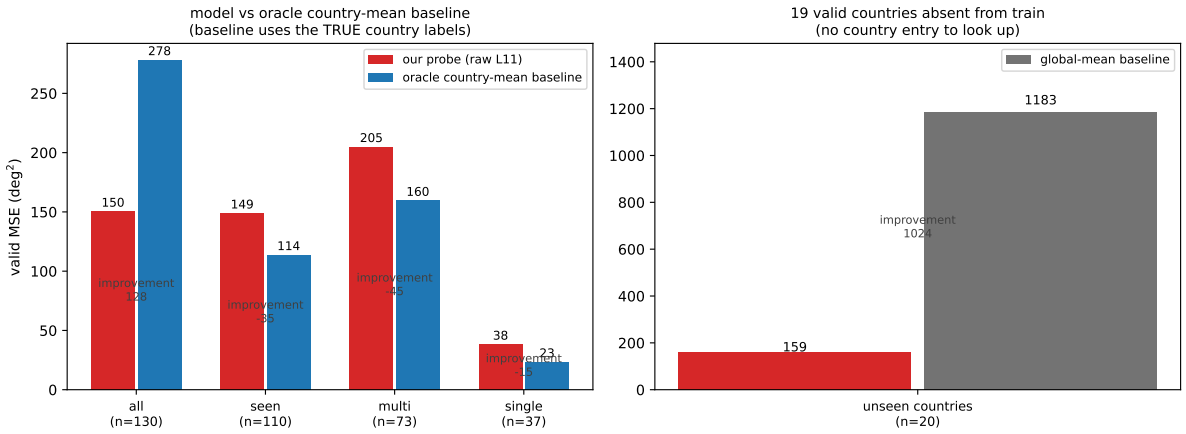


图 10: 模型与国家均值基线的分层 MSE。

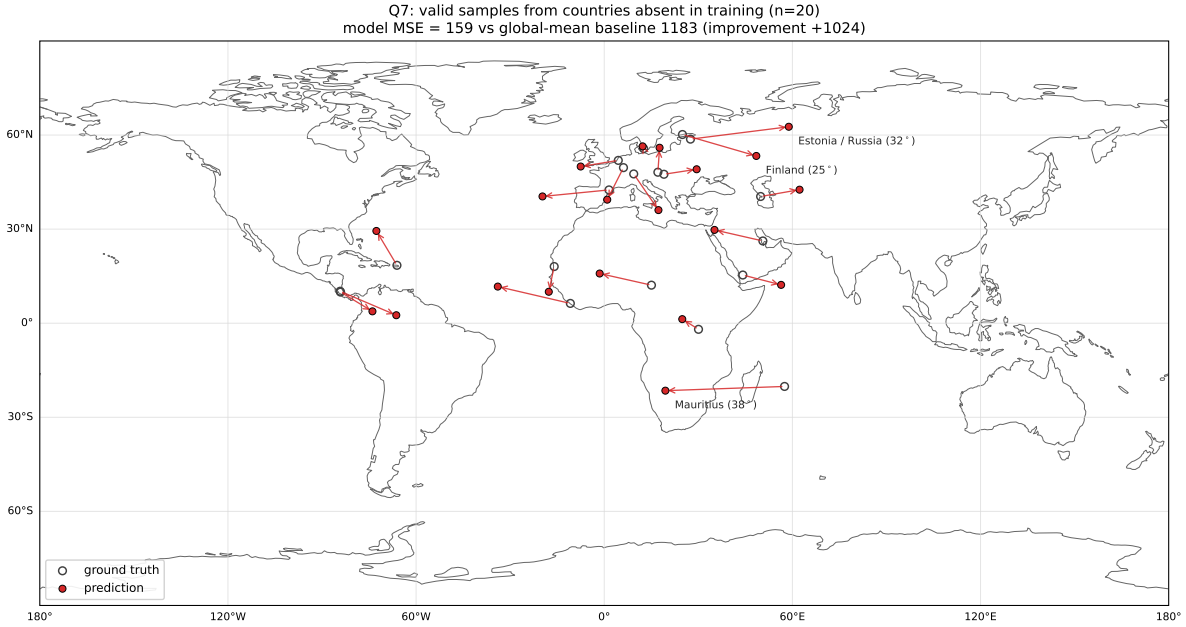


图 11: 19 个未见国家的预测位置（仅海岸线，无国界线）。

8. truth：训练集/验证集的分布差异与应对

题面：仔细阅读训练集和验证集，模型的训练集和验证集存在哪些分布上的差异？你是如何应对的？

（1）分布差异。主要有三点。① **拼写噪声：**train 有 7.0%（354/5088）的句子带相邻字母交换型错拼（mkaes→makes 这种），valid 有 24.7%（74/300），约为 train 的 3.5 倍，但在两类标签内都均衡。② **未出现的实体：**valid 的 212 条可识别首实体中，164 条（**77.4%**）在 train 里没出现过；

③ **模板/长度**：train 特有的“One can” / “If one” 句式约 3.0%，valid 只剩 0.7%；valid 的长句被截断（最长 162 vs 487 字符）（如图 12 所示）。

（2）对模型的影响。笔者对相关分布带来的影响进行了研究，将验证集的结果按照 typo/clean, seen/unseen 划分。L20 总体准确率为 0.8967。带错拼的子集 0.932，反而比干净子集 0.885 好（如图 13 所示）；主体 seen 0.917 对 unseen 0.884，未见过的实体分数没有下降。在不同层上看，错拼只在浅层造成伤害，说明文本噪声在中深层被平滑吸收了。

（3）应对。第一，文本不清洗：模型直接从原始文本（含错拼）学习，从结果上来看这些噪声对模型有益处；第二，同分布对照：笔者做了一个测试，在 train 内做 3 折 CV（L20），按照随机划分准确率 0.869，按实体分组 0.877，差 0.8 个百分点，在折间波动范围内，差异不显著，说明模型不靠“记住实体”来保证准确率。综合以上实验，笔者认为无需对训练集做额外处理，模型训练也可以达到比较不错的效果，笔者所提交的 truth 权重也是基于未做处理的原始 train 进行训练。

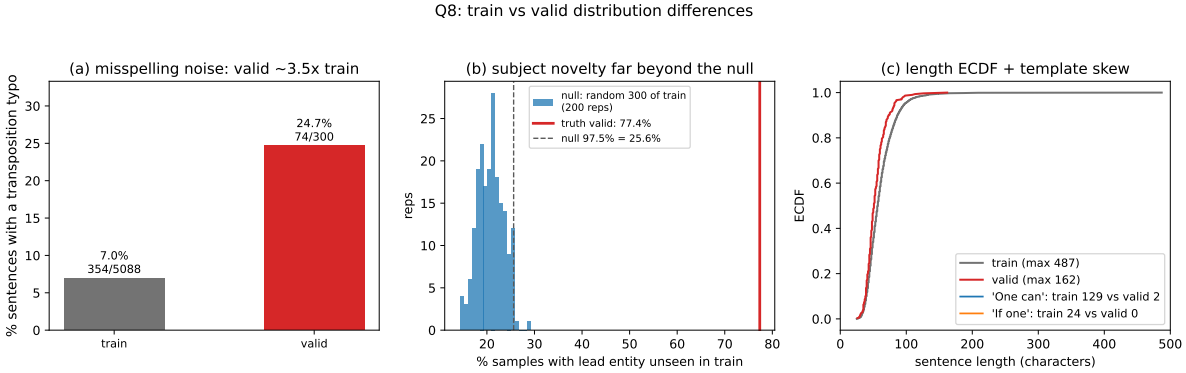


图 12: train/valid 的分布差异。

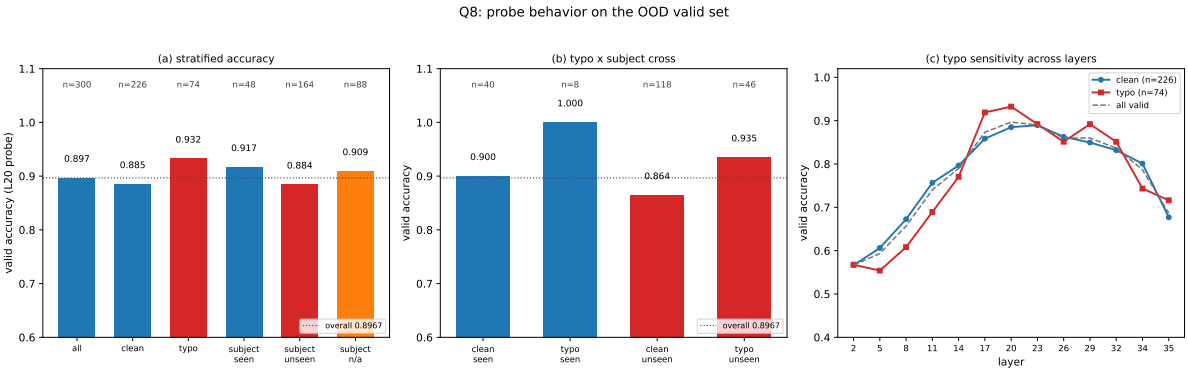


图 13: L20 探针的分层准确率。

9. truth：选层与正则化的理由

题面：你在最终模型提交中是怎么选择特征选取层次和正则化的？请说明理由。

（1）实验设置。和 world 一样扫 13 层，统一配置：lr= 5×10^{-3}、5000 轮、$\lambda_1 = \lambda_2 = 10^{-3}$，truth 用原始特征，得到完整曲线。

（2）结果分析。truth 的曲线是清晰的**倒 U 形**：中间高、两边低。选 L20，因为它最高，而且峰位居中、两侧比较对称。解释：真假判断靠语义级信息，这些信息在 L17–L23 对线性探针最可

读；浅层还是词法和局部特征，深层经过非线性重整后线索被稀释。这和 world 的最优层正好相反，说明不同深度装的是不同类型的信息（如图 14、表 3 所示）。

（3）正则化。结果显示 λ_1 有害：$0 \to 70.0\%$、$10^{-3} \to 68.7\%$、$10^{-2} \to 67.0\%$、$0.1 \to \mathbf{50.0}\%$（直接掉到随机）。原因是表征稠密，ℓ_1 把大量分量压成 0，反而对准确率有害；λ_2 则对准确率几乎无影响（四个取值都是 68.7%）。所以最终取 $\lambda_1 = \lambda_2 = 10^{-3}$，采用很弱的正则化（如图 15 所示）。

（4）最终提交。raw L20，lr$= 5 \times 10^{-3}$，5000 轮，$\lambda_1 = \lambda_2 = 10^{-3}$，valid acc **0.8967**。

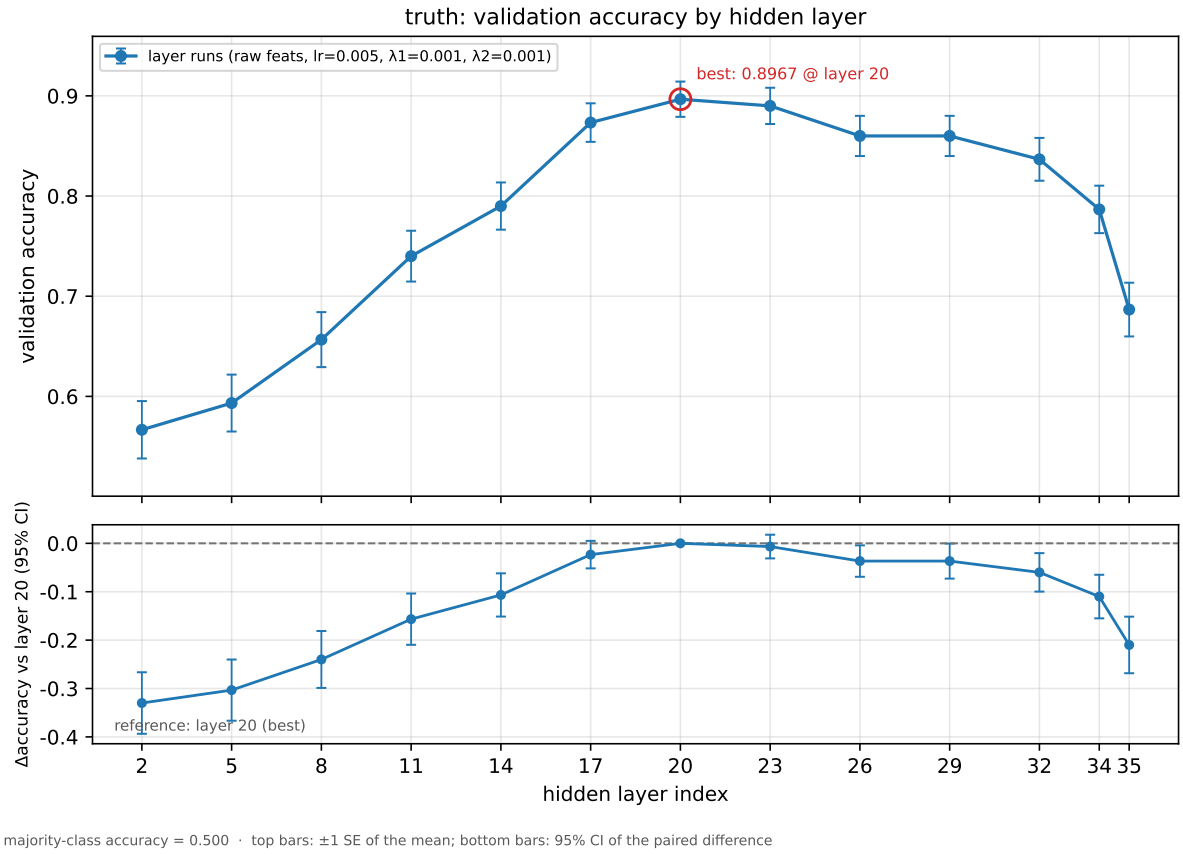


图 14: truth 各层验证准确率与配对差。

层	acc	±SE	Δ vs L20（95% CI）/判定
2	0.5667	0.0287	−33.00pp ± 6.36pp 显著
5	0.5933	0.0284	−30.33pp ± 6.32pp 显著
8	0.6567	0.0275	−24.00pp ± 5.88pp 显著
11	0.7400	0.0254	−15.67pp ± 5.30pp 显著
14	0.7900	0.0236	−10.67pp ± 4.47pp 显著
17	0.8733	0.0192	−2.33pp ± 2.84pp 不显著
20	**0.8967**	0.0176	参考（最优）
23	0.8900	0.0181	−0.67pp ± 2.45pp 不显著
26	0.8600	0.0201	−3.67pp ± 3.25pp 刚好显著
29	0.8600	0.0201	−3.67pp ± 3.62pp 边缘
32	0.8367	0.0214	−6.00pp ± 3.98pp 显著
34	0.7867	0.0237	−11.00pp ± 4.50pp 显著
35	0.6867	0.0268	−21.00pp ± 5.84pp 显著

表 3: truth 13 层验证准确率（raw，$n = 300$）。

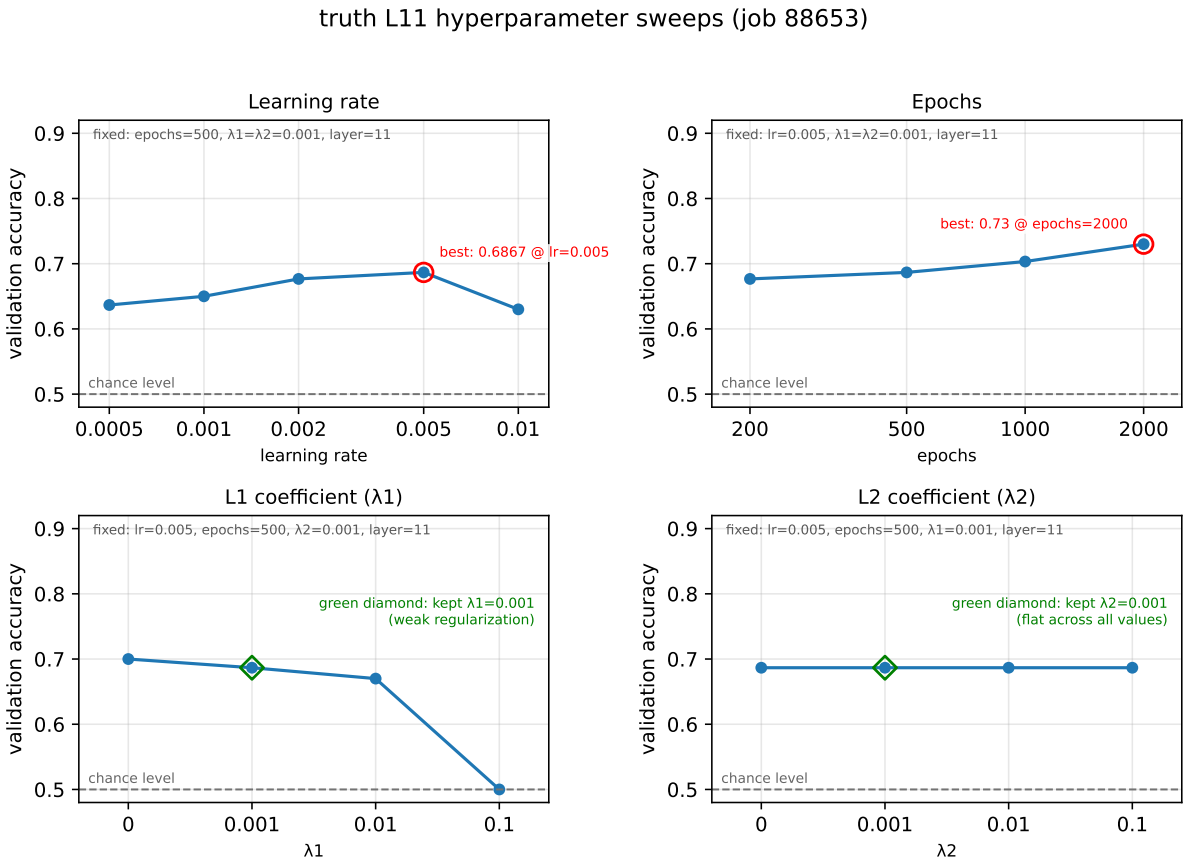


图 15: truth L11 超参数扫描。

A 背景与实验说明

线性探测（linear probing）[1] 是研究模型内部表征的一种回归分析手段：训练时冻结大语言模型，只在某一中间层的激活（隐表征）上训练一个简单模型——本实验中即手写实现的线性回归与逻辑回归；若该模型能在独立验证集上优于合理基线，说明相应信息以（近似）线性可分的形式编码于该层表征、可被“解码”。线性可解码是一个良好的性质：信息可用简单模型读出，也是激活引导（activation steering）等后续干预研究的前提。本实验考察 Qwen3-4B-Base 内部的两类表征：地理空间坐标（论文 [3] 实验的简化，用线性回归预测经纬度）与句子真假（论文 [4] 实验的简化，用逻辑回归预测真假标签）。

Qwen3-4B-Base 共 36 个 decoder block（编号 0–35），隐藏维度 $D = 2560$；特征取指定词元在 block 输出处（最终 RMSNorm 之前）的隐状态，不使用聊天模板。词元选择随任务而定：world 取“国名最后一个词元”，truth 取“句子最后一个词元”。课程预提取了第 11、23、35 层；笔者另按实验文档的算力平台教程提取了其余 10 层，凑成 13 层（从 2 到 35、步长约 3）以支撑层间对比（提取与训练的工程细节见附录 B）。特征文件以 float16 存储为 $(N, 2560)$ 数组，训练与评测时转为 float64。

两个任务的规模与角色不同。world 为回归任务：train 500 / valid 130，目标为（纬度, 经度）双输出（单位度，北纬、东经为正），按 MSE 评测；$N = 500 \ll D = 2560$ 为欠定问题，必须借助正则化与特征层选择获得泛化能力。truth 为二分类任务：train 5088 / valid 300，标签 1 为真、0 为假，两个集合内真假各半；样本数大于特征维度。

B 提交的文件结构

提交包解压后，根目录只有四项：`code/`、`report.pdf`、`linear.11.npz`、`logistic.20.npz`。`code/` 是去掉数据集后的 LAB1 代码目录，只保留报告实际用到的脚本、图、结果与配置（含少量复现依赖）；`report.pdf` 是本报告；两个 `.npz` 是最终提交权重，均为 float64，且已折回原始特征空间。

`code/` 根目录的 `model.py` 是手写模型（线性/逻辑回归，全批量梯度下降），`extract_intrep.py` 负责隐藏状态提取，`train23.py` 是单层训练入口，`train1.py` 是两模型的小型冒烟测试，`requirements.txt` 记录依赖；`experiments/` 放训练、扫描、绘图的执行器与配置，以及三组拓展实验；`scripts/` 是集群 sbatch 脚本；`question/code` 是 Q1–Q3、Q6–Q8 的复现脚本，`question/data` 只带 Q1/Q2 使用的 KC 房价 csv；`results/` 保存报告引用的扫描/分层训练结果、最终权重与图；`report/` 放本报告的 `report.tex`。

环境方面，本地与集群统一使用讲义中给出的 ai26 环境。

C 拓展实验列表和动机

下面两个附录（D、E）汇总正文 Q1–Q9 之外的补充实验。附录 D 是思考题的补充：一组为 train 的交叉验证复核选层结论，一组是 prompt 与读点消融检验 Q7 的坐标可读性来源。附录 E 是一个探索性实验：让 Qwen 直接生成坐标，与线性探针对照（见表 4，细节见对应小节）。

实验	动机	主要结论
附录 D：思考题的补充实验		
train 内 5 折交叉验证	Q5/Q9：选层结论是否依赖一次划分	truth 同峰 L20（$\rho = 0.968$）；world 在前面的层差距不显著
prompt 与读点消融	Q7：坐标可读性依赖什么	删国家名 +1005 km；读点换到句末 +1511 km，影响最大
附录 E：有趣的研究实验		
Qwen 直接生成坐标	线性探针和直接输出的区别是什么	valid 中位 43.8 对 953.8 km，119/130 条直接输出更近

表 4: 拓展实验总览。

D 思考题的补充实验

本节用仅含 train 的交叉验证复核正文的选层结论，并通过 prompt 与读点消融检验 Q7 的坐标可读性来源；所有数字与正文的提交结果同源，这些实验不改变提交选点。

D.1 用 train 的 5 折交叉验证能否复现选层结论

（1）问题。正文的选层都建立在一次 train/valid 划分上，如果换一批训练样本，结论还成立吗？实验设置上没有让我们进行数据集的划分，这个拓展实验可以看作是对 Q5 和 Q9 的补充。

（2）实验设置。在 train 内做 5 折 × 3 次重复：truth 按标签分层，world 按纬度五分位分层以保证每折的地理覆盖；对于不同层，需要标准化，只对训练折进行了标准化，验证折不参与。使用了两个估计器快速获得参数结果：world 用闭式对偶 ridge（$\lambda_2 = 1.0$），truth 用 lbfgs（$\lambda_2 = 10^{-3}$），每任务 13 层 × 15 折 = 195 次拟合，两任务合计 390 次。

层	world CV MSE	world valid MSE	truth CV acc	truth valid acc
2	378.9 ± 177.4	157.6	0.5666 ± 0.0142	0.5900
5	377.1 ± 175.6	162.8	0.5844 ± 0.0151	0.6233
8	$\mathbf{351.0 \pm 150.6}$	158.9	0.6216 ± 0.0083	0.6800
11	377.7 ± 156.4	167.2	0.6517 ± 0.0132	0.7167
14	404.3 ± 147.6	213.7	0.7666 ± 0.0143	0.7800
17	444.8 ± 157.0	227.0	0.8293 ± 0.0111	0.8333
20	419.8 ± 155.2	241.6	$\mathbf{0.8508 \pm 0.0124}$	**0.8667**
23	392.9 ± 164.5	241.0	0.8458 ± 0.0145	0.8500
26	423.2 ± 173.8	226.4	0.8210 ± 0.0145	0.8167
29	426.1 ± 194.9	210.3	0.8067 ± 0.0129	0.8000
32	413.3 ± 201.5	180.9	0.7984 ± 0.0129	0.8167
34	401.3 ± 194.8	196.9	0.7871 ± 0.0159	0.7867
35	404.1 ± 189.6	205.3	0.7864 ± 0.0134	0.8067

表 5: train 内 5 折交叉验证的逐层 OOF 指标。

（3）结果。

truth 的结果与思考中几乎一致：CV 与 valid 的 13 层 Spearman 相关 $\rho = 0.968$（$p < 10^{-6}$），两边都选 L20。

world 的 CV 最优是 L8（351.0 ± 150.6），valid 最优是 L2（157.6），两者在 CV 上的差只有 27.9 MSE、在 valid 上的差只有 1.29 MSE，差异不是很显著；CV 与 valid 的排序相关为 $\rho = 0.703$（$p = 0.007$），但具体名次由在不同折中不同。（如表 5、图 16 所示）。

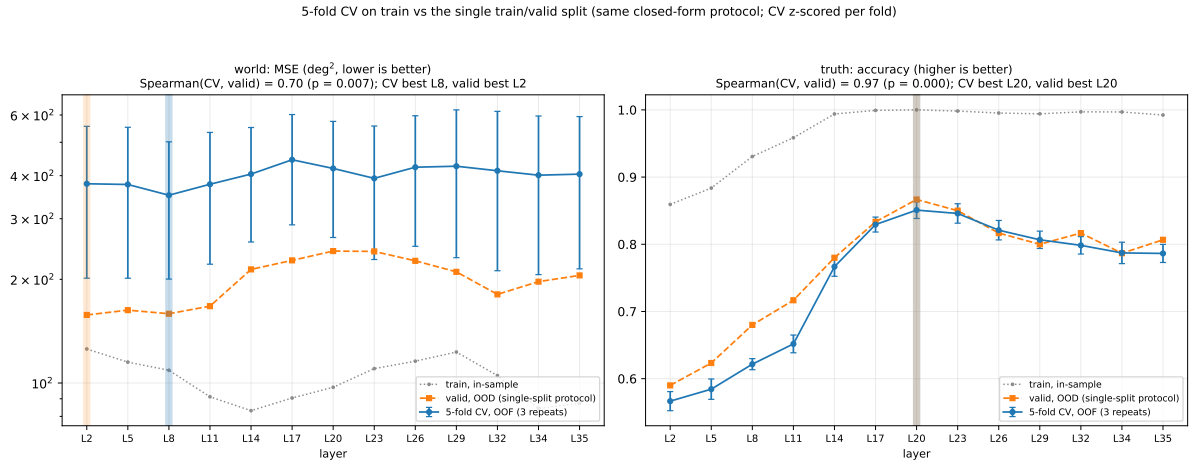


图 16: 5 折交叉验证与单次划分的对照。

（4）结论。 world 的 CV 结果也进一步证实了 L2/L5/L8/L11 差异不显著，没有选择表现最好的 L2，而选择了 L11 也是合理的。truth 的 CV 结果进一步说明了 L20 选层的重要性。

D.2 prompt 变体与读点的消融

（1）问题。这是对 Q7 的追问：如果坐标的预测依赖国家名，那么把国家名拿掉，实验结果会发生什么变化？进一步想，如果改变句子问法或者改变实验讲义中给出读点，效果会发生什么变化？

（2）实验设置。实验设置了五个变体，均使用同一批 500/130 个地点，行序与实验给的 `datasets/world` 对齐，分别为 `origcountry`（原句，读国家名最后一个 subtoken）、`origlast`（原句，读句末）、`nocountry`（删去 “, {country}”，读句末）、`nameonly`（只给 “地名, 国家”，无指令，读国家名）、`rephrase`（换一种问法，读句末）。主训练选择 L11，做了标准化，超参数为 lr 0.002、2000 轮、$\lambda_1 = 10^{-3}$、$\lambda_2 = 1.0$。

变体	MSE	中位 km	平均 km	P90 km	≤ 1000 km
`origcountry`	167.4	909	1203	2471	55.4%
`origlast`	539.1	2280	2715	5530	11.5%
`nocountry`	1069.4	3115	3719	7544	9.2%
`nameonly`	224.6	1100	1436	3009	45.4%
`rephrase`	492.6	2163	2515	4540	13.8%

表 6: prompt 变体对比（world valid，$n = 130$）。

（3）结果分析。第一，删去国家名 +1004.9 km，同时预测点平均漂移 2915.6 km，说明国家名对模型效果具有较大影响；第二，删去指令 +232.6 km，换问法 −199.2 km，说明这两个对模型效果有一定影响，但不是主要因素；把读点从国家 token 换到句末问号 +1511.4 km，说明讲义中 world 选择取国名最后一个词元是有必要的（如表 6、图 17 所示）。

（4）结论与局限。本实验中模型的预测效果一定程度上依赖国家名，国家名是坐标可读性的主要信息来源，但不是唯一来源：指令和换问法影响很小，而读点位置的影响最大，这些因素综合影

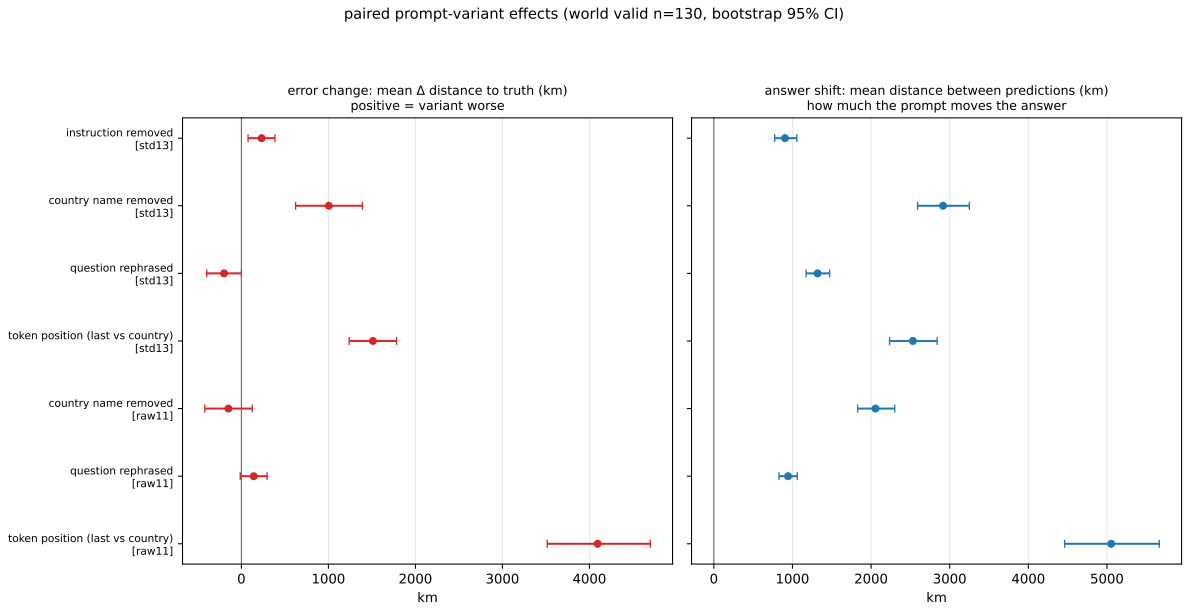


图 17: prompt 变体的配对效应。

响了模型的效果。

E 有趣的研究实验

E.1 Qwen 直接生成坐标与线性探针的对照

（1）问题。前面的探针都是“读出某一层，再训一个线性头”。能不能跳过线性头，直接问 Qwen 本身：“这个地点在哪？”

（2）实验设置。不训练任何头，直接让 Qwen3-4B-Base 零样本生成经纬度。模型用官方权重（revision `906bfd4b`），以 bf16 载入。输入是 world 的 630 道原题：逐字保留原句，只在末尾追加固定指令“Output only JSON with numeric latitude and longitude in decimal degrees. Answer:”；不加聊天模板、不给示例、不额外提示国家或坐标。生成用 batch 4，贪心解码，最多 64 个新词元。贪心是为了可复现；valid 130 条用于主对照，train 500 条只作同分布参照。

回答按“严格 JSON、嵌入 JSON、正则”三档解析，不做符号纠正、不交换经纬度、不自动回绕，同时检查了回答中坐标的合法性。探针的参照选择的是 world raw L11。严格 JSON 的接受率是 train 99.8%、valid 99.2%，放宽后 valid 100%。

指标	Qwen 直接（valid）	线性探针（valid）	Qwen 直接（train）	线性探针（train）
中位距离 / km	43.8	953.8	15.5	662.4
平均距离 / km	159.1	1141.7	–	–
P90 距离 / km	416.0	2391.0	–	–
原始坐标 MSE	505.76	150.43	159.64	116.93
周期经度 MSE	17.64	150.43	108.54	116.93

表 7: Qwen 直接输出与 L11 线性探针的对照。

（3）结果。直接输出在距离上全面更好：valid 中位 43.8 对 953.8 km（约 22 倍），平均 159.1

对 1141.7 km，P90 416.0 对 2391.0 km；train 中位 15.5 对 662.4 km（约 43 倍）。逐条比，valid 130 条里有 119 条直接输出更近，探针减直接的距离差均值是 +982.5 km，bootstrap 95% 区间 $[835.0, 1138.9]$，不跨 0。但原始 MSE 存在问题。valid 的 505.76 里有 96.52% 来自一条 Mount Tomanivi（斐济，跨 ±180° 日界线），把经度周期带来的差距消除后，周期 MSE 只有 17.64（如表 7、图 18、图 19 所示）。

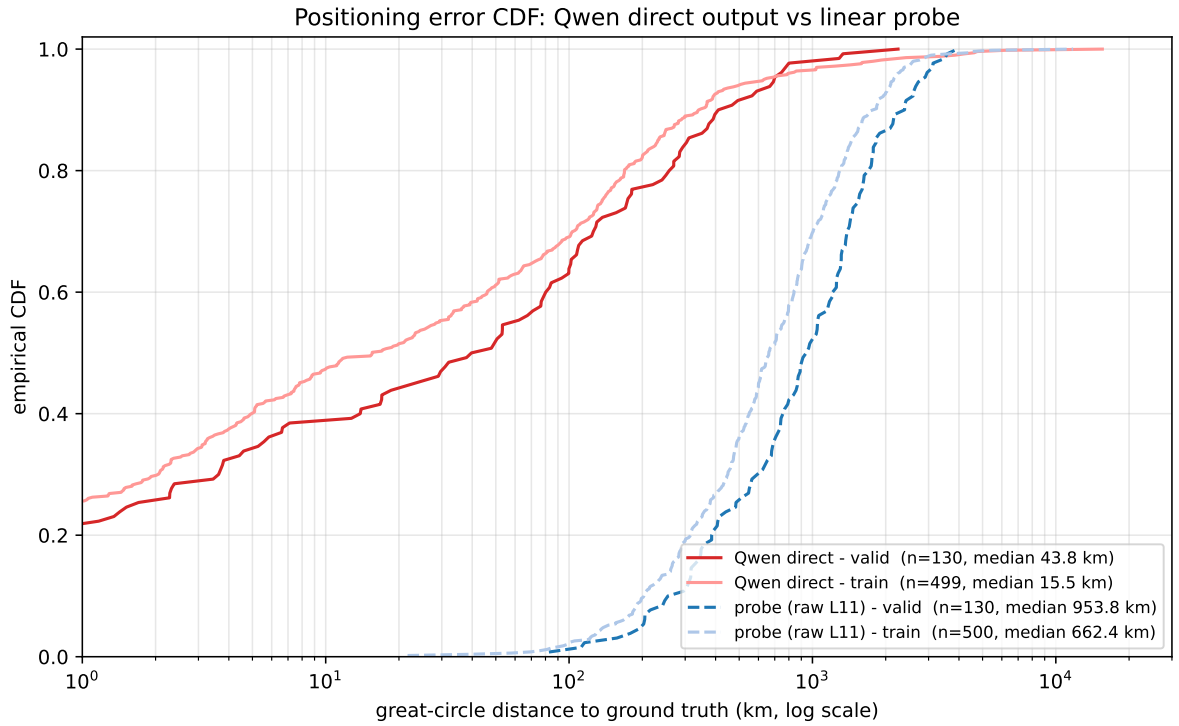


图 18: 到标签的大圆距离经验 CDF。

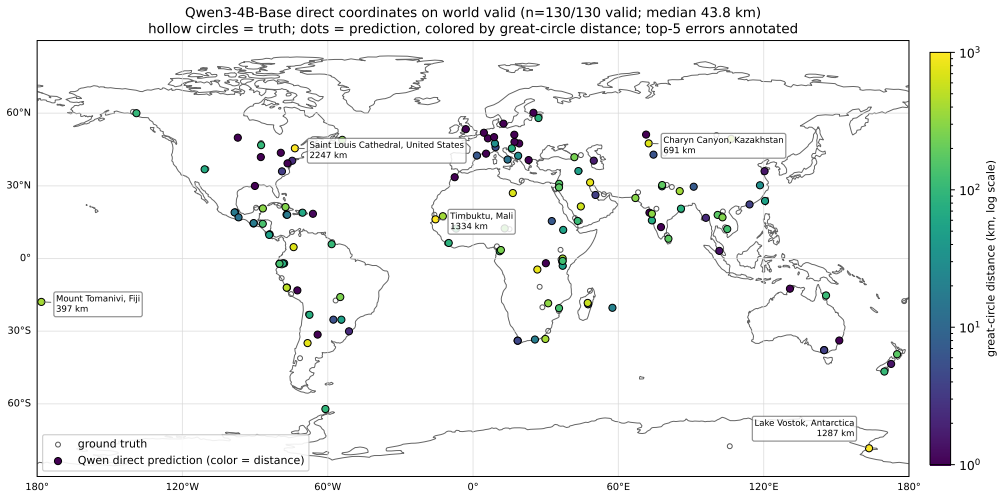


图 19: Qwen 直接输出的 valid 预测位置（仅海岸线，无国界线）。

（4）结论。 Qwen 模型本身具有的地理识别能力，只是线性探针探测时产生了误差，导致预测效果没有 qwen 本身好。

F 实验建议与反馈

我有一点实验上的建议，就是可能的实验时间预估。老师说这门课是实验课，实验必然付出大量时间，我深以为然。但是做 Lab1 的过程中给我一种无休止的感觉————我不知道对于我来说，这个实验究竟需要多少时间，我到底应该每天花多少时间，才能顺利的完成实验，才能不被 ddl 追着跑？未知带来恐惧啊！尽管实验对于不同的人来说所需要的时间肯定是大相径庭的，但我还是希望后来的实验能提供一个参考时间，一是可以降低不确定性焦虑，让每个人对实验心里有一个底；二是有助于我们更好的安排时间；三是防止过度投入或低质完成。我认为时间建议不必很精确：可以给总时长区间 + 分阶段估计（读题/实现/调试/写报告），并说明假设条件，让后来的实验少一点“未知带来的恐惧”。

最后，感谢助教设计的实验和编写的实验讲义。从手写线性回归、逻辑回归，到把它们当作探针去读 Qwen 隐藏层里的地理坐标和句子真假，通过思考题的设置，让每一步都有迹可循同时给了充足的拓展空间，包括附录里配环境，算力平台的介绍，也让我初步掌握了这些能力。确实收获颇丰！