FAIML Lab1 实验报告

【姓名】
【学号】

2026 年 10 月

1　思考题

1. 复现 ℓ_1 / ℓ_2 系数路径与数据来源

题面：重现课件（第 42、48 页）中 ℓ_1、ℓ_2 正则化的“系数路径”，并解释数据来源。
【骨架 · 结论要点，待扩写】

- **数据来源判定：**课件图的 8 个特征列名（bedrooms、bathrooms、sqft_living、sqft_lot、floors、yr_built、yr_renovated、waterfront）与 King County 房屋销售数据集列名完全一致 $\Rightarrow$ 判定课件系数路径的数据来源为该数据集（Kaggle `harlfoxem/housesalesprediction`，CC0）；$y = \text{price}$。本仓库副本已与 OpenML 版本按 `id` 对拍（仅 23 个缺失单元格口径不同，对拍记录见 § 附录 E）。
- **预处理：**8 特征 + price，剔除 16 个含缺失行（21613 → 21597 行）；特征 z-score（依据课件批注“all features normalized so coeff. on same scale”）；λ 网格 $0\text{–}2 \times 10^5$ 共 201 点。
- **实现：**Ridge 用 SVD 闭式解并与 sklearn 对拍（$\max|\Delta| \approx 10^{-9}$）；Lasso 用坐标下降 + warm start（推导见 § 附录 D）。
- **读数（$\lambda = 0$ 最小二乘解，单位美元/σ）：**sqft_living 268 160、waterfront 63 307、bathrooms 49 137、floors 28 399、yr_renovated 3 397、sqft_lot −12 378、bedrooms −56 868、yr_built −92 382（与课件量级一致）。
- **ℓ_2 行为：**全部系数只缩不归零（课件 p48 批注“所有 $\hat{w}_j \neq 0$ 但大 λ 下都很小”）；bedrooms 与 bathrooms 先升后降（相关特征的补偿效应），与课件曲线形态一致。
- **ℓ_1 行为：**归零顺序 λ^*：sqft_lot 9k → yr_renovated 13k → bedrooms 21k → floors 23k → bathrooms 26k → yr_built 45k → waterfront 79k；sqft_living 至 2×10^5 仍非零（57.7k）——“只剩一个特征”，对应课件 p49 “only features in our model”。
- **结论：**复现的趋势与量级与课件一致（个别系数有小差，源于数据版本/预处理细节）。

成文素材：`question/code/q1_coefficient_paths.py`；`execution_log.md` §3 Q1；对拍记录 `execution_log.md` §1.2。

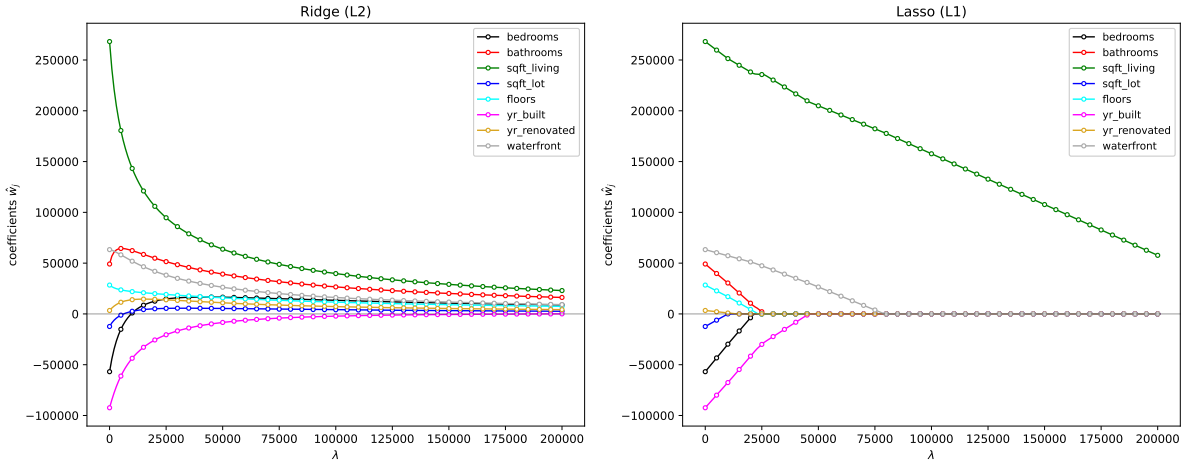


图 1: King County 数据（8 特征 z-score、price 中心化）的系数路径。左：Ridge（ℓ_2）——只缩不归零；右：Lasso（ℓ_1）——精确归零，sqft_living 保留到最后。

2. 用案例说明 ℓ_2 阈值化做特征选择为什么不好

题面：请用案例说明 ℓ_2 正则化在回归中将很小的系数设为 0 进行特征选择是不好的（相比 ℓ_1 正则化，课件第 44 页）。

【骨架 · 结论要点，待扩写】

- **数据：**King County 取 9 特征（Q1 的 8 列 + sqft_above，与 sqft_living 相关 $r = 0.876$）；z-score + price 中心化；主阈值 $\tau = 10^4$（美元/σ）。
- **①选择高度依赖阈值 τ：**同一拟合（$\lambda = 2 \times 10^4$）下 $\tau = 10^4 \to 5 \times 10^4 \to 10^5$，选中特征数 $7 \to 5 \to 2 \to 0$（$\tau = 10^5$ 时“全删”）；沿 λ 看保留集跳变 11 次、含 3 次回归（bedrooms、floors 离开后又回归；yr_renovated 在 $\lambda = 0$ 反而在带内）——而 lasso 零模式严格嵌套（违例 0 次）。
- **② bootstrap（40 次半样本）：**边界特征 yr_renovated 仅 92% 保持选中；$\tau = 10^5$ 下 40/40 全“选空”。
- **③共线平摊 → 整组删除（核心机制）：**sqft_living 单特征 ridge($\lambda = 2 \times 10^4$) 系数 133 791；加入兄弟特征 sqft_above 后为 86 578 + 59 449（$\approx$ 对半切，和 $\approx$ 单特征值）。$\tau = 10^5$：单特征模型保留、成对模型两个成员都被删 $\Rightarrow$ 整个 living-area 组从“必选”变“全删”。合成复制特征（$x_2 \equiv x_1$）下 ridge 精确对半 (88 067, 88 067)，任何 $\tau \in (88\,067,\ 176\,134)$ 都删整组；lasso 保留一个代表 (237 689, 0)。
- **④预测代价**（train/valid 7:3，按选中特征重拟合 OLS 的 valid R^2）：全 9 特征 0.5972；$\tau = 10^4$（7 特征）0.5806；$\tau = 5 \times 10^4$（2 特征）0.5032；$\tau = 10^5$（0 特征，常数模型）-0.0003；对照 lasso@10^5（仅 sqft_living 一个代表）仍 0.5033——组信号被完整保留。
- **⑤原因归纳：**(a) ridge 解没有稀疏性，$|w_j|$ 小只代表被收缩多，不代表不重要；(b) 共线时 $|w_j|$ 不是可识别的重要性度量——权重可在组内任意重分配而拟合不变，ridge 最小范数解把权重“平摊”；(c) 阈值 τ 是人为的第二个超参数，无目标函数可优化；(d) ℓ_1 的零来自优化本身（KKT/软阈值），零集沿 λ 单调嵌套、由单一超参数控制。

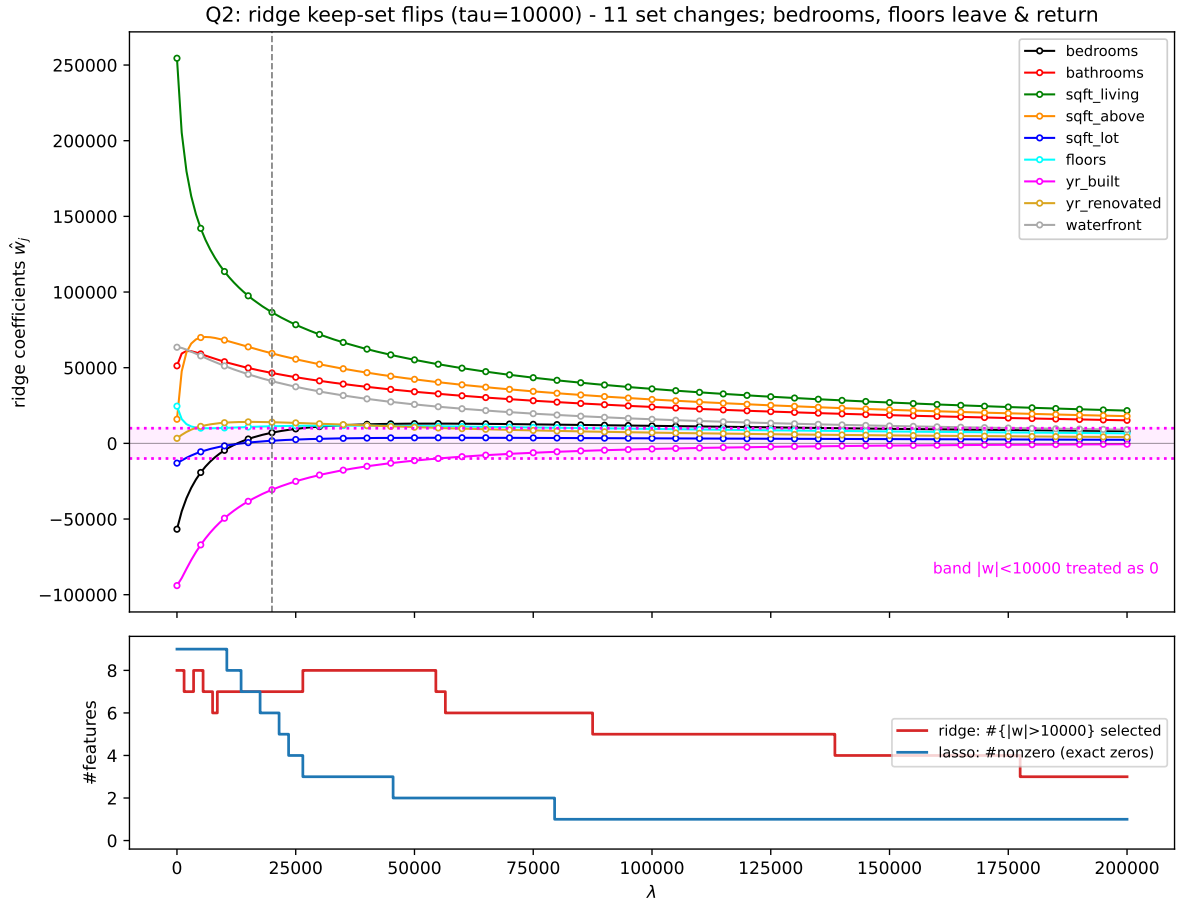


图 2: 阈值化 ridge 的“选择路径”连单调性都不满足：$\tau = 10^4$ 时保留计数沿 λ 跳变 11 次（含 3 次回归）；lasso 非零数严格单调。

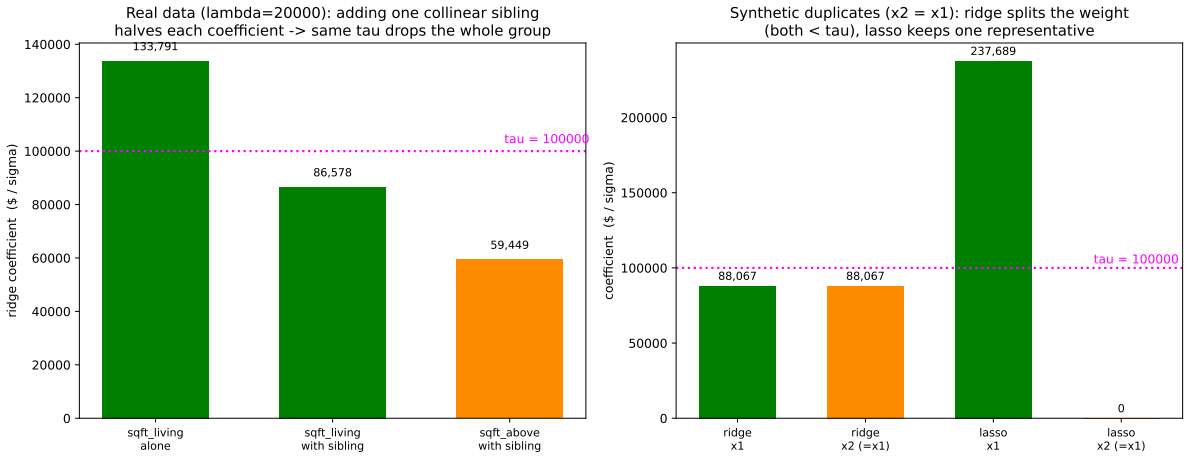


图 3: 共线案例：加入一个共线兄弟即可让每个系数减半、$\tau = 10^5$ 下整组被删（133 791 → 86 578 + 59 449）；lasso 组内保留一个代表（237 689, 0）。

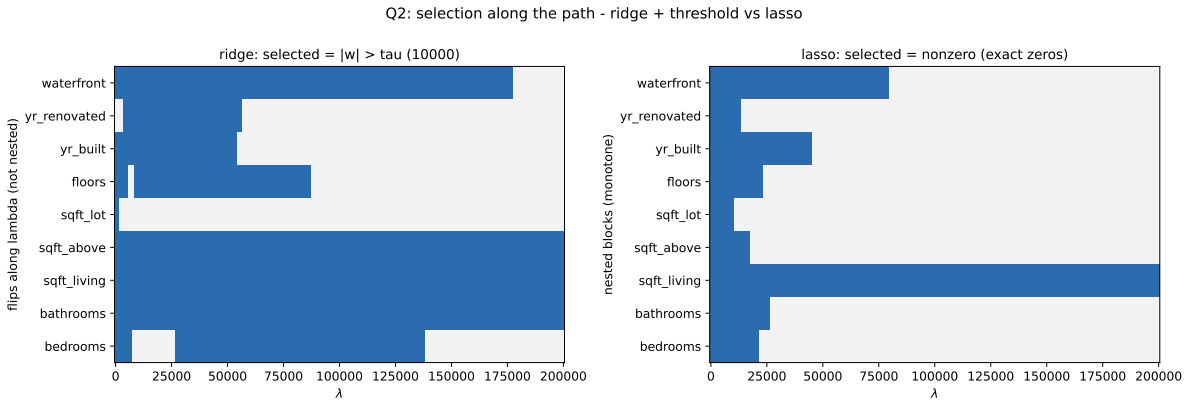


图 4: 结构判据：ridge 阈值化选择集不嵌套（bedrooms、floors 离而复返）；lasso 零模式严格嵌套，每特征仅一个连续非零窗口 $[0, \lambda^*]$。

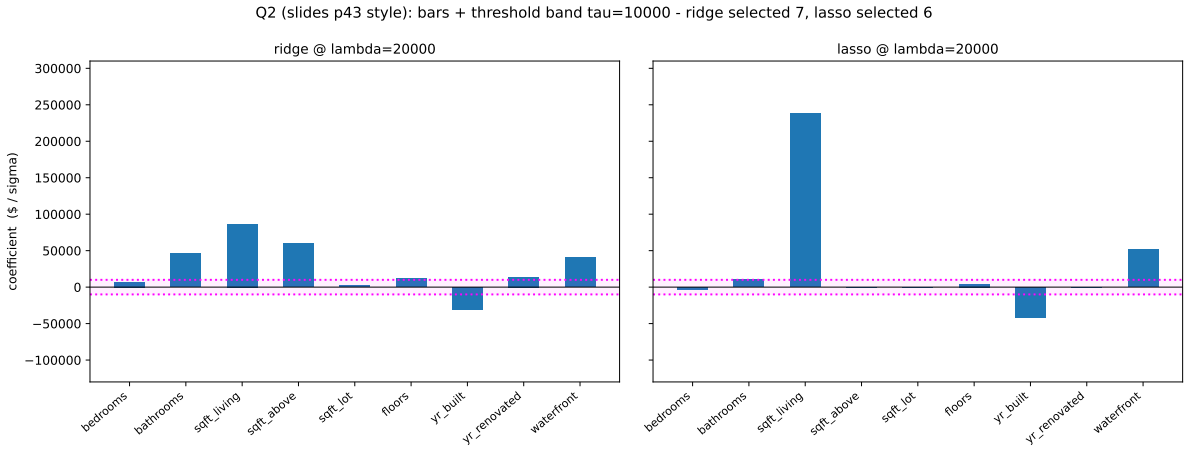


图 5: 同一 $\lambda = 2\times10^4$ 截面（p43 画风）：阈值化 ridge 与 lasso 的保留集在 bedrooms、yr_renovated、sqft_above 三个特征上互相矛盾；τ 从 10^4 扫到 10^5，ridge 保留数 $7 \to 5 \to 2 \to 0$。

成文素材：question/code/q2_ridge_thresholding.py；逐图说明 figures/q2_figure_notes.md；execution_log.md §3 Q2。

3. 与 sklearn 实现有拟合效果差异吗

题面：你的模型相比于 sklearn 的实现有拟合效果上的差异吗？（简要说明即可）（提示：可以在做完后两项实验后回答该题。）

【骨架 · 结论要点，待扩写】

- **换算对齐**（否则比较的是两个不同目标函数）：Ridge $\alpha = N\lambda_2$；Lasso $\alpha = \lambda_1/2$；ElasticNet $\alpha\rho = \lambda_1/2$ 且 $\alpha(1-\rho) = \lambda_2$；逻辑回归 $C = 1/(2N\lambda_2)$（truth $N = 5088$、$\lambda_2 = 10^{-3} \Rightarrow C \approx 0.098$）。
- **结论：没有本质差异**。同一目标函数 + 充分收敛时两者同解（A2/A4 cos = 1.00000、relL2 = 0.002；B2b cos 0.997）。观察到的差异全部可归为非模型因素：优化器机制、收敛预算（≈ 隐式早停正则）、正则口径。
- **①优化器机制**：固定步长全批量 GD 受稳定界约束——B3 raw L11 无正则 lr= 10^{-3}（界 $\approx 5.4 \times 10^{-4}$）第 8 轮 loss 爆炸自动停；sklearn 用精确求解器无此问题。
- **②收敛预算 ≈ 隐式早停正则**：有限轮 GD 停在更小范数点、valid 反而更好（A1 306.55 < 311.56；B1 223.58 < 395.02；T2 ours 0.8867 > 0.8600）；延长训练向 sklearn 靠拢（cos 0.897→0.997）但 valid 可能回落（B2b 162.4 vs B2 150.4）。
- **③正则口径**：sklearn 默认 $C = 1$（更强正则）valid 0.8500；不换算直接比会把“超参不同”误读成“实现差异”。
- 一句话：差异是**优化差异**（步长/求解器/预算/早停），不是模型或实现差异。

行	设置（ours 口径）	sklearn 等价	ours valid	sk valid	cos	relL2
A1	world z-score，无正则，ep20000	LinearRegression	306.55	311.56	0.99929	0.039
A2	world z-score，$\lambda_2 = 1.0$	Ridge $\alpha = 500$	167.06	167.17	1.00000	0.002
A3	world z-score，$\lambda_1 = 10^{-3}$	Lasso $\alpha = 5 \times 10^{-4}$[a]	238.36	598.47	0.594	0.814
A4	world z-score，$\lambda_1 = 10^{-3} + \lambda_2 = 1.0$	ElasticNet	167.04	167.16	1.00000	0.002
B1	world raw，无正则，ep20000	LinearRegression	223.58	395.02	0.871	0.573
B2	world raw，历史最优，ep2000	ElasticNet	150.43	165.34	0.897	0.475
B2b	world raw，历史最优，ep20000	ElasticNet	162.36	165.34	0.997	0.082

表 1: world（L11，valid MSE；小者好）与 sklearn 逐配置对比。[a]：A3 的 sklearn Lasso 未收敛到 tol（dual gap ≫ tol），数值仅供参考。

成文素材：question/code/q3_sklearn_compare.py；逐图说明 figures/q3_figure_notes.md；execution_log.md §3 Q3。

4. world：不同层中间表征的预测效果对比与选层

题面：对比不同层中间表征的预测效果，并分析原因；你在最终模型提交中是如何选择特征选取层次的？

【骨架 · 结论要点，待扩写】

行	设置	ours acc	sk acc	ours ll	sk ll	cos
T1	无正则，ep4000	0.8867	0.8533	0.255	27.77	0.772
T2	$\lambda_2 = 10^{-3}$（sk $C \approx 0.098$），ep5000	0.8867	0.8600	0.257	0.383	0.802
T2b	同 T2，ep10000	0.8733	0.8600	0.269	0.383	0.883
T3	最优配置 $\lambda_1 = \lambda_2 = 10^{-3}$，ep5000	0.8967	0.8600	0.259	0.383	0.712

表 2: truth（L20，valid 准确率；大者好）与 sklearn 对比。T1 行 sklearn 无正则的 ll= 27.77 灾难：可分数据上 MLE 在无穷远。参考：sklearn 默认 $C = 1$（更强正则）→ valid 0.8500。

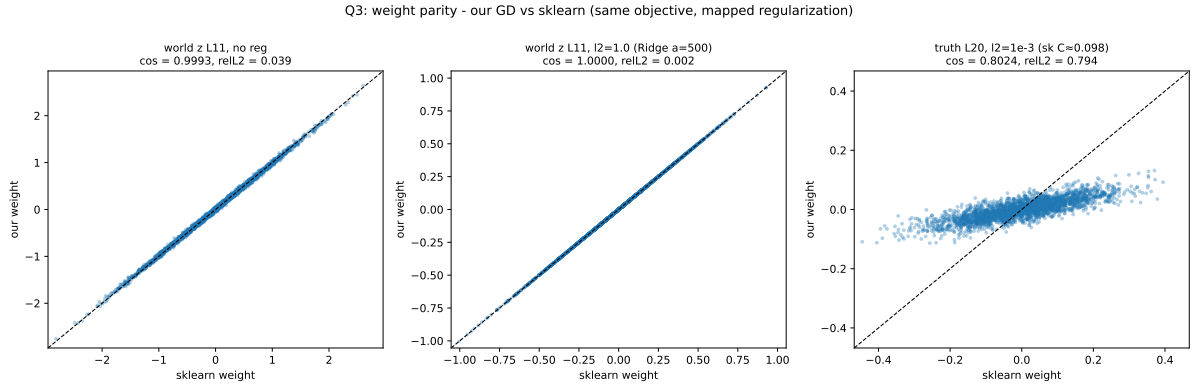


图 6: 对齐正则口径后权重逐点比对：world（$\lambda_2 = 1.0$）落在对角线上（cos = 1.00000）——同一目标函数充分收敛 ⇒ 同解；truth 未充分收敛时权重整体压向 0（relL2 = 0.794）。

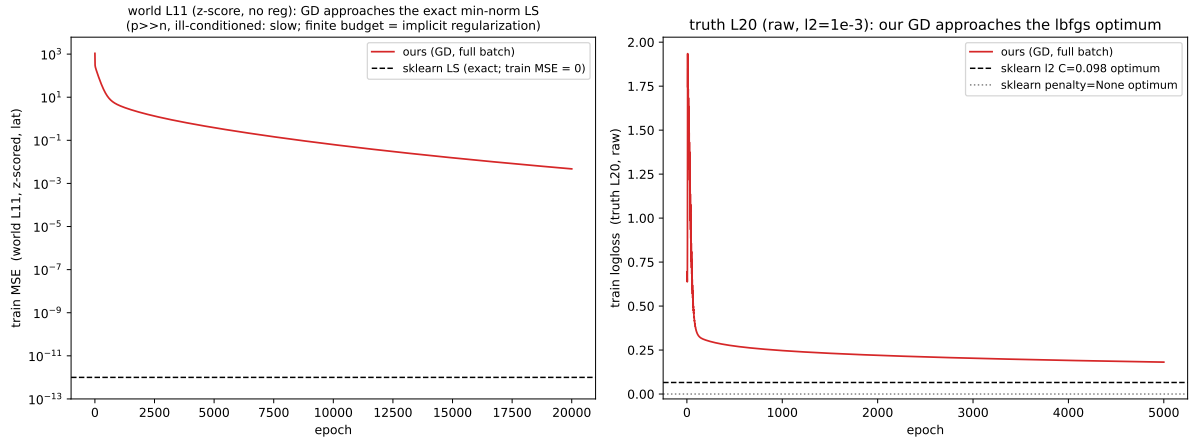


图 7: 收敛曲线：world（$p \gg n$ 病态）GD 20000 轮仅到 0.0047（精确 LS= 0）；truth GD 5000 轮停于 0.181，未达 lbfgs 最优 0.066——有限预算 GD 天然早停、起正则化作用。

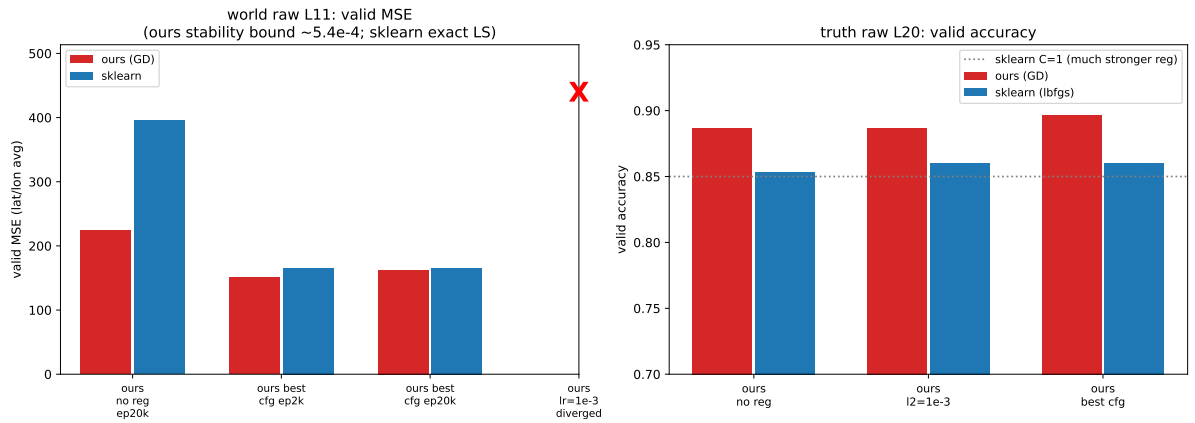


图 8: valid 指标总览：world raw 早停的 223.6 ≪ 精确 LS 的 395.0；lr= 10^{-3} 超稳定界第 8 轮发散（红叉）。truth：ours 全面不低于 lbfgs；灰线为 $C = 1$ 口径陷阱。

- **设置**：13 个层（$2, 5, 8, \ldots, 35$，步长 3）在统一配置下训练（z-score + lr= 0.002 + 2000 轮 + $\lambda_2 = 1.0$），外加 raw L11 的历史最优配置（extra）。统计：单层 ±1 SE；层间比较用同批验证样本的配对差 95% CI。
- **曲线形状（U 形）**：浅层平台 L2–L11（157.6 / 163.0 / 159.1 / 167.0，两两配对差均不显著）→ 中层低谷 L14–L29（L20/L23 ≈241，+84 显著）→ 深层回升 L32 180.3（与 L11 差 -13.3 ± 56.2，不显著）。
- **全场最低** raw L11 extra **150.43**（与 std L2 差 7.1，不显著）⇒ world 水平锁定在 150–167（$R^2 \approx 0.955$），继续调参无显著收益。
- **原因分析（写作时展开）**：world 的位置/坐标信息在**浅层**最线性可分；随层深增加，表征经更多非线性变换、语义抽象增强，坐标的线性可读性下降；深层（L32+）“回升”的机制尚无定论——如实报告为观察（本实验范围内无法归因）。跨任务对照见下题与 § 附录 C。
- **最终提交的选层：raw L11**（层号 11）。理由：点估计最低（150.43）+ 与 std L2/L5/L8/L11 统计上不可区分（$n_{\text{valid}} = 130$、SE ≈13–19，平台内差异不可信）+ 11 层为课程预提取层（不需自行提特征）。备选 std L2（157.57）。**不要用** L14–L29。
- 附：raw L2 探针为负结果（198.78，显著更差）——raw 增益是 L11 特有的组合，不是“浅层普遍现象”。

成文素材：`results/slurm_layers/world/`（results.json + summary.csv + plots/）；《LAB1 分层训练结果分析报告.md》§2/§6；训练配置 `experiments/train_layers.json`。

5. world：正则化与学习率的选择

题面：你在最终模型提交中是怎么选择正则化的？请说明理由；

【骨架 · 结论要点，待扩写】

- **问题背景**：world 为 $N = 500 \ll D = 2560$ 的欠定问题，必须正则化；且原始特征尺度不齐，固定学习率的稳定界随层深暴跌（1800×，详见 § 附录 D）——不先解决数值问题，扫正则没有意义。

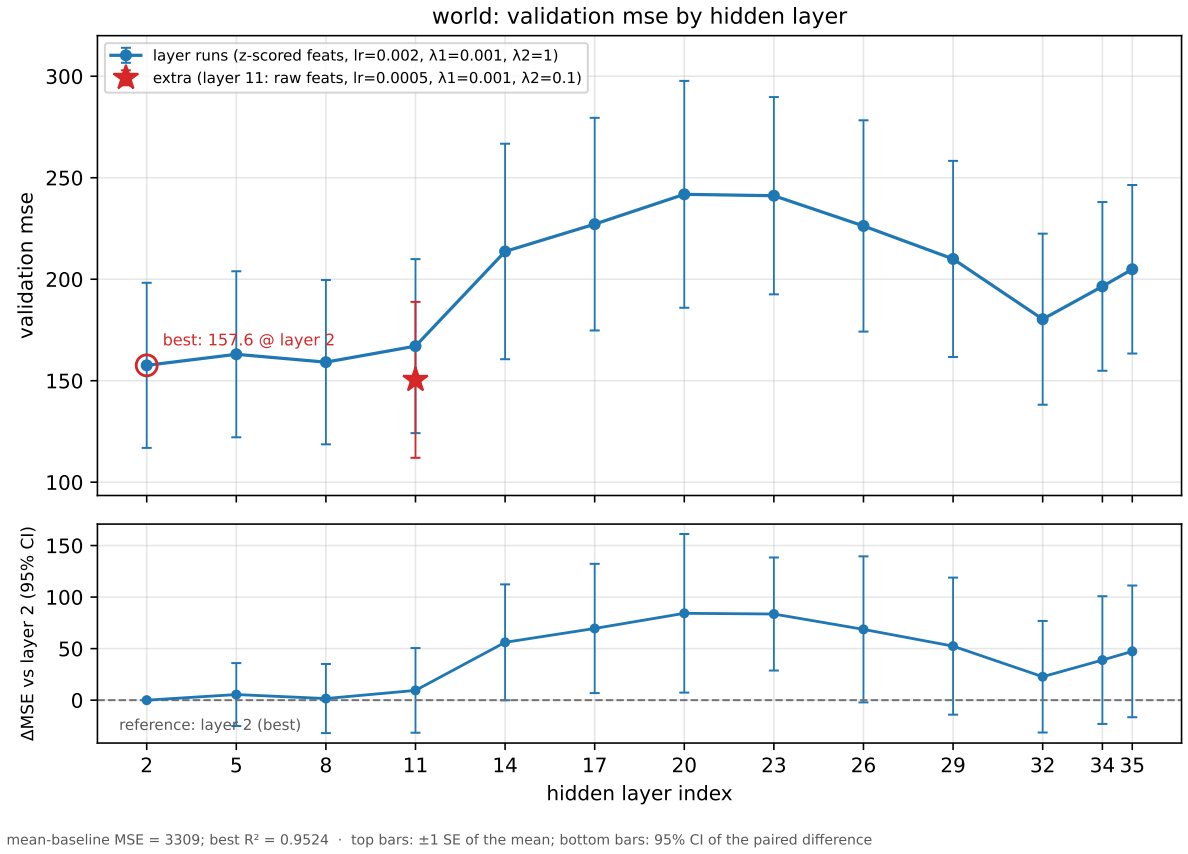


图 9: world 各层验证 MSE（上：±1 SE，红圈 = 最优 std 层，红星 = raw L11 extra；下：与 L2 的配对差 95% CI）。浅层平台—中层低谷—深层回升的 U 形。

层	配置	MSE	±SE	Δ vs L2（95% CI）	判定
2	std	**157.57**	40.7	参考	最优
5	std	163.02	40.9	+5.4 ± 30.5	不显著
8	std	159.14	40.5	+1.6 ± 33.5	不显著
11	std	167.04	42.9	+9.5 ± 41.1	不显著
14	std	213.67	53.1	+56.1 ± 56.2	边缘
17	std	227.13	52.4	+69.6 ± 62.7	显著
20	std	241.83	55.9	+84.3 ± 76.9	显著
23	std	241.14	48.6	+83.6 ± 54.8	显著
26	std	226.25	52.0	+68.7 ± 70.8	边缘
29	std	209.99	48.3	+52.4 ± 66.5	不显著
32	std	180.31	42.1	+22.7 ± 54.1	不显著
34	std	196.46	41.6	+38.9 ± 61.9	不显著
35	std	204.91	41.5	+47.3 ± 63.9	不显著
11	raw（extra）	**150.43**	38.4	—	全场最低

表 3: world 13 层验证 MSE 全表（含 raw extra）。

- **①特征标准化（z-score，统计量只取 train）**：把各界稳定界拉平到 $3.1\text{–}4.8\times10^{-3}$（仅 1.5 倍差距），同一 lr 对所有层公平；λ_2 的真实作用在标准化后才显形。
- **② λ_2 呈 U 形**：$\lambda_2=0.1$ 时训练残差 ≈3 但 valid MSE 209（严重过拟合）；$\lambda_2=1.0$ 最优（167.06）；3.0 回升（184.57）。标准化版扫描固定 lr$=3\times10^{-3}$。
- **③ λ_1**：truth 的扫描显示 λ_1 对大表征有害（稠密表征，见 Q9）；world 提交沿用 $\lambda_1=0.001$（小量、与扫描一致，未观察到收益）。
- **④学习率在稳定界内选取**：raw L11 界 $5.4\times10^{-4}\Rightarrow$ lr$=5\times10^{-4}$（贴线，MSE 150.43）；z-score 版 L11 界 $3.6\times10^{-3}\Rightarrow$ lr$=3\times10^{-3}$（0.83 倍余量，167.06）。训练脚本另有发散兜底（lr×0.5 重试 $\le$4 次）。
- **最终选择**：raw L11，lr$=5\times10^{-4}$，ep2000，$\lambda_2=0.1$（MSE **150.43**）；备选 z-score L11，lr$=3\times10^{-3}$，$\lambda_2=1.0$（167.06）。两者差 17 不显著（SE 13–19）$\Rightarrow$ 按简单性（权重直接可用、无须再标准化）选 raw。
- 论据链：稳定界公式与对拍表见 § 附录 D；扫描全表见 § 附录 B。

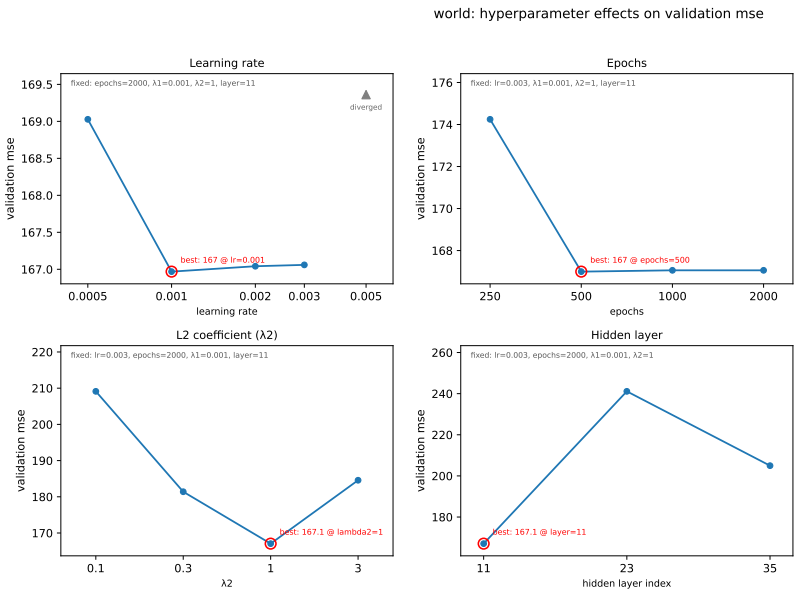


图 10: world 修复重扫（标准化后 16 次）：lr、epochs、λ_2、layer 四组超参数对 valid MSE 的影响；lr$=5\times10^{-3}$ 被正确标记为发散（finite=False）。

成文素材：《LAB1 超参数扫描实验报告.md》§8（job 89085）；`experiments/稳定界说明.md`；`results/slurm_grid/20261009_215412_89085/`。

6. 验证集预测的地图可视化

题面：给出你的模型在验证集上的预测结果，并可视化在地图上（推荐不含国界线）。（提示：此题推荐使用 AI 工具辅助可视化程序的编写。）

【骨架 · 结论要点，待扩写】

- **模型**：world raw L11 最终探针（`world_layer11_extra0/weights.npz`，权重已折回原始特征空间，推理直接 $x@w^\top+b$）。

- **口径闭环**：本地推理复算 valid MSE = 150.4277，与训练记录逐位一致；$R^2 = 0.9545$。
- **定位能力**：单点误差（$\sqrt{\Delta lat^2 + \Delta lon^2}$）平均 12.44°、中位 9.52°（千公里量级的“大洲级”定位）；> 30° 仅 7/130。
- **误差结构**：纬度 MAE 4.25° vs 经度 MAE 10.85°（≈ 2.5 倍）——对“气候带式”纬度线索敏感、具体经度定位弱；最差样本为南极洲 2 条（89.6° / 73.8°，预测均落到 ~28–34°E 的南大洋）。
- **覆盖决定精度**：欧洲/东非/中美等训练覆盖密集区误差 < 5°（Denmark 0.79°）；高纬、孤立岛屿失败（加拿大纽芬兰经度差 40.7°）。
- **合规**：仅绘 110m 海岸线，**无国界线**（课程红线：不合规地图可扣全部报告规范分）。

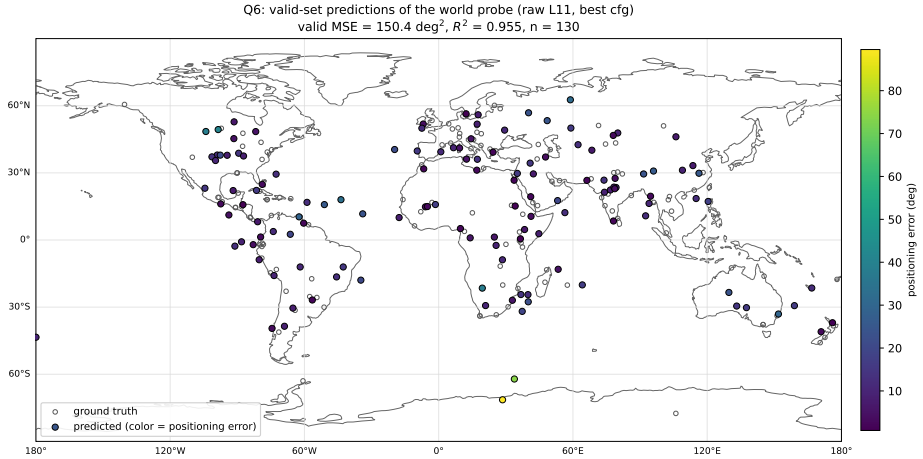


图 11: 130 个验证样本的定位：灰空心圆 = 真值，彩点 = 预测（颜色 = 单点定位误差）。valid MSE = 150.4（$R^2 = 0.955$）；中位误差 9.5°，纬度误差显著小于经度；高纬与孤立岛屿样本误差最大。仅海岸线，无国界线。

成文素材：`question/code/q6_valid_map.py`；逐图说明 `figures/q6_figure_notes.md`。

7. 是地理坐标表征，还是仅仅识别了国家？

题面：从训练集和验证集的表现，是否能够强烈说明模型内部存在地理坐标的表征，而不是仅仅识别了输入中的国家？对于该题可以参考原始论文 [3] 的部分结论和上一题的可视化结果；也可与按训练集国家分组的平均坐标基线比较，考察同一国家内不同地点的预测。

【骨架 · 结论要点，待扩写】

- **设计（三层证据 + 双基线）**：① oracle 国家均值基线——每国取训练集该国坐标均值、用**真实国家标签**查找（对基线有利；未见国家回落全局均值，MSE 3311.27）；②同国中心化——真值/预测相对该国训练均值的偏差，检验“仅国家识别”的常数预测假设；③ unseen 国家——查表原理上不可能。集合分层：all 130 / seen 110 / multi 73 / single 37 / unseen 20（19 国）。CI 为 paired bootstrap。

- **证据 I（不是“仅仅识别国家”）**：unseen 20 条上模型 MSE 158.90 vs 全局基线 1182.83，improvement +**1023.93** [**513.94**, **1654.14**]；同国中心化 lat $r = 0.201$ [0.021, 0.389]（弱显著）、slope 0.115。
- **证据 II（限度）**：seen 110 上 oracle 反超（148.89 vs **113.77**，imp −35.12 [−60.90, −7.08]）；经度国内 $r = 0.046$（ns）；valid→ 同国最近 train 点距离中位 **2.03**°（40/130 < 1°、89/130 < 3°）——大量地点重叠，“记住常见地点”贡献可观（极端例 Jamaica 基线 MSE = 0.01）。
- **结论定性：中等强度**——强于“纯国家分类器”（unseen 上查表不可能却大胜全局基线），弱于论文 [3] §5 的神经元/干预级证据（超出本实验范围）；与论文 §4.1 自评“weak evidence”以及 README §1.2 “可解码 ≠ 使用时一定使用”的警示一致。
- 与 Q6 呼应：误差的经度/小岛屿集中与“相对位置对、绝对位置偏”（论文术语）结构一致。

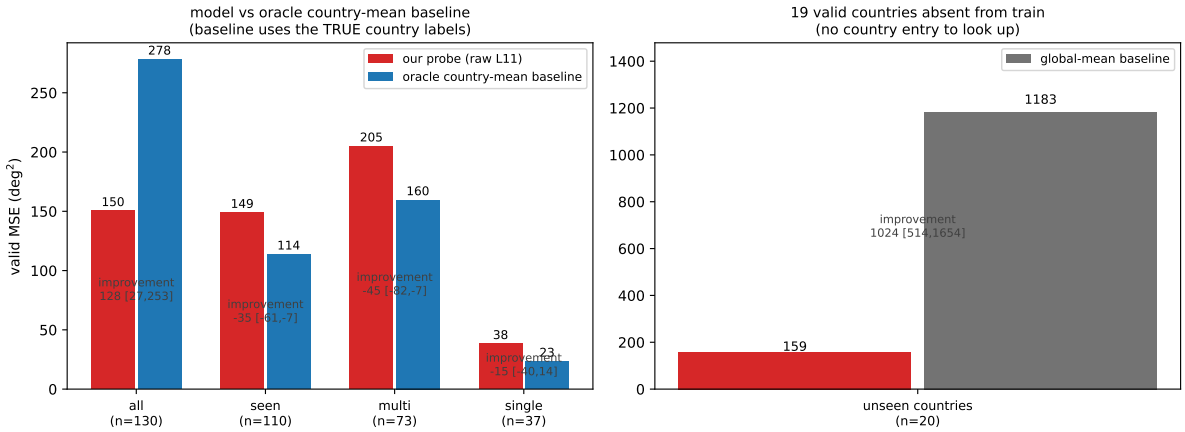


图 12: 模型 vs oracle 国家均值基线的分层 valid MSE。左：seen 国家按样本数分层；右：19 个训练未见国家。improvement = 基线 − 模型；误差棒为 paired bootstrap 95% CI。

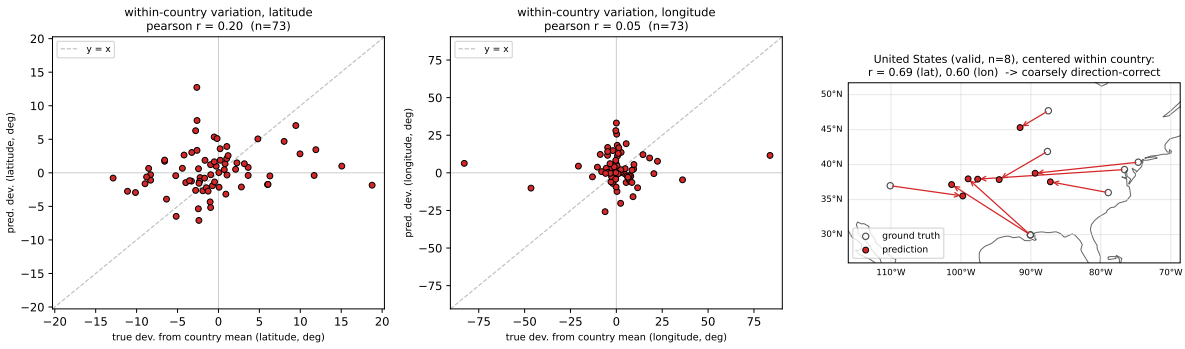


图 13: 同国内分辨力：73 条多样本国家样本相对该国训练均值的偏差（纬度 $r = 0.20$ 弱显著，经度 $r = 0.05$ ns）；右：美国 8 条样本真值 → 预测箭头（方向大体正确、幅度收缩）。

成文素材：`question/code/q7_country_baseline.py`；逐图说明 `figures/q7_figure_notes.md`（含与论文 [3] §4.1/§5 对应表）。

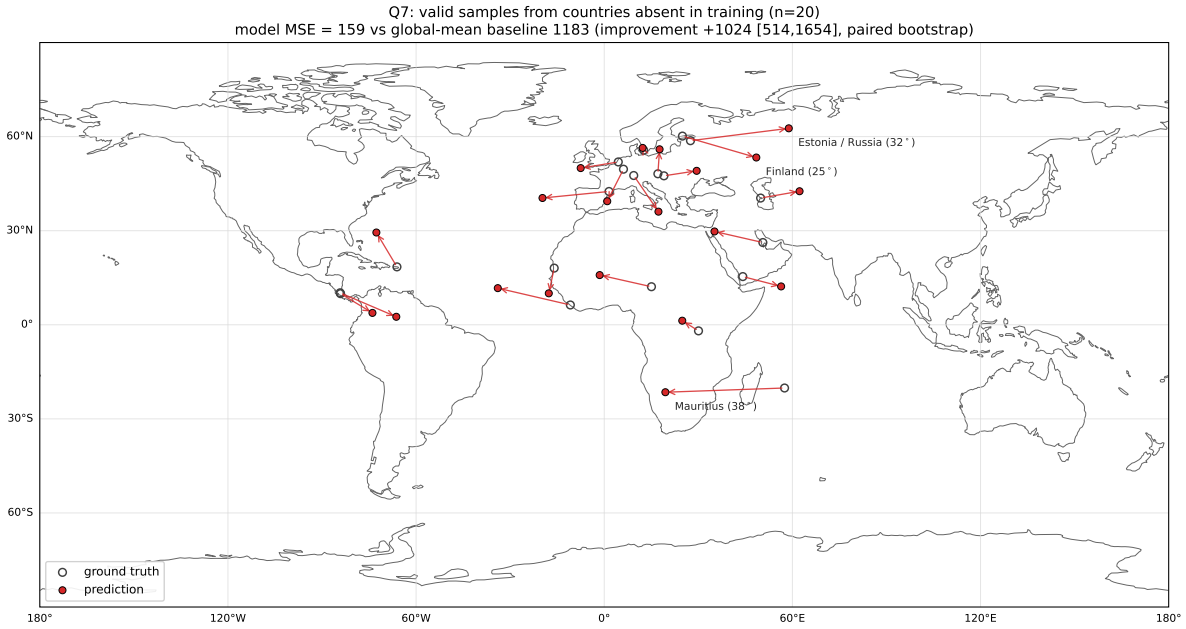


图 14: 19 个未见国家 20 条样本：模型 MSE 159 vs 全局均值基线 1183（imp +1024）。预测整体落对区域（欧洲 → 欧洲、中美 → 中美），最差 Mauritius 38.0°。仅海岸线，无国界线。

8. truth：训练集/验证集的分布差异与应对

题面：仔细阅读训练集和验证集，模型的训练集和验证集存在哪些分布上的差异？你是如何应对的？

【骨架 · 结论要点，待扩写】

- **差异①拼写噪声：**相邻字母换位型错拼句率 truth **valid 24.7% vs train 7.0%**（标签对称：25.3%/24.0% 与 7.1%/6.8%）；world 无此差异（0.8% vs 0.8%，均为地名误报）。
- **差异②主体新颖度：**valid 可识别首实体 212 条中 **77.4% 未在 train 出现**；随机划分零假设（从 train 随机抽 300 条）仅 20.8% [15.6, 25.6]——远在零假设外。头部实体（Dave Grohl、Dwyane Wade、The Offspring）train 计数 0。
- **差异③模板/长度：**train 含“One can” 2.5% vs valid 0.7%、“If one” 0.5% vs 0；句长上界 487 vs 162 字符。
- **差异④ world 对照：**无噪声差异；但 valid 20/130 来自 19 个未见国家、126/130 地点字符串未见过（其中 41 条距同国 train 点 $> 3°$）——字符串新颖 $\neq$ 空间新颖。
- **探针在 OOD valid 上的表现**（L20，总体 0.8967）：typo 子集 0.932 [0.865, 0.986] vs clean 0.885 [0.841, 0.925]（差 -0.047，CI 含 0——错拼不伤害）；主体 unseen 0.884 vs seen 0.917（ns）。逐层看，中深层（L17–L29）typo 子集甚至更高——文本级噪声被表征部分“平滑吸收”。
- **我们的应对**（写作时打磨口径）：(a) 设” 同分布口径” 对照：train 内部 3 折 CV 随机 vs 按主体分组（分组折测试主体 100% 未见）——0.869 vs 0.877（差 -0.8pp 在折间噪声内）$\Rightarrow$ L20 不依赖” 记住主体”，valid 成绩无主体记忆注水；(b) 全流程只用官方固定 train/valid 划分，且不向 valid 泄漏（训练固定预算、不按 valid 早停）；(c) 把 valid 视为部署分布代理（文档明

示” 测试集分布更接近验证集”），选层/正则以 valid 稳健为准；用分层指标（typo/主体）确认 valid 上的成绩不被噪声主导。数据来源线索：valid 是构造性 OOD（拼写扰动 + 主体轮换），该指纹与公开数据集 CREAK 的对拍为中。

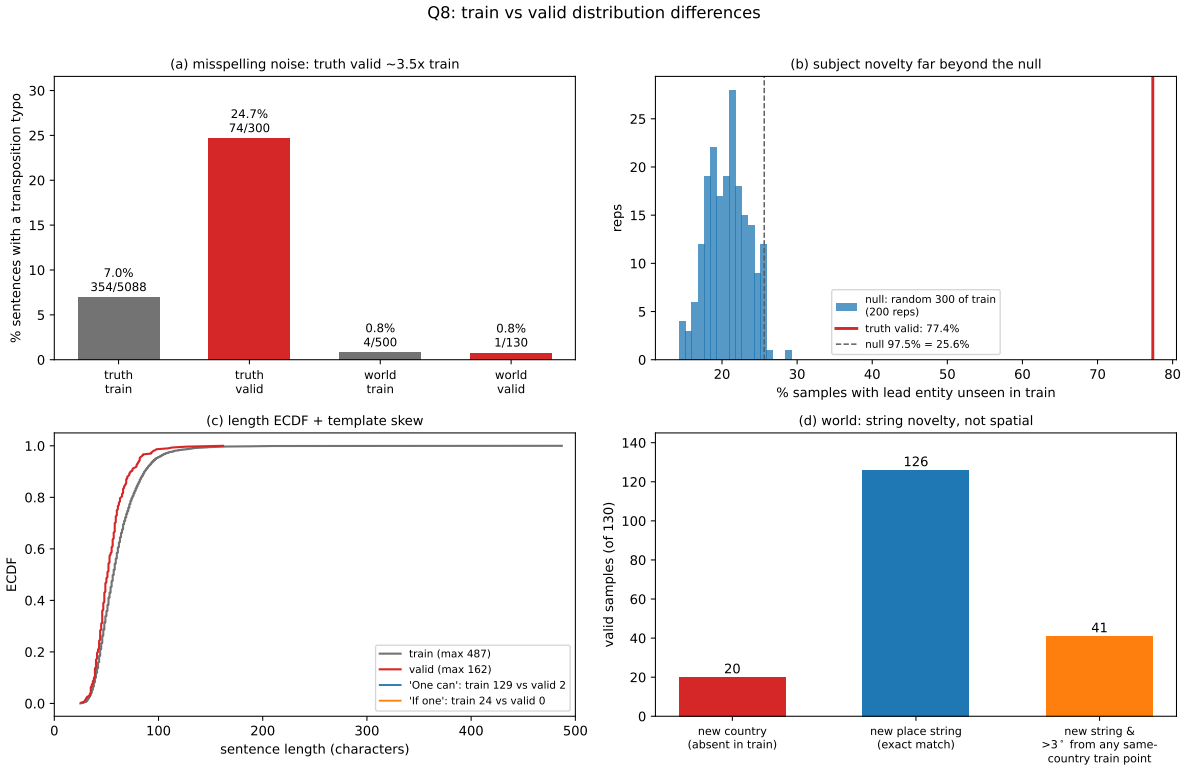


图 15: 分布差异总览：(a) 拼写噪声 valid ≈3.5× train；(b) 主体新颖度 77.4% 远在零假设分布之外；(c) 长度 ECDF 与模板差异；(d) world 对照——字符串新颖而非空间新颖。

成文素材：`question/code/q8_split_analysis.py`；预调查 `execution_log.md` §3 Q8 相关记录；CREAK 路线 `guide/指南综述与可做实验清单.md` §3-B1。

9. truth：选层与正则化的理由

题面：你在最终模型提交中是怎么选择特征选取层次和正则化的？请说明理由。

【骨架 · 结论要点，待扩写】

- **13 层曲线（倒 U 形）：**L2 0.567 单调爬升至 **L20 峰值 0.8967**，L26 起显著回落（L35 0.687）；L17–L23 为统计等价平台（−2.33pp ± 2.84pp、−0.67pp ± 2.45pp，均含 0）——不要过度解读 0.67pp 的峰差，但 L20 数值最高、峰位居中。
- **选层理由：**中层（L17–L23）是“真假语义”最线性可分的层带；与 world（浅层最优）形成鲜明对照——两任务的最优层不同、说明两类信息在不同深度；选择 **L20**（备选 L23）。对比 88653 的三层扫描（当时 lr 偏小、轮数偏少）：L23 一枝独秀的结论在 13 层全扫后修正为“中层平台、峰位 L20”。
- **正则化：**扫描结论（L11 口径）λ_1 有害（0 → 70.0%、0.001 → 68.7%、0.01 → 67.0%、0.1 → 50.0%）——表征稠密（2560 维全非零），ℓ_1 的精确零摧毁可分方向；λ_2 在 test 范围内无差异（0/0.001/0.01/0.1 全 68.7%）。最终 $\lambda_1 = \lambda_2 = 10^{-3}$（平衡、两侧都留余量）。

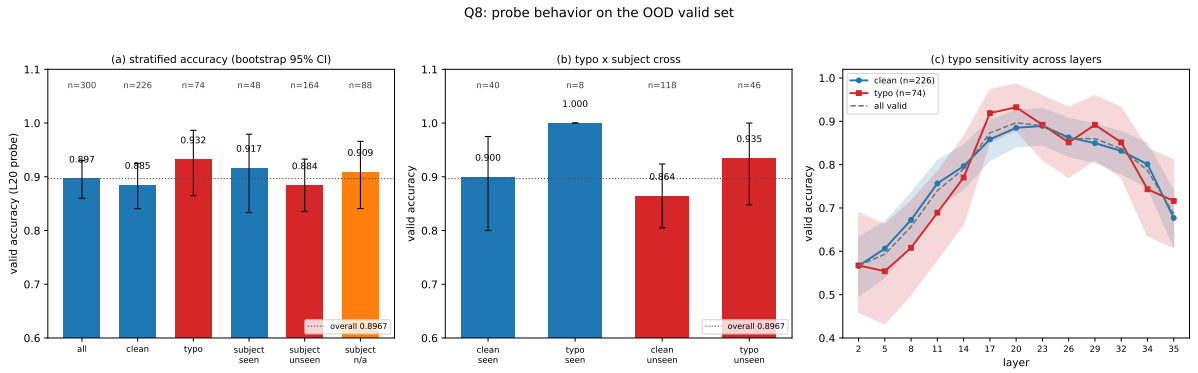


图 16: L20 探针在 OOD valid 上的分层表现：(a) 主分层准确率；(b) typo × 主体交叉；(c) 13 层探针的 typo 敏感度。

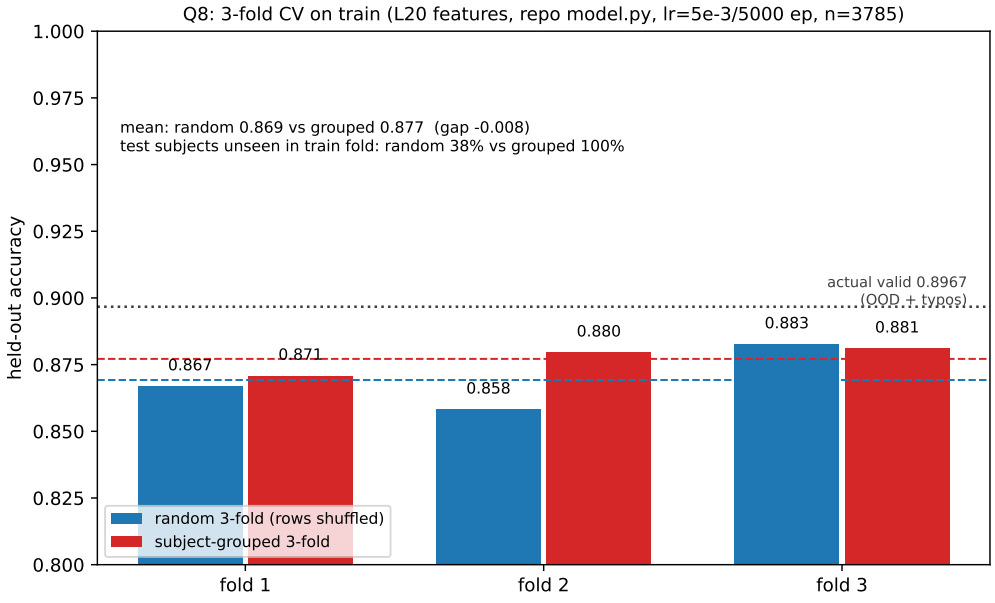


图 17: train 内部 3 折 CV 对照（L20、仓库 model.py 同配置、n=3785）：随机 vs 按主体分组划分（测试折主体未见比例 38% vs 100%）的 held-out 准确率——均值 0.869 vs 0.877（差 −0.8pp，在折间噪声内）；灰点线为实际 valid 0.8967。两种划分口径几乎无差 ⇒ L20 探针不依赖主体记忆。

- **为什么不干脆无正则**：可分数据上 MLE 在无穷远（Q3 T1：sklearn penalty=None valid ll= 27.77 灾难；ours 靠早停 0.255）——弱正则 + 有限轮预算共同起稳定作用。
- **收敛预算**：5000 轮；13 层中仅 L2/L32 触发早停，其余跑满——单层再精调或有 1–3pp 空间，但收益/代价比一般（如实说明）。
- **最终提交**：raw L20，lr= 5×10^{-3}，ep5000，$\lambda_1 = \lambda_2 = 10^{-3} \Rightarrow$ valid acc **0.8967**；备选 L23（0.8900）。**不要用** L14 及以下、L26 及以上。

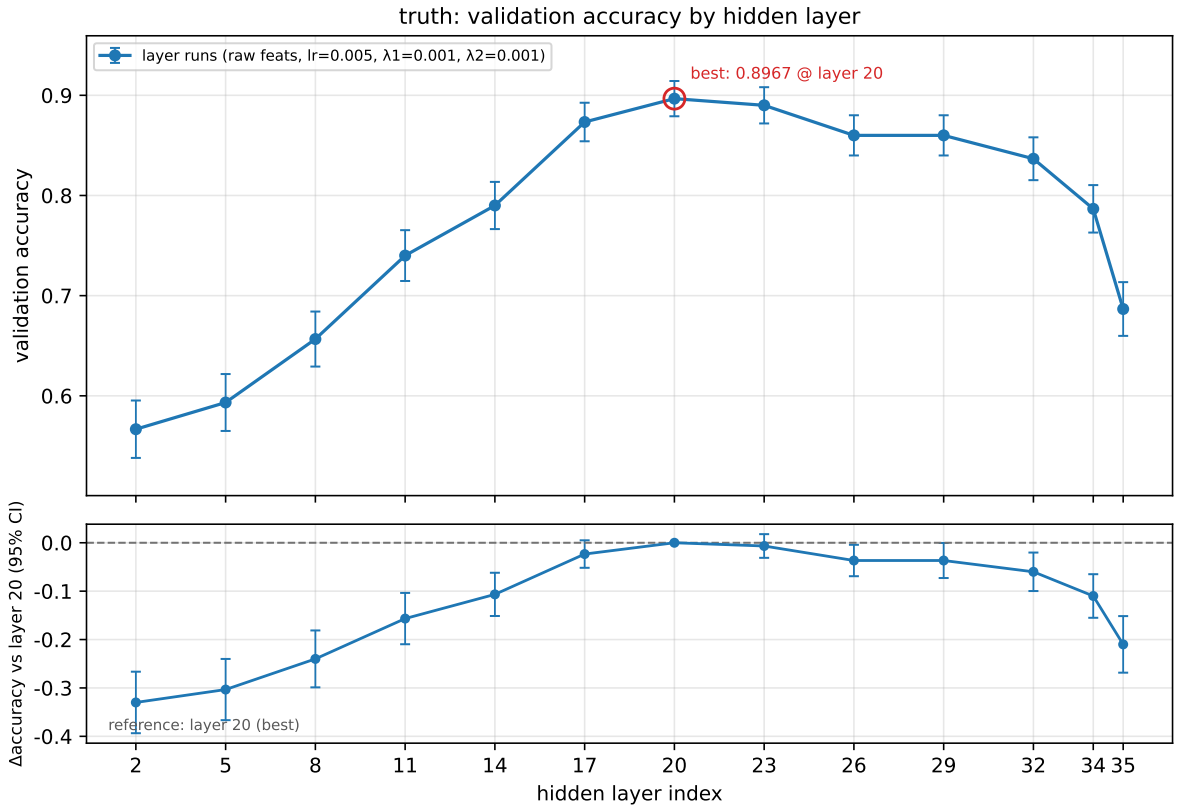


图 18: truth 各层验证准确率（上：±1 SE，红圈 = L20；下：与 L20 的配对差 95% CI）。倒 U 形、中层平台。随机水平 = 多数类 = 0.50。

成文素材：`results/slurm_layers/truth/`（合并 results.json + plots/）；《LAB1 分层训练结果分析报告.md》§3/§6；truth 扫描 §2。

层	acc	±SE	Δ vs L20（95% CI）/判定
2	0.5667	0.0287	−33.00pp ± 6.36pp 显著
5	0.5933	0.0284	−30.33pp ± 6.32pp 显著
8	0.6567	0.0275	−24.00pp ± 5.88pp 显著
11	0.7400	0.0254	−15.67pp ± 5.30pp 显著
14	0.7900	0.0236	−10.67pp ± 4.47pp 显著
17	0.8733	0.0192	−2.33pp ± 2.84pp 不显著
20	**0.8967**	0.0176	参考（最优）
23	0.8900	0.0181	−0.67pp ± 2.45pp 不显著
26	0.8600	0.0201	−3.67pp ± 3.25pp 刚好显著
29	0.8600	0.0201	−3.67pp ± 3.62pp 边缘
32	0.8367	0.0214	−6.00pp ± 3.98pp 显著
34	0.7867	0.0237	−11.00pp ± 4.50pp 显著
35	0.6867	0.0268	−21.00pp ± 5.84pp 显著

表 4: truth 13 层验证准确率全表（raw，lr= 5×10^{-3}，5000 轮，$n = 300$）。

A 背景知识：线性探测、Qwen3-4B 与两个任务

【骨架 · 背景素材，成文时自由组织（附录不直接记分，建议 0.5-1 页）】

- **线性探测（linear probing）**：冻结 LLM，在某一中间层的表征上训练简单线性模型（回归/分类），以判断目标信息在该层是否**线性可分地存在**（Alain & Bengio, 2018 [1]）。本实验考察 Qwen3-4B-Base 的**空间坐标**（论文 [3]）与**句子真假**（论文 [4]）两类表征。
- **特征口径**：0-35 共 36 个解码器块的输出（final RMSNorm 之前），$D = 2560$；world 取“国家名最后一个 token”，truth 取“句子最后一个 token”；训练时 `float16`→`float64`。
- **两任务规模**：world train 500 / valid 130（回归，目标 lat+lon）；truth train 5088 / valid 300（二分类，标签对称）。world 为热身（$N \ll D$）；truth 为效果主考察。
- **提交物**：world `weights` $(2, 2560)$ + `bias` $(2,)$；truth `weights` $(2560,)$ + `bias` 标量；均 `float64`，另有输入层号（整数）。
- **本实验两个任务的数据集不公布构造方式**（world），truth 的来源经我们反推与对拍做了解释（见 Q8 / §B）。

B 有意思的实验：超参数扫描、稳定界与工程实践

【骨架 · 附加内容（报告 §2.4）素材，成文时压缩为 1-2 页】

- **超参数扫描（job 88653，9 组 35 run）**：两任务在 L11 上分别扫 lr / epochs / λ_1 / λ_2，L11/23/35 扫 layer。要点：truth lr= 0.005（68.7%）、ep≥2000；world lr= 5×10^{-4}（150.94）、ep2000、$\lambda_2 = 0.1$（150.43）；truth layer 23（84.3%）；world layer 23/35 直接发散（inf）——引出数值修复。
- **world 数值修复 + 重扫（job 89085，16 run）**：根因 = 学习率越过**按层稳定界**（§D）；z-score 后 lr= 3×10^{-3} 三层均安全、λ_2 呈 U 形（1.0 最优 167.06）；lr= 5×10^{-3} 被正确判为发散。三条独立路径交叉验证“L11 是 world 最优层、深层收敛后确实更差”。

- **稳定界（数值问题的数学根因）**：$\mathrm{lr} < 2/\lambda_{\max}(H) = N/\|X\|_2^2$，只依赖特征矩阵；13 层 × 两任务 × raw/z-score 全表见 §D。raw 界随深度暴跌 1800×、z-score 后拉平到 1.5×。
- **集群工程（分块提交 + 断点续跑）**：13 层训练在 4h 平台上限内跑不完（首跑 89700 超时）→ truth 拆 4 分块 + `--skip-existing` 复用 + `python -u` 实时日志 + BLAS 线程钉 4；90243–90246 全部成功、零发散，L5 撞慢节点（3390.5s ≈15×）被分块吸收、零进度损失。本地与集群数值逐位一致（确定性代码）。
- **统计方法**：层间比较用同批样本**配对 bootstrap 95% CI**；world 的 MSE 重尾，单层 SE 40+ 而配对后 CI 显著收窄；truth 单样本 = 0.33pp。
- **（可选补充：Q8 的随机 vs 分组 CV 对照）**。

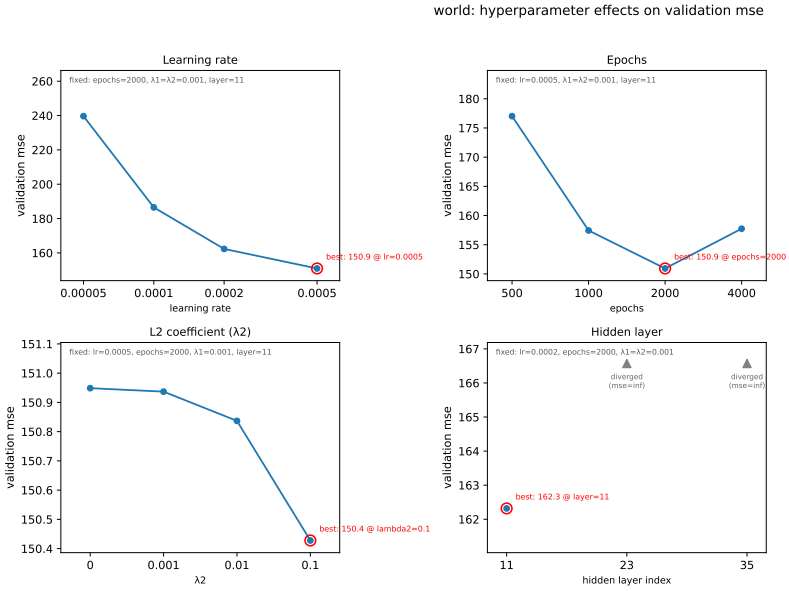


图 19: 首轮 world 超参数扫描（88653，未标准化特征）：lr 越大越好但上限被困在 5×10^{-4}（更大即发散）；layer 23/35 的“inf”由数值问题造成，而非“深层无信息”。

成文素材：《LAB1 超参数扫描实验报告.md》全文；`experiments/`稳定界说明`.md`；`results/slurm_layers/LAB1`分层训练结果分析报告`.md` §5（工程）。

C 有趣的表征：跨任务对照与现象观察

【骨架 · 表征研究素材，成文时压缩为 1-2 页（图可复用正文）】

- **两任务最优层带不同**：world 在**浅层** L2–L11、truth 在**中层** L17–L23，且都在 L32–L35 变差——位置/坐标信息与真假语义的“可线性解码深度”不同（对照论文 [3] 约 60% 深度、论文 [4] 中层，我们 world 的浅层结果与之不同，如实报告）。
- **raw 与 z-score 的相互作用**（一个非平凡的观察）：raw 特征的增益是 L11 特有的（raw L11 150.43 全场最低，但 raw L2 198.78 显著更差）——并非“浅层 + raw 普遍更好”；z-score 的意义不是“提点”而是**解锁深层**（把按层稳定界拉平、让深层可训）。

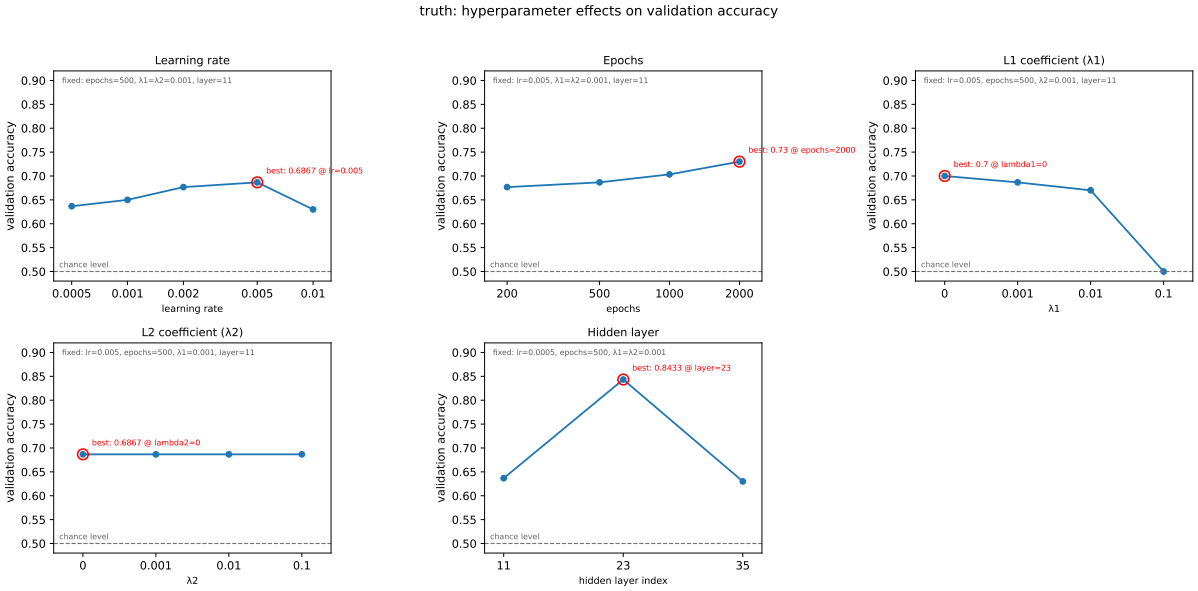


图 20: 首轮 truth 超参数扫描（88653）：lr、epochs、layer 的效应；λ_1 增大有害、λ_2 无差异。

- **深层信息“回升”观察**：world 在 L32 回到 180.3（与浅层不显著）；truth 在 L32/34/35 单调下降——两任务在尾部层的分离性不同，机制留作观察（不做超出证据的归因）。
- **表征里有什么（Q7 汇总）**：坐标信息超越国家身份（unseen +1024）；同国内纬度弱可解码、经度近乎不可解码；结合 Q6 的“经度误差 $\gg$ 纬度”，指向“气候带式”粗粒度空间信息 + 有限的地名知识。
- **噪声稳健性（Q8 汇总）**：中深层表征对字符级扰动不敏感（typo 子集 acc 不低于 clean）——与“表征是分布式语义编码”的直觉一致。
- **token 口径备注**：world 的“国家名最后 token”意味着写入位置的就是国家实体处的状态；结果表明该状态同时编码了超越国名的坐标信息。

成文素材：《LAB1 分层训练结果分析报告.md》§2/§3/§4；`execution_log.md` Q6/Q7/Q8 各节；建议与正文交叉引用、不重复贴图。

D 数学原理：稳定界、闭式解与 KKT

【骨架 · 数学素材，成文时压缩为 1.5-2 页】

- **全批量 GD 稳定界（world）**：$L = \|Xw + b\mathbf{1} - y\|^2/N$ 的 Hessian $H = 2X^\top X/N$；误差传播 $e_{t+1} = (I - \mathrm{lr}\cdot H)e_t$ 收敛 $\Leftrightarrow \mathrm{lr} < \dfrac{2}{\lambda_{\max}(H)} = \dfrac{N}{\|X\|_2^2}$——只依赖特征矩阵、与 y 无关，每层一个值。越界后误差沿最大特征方向每轮 $\times|1 - \mathrm{lr}\,\lambda_{\max}| > 1$ 指数放大。
- **logistic 的松弛**：$H_{\log} \preceq X^\top X/(4N)$，最坏情形充分界 $\approx 8N/\|X\|_2^2$；且梯度有界（$p - y \in [-1, 1]$），越界表现为震荡/饱和而非爆炸——这是 truth 可以不标准化、lr= 0.005 的原因。
- **13 层稳定界全表**（$N/\|X\|_2^2$，越小越危险）与实测对拍（节选：raw L11 界 5.4×10^{-4}，lr= 5×10^{-4} 稳定、10^{-3} 溢出；std L35 界 4.8×10^{-3}，lr= 4×10^{-3} 稳定、8×10^{-3} 第 9 轮爆炸）。

层	world raw	world z-score	truth raw	truth z-score
2	4.95×10^{-3}	4.07×10^{-3}	6.51×10^{-3}	2.67×10^{-3}
5	1.14×10^{-3}	$\mathbf{3.08 \times 10^{-3}}$	1.14×10^{-3}	4.85×10^{-3}
8	6.90×10^{-4}	3.15×10^{-3}	1.09×10^{-3}	9.20×10^{-3}
11	5.45×10^{-4}	3.59×10^{-3}	7.37×10^{-4}	9.74×10^{-3}
14	4.47×10^{-4}	3.40×10^{-3}	6.10×10^{-4}	1.05×10^{-2}
17	3.19×10^{-4}	3.48×10^{-3}	5.01×10^{-4}	1.03×10^{-2}
20	1.93×10^{-4}	3.42×10^{-3}	3.04×10^{-4}	7.00×10^{-3}
23	8.37×10^{-5}	3.16×10^{-3}	1.33×10^{-4}	5.38×10^{-3}
26	3.94×10^{-5}	3.16×10^{-3}	4.08×10^{-5}	4.72×10^{-3}
29	1.89×10^{-5}	3.46×10^{-3}	1.63×10^{-5}	5.42×10^{-3}
32	7.48×10^{-6}	3.92×10^{-3}	6.17×10^{-6}	6.70×10^{-3}
34	3.02×10^{-6}	4.40×10^{-3}	2.93×10^{-6}	7.25×10^{-3}
35	2.77×10^{-6}	$\mathbf{4.77 \times 10^{-3}}$	1.68×10^{-6}	5.84×10^{-3}

表 5: 13 层稳定界 $N/\|X\|_2^2$ 全表（SVD 精确值；raw 界随深度跨 1800×，z-score 后压至 1.5×）。

【骨架 · 数学要点续】

- **Ridge 的 SVD 闭式解**（Q1/Q2 实现）：$X = U\Sigma V^\top$，$\hat{w} = V\,\mathrm{diag}\big(\sigma_i/(\sigma_i^2+\lambda)\big)\,U^\top y$；$\lambda = 0$ 退化为最小范数最小二乘（伪逆解）。用于系数路径的精确计算（与 sklearn 对拍 10^{-9}）。
- **Lasso 的 KKT / 软阈值**（Q1/Q2 实现）：$\partial L/\partial w_j = \frac{2}{N}[X^\top(Xw-y)]_j + \lambda_1\,\mathrm{sgn}(w_j) + 2\lambda_2 w_j = 0$；坐标下降 + warm start；精确零来自优化几何，零集沿 λ 嵌套（与 Q2 的阈值化 ridge 对照）。
- **逻辑回归梯度**（`model.py`）：$\nabla_w L = \frac{1}{N}X^\top(\hat{y}-y) + \lambda_1\,\mathrm{sgn}(w) + 2\lambda_2 w$；数值稳定：$\log(1+e^{-z}) = \mathrm{logaddexp}(0,-z)$。
- **sklearn 换算表**：Ridge $\alpha = N\lambda_2$；Lasso $\alpha = \lambda_1/2$；ElasticNet $\alpha\rho = \lambda_1/2$、$\alpha(1-\rho) = \lambda_2$；Logistic $C = 1/(2N\lambda_2)$。（量纲陷阱：sklearn 的 α 是“平方误差总和”口径。）
- **基线口径与 R^2**：train-mean 基线的元素平均口径 MSE = 3311.27（与模型同口径）；坐标求和口径 = 6622.54。混用会把 R^2 抬高约 2.3pp；统一后 world 最佳 $R^2 = 0.9546$（RMSE $\approx 12.3°$）。

成文素材：`experiments/稳定界说明.md` + `experiments/stability_bound.py`（一键复现全表，本机约 2.5 分钟）；`model.py` 实现即提交代码。

E 复现清单与文件结构

【骨架 · 复现信息，成文时压缩为半页—1 页】

- **仓库结构**：`model.py`（提交的手写模型）；`datasets/`（world/truth 各 13 层 npy）；`experiments/`（`train_layers.py`、`run_grid.py`、`plot_layers.py`、`stability_bound.py`、配置 json）；`scripts/`（集群 sbatch 与分块提交）；`question/code`（Q1–Q8 脚本）；`results/`（扫描/分层/提取的结果与图）；`report.tex`（本报告）。
- **环境**：本地 `ai26`（numpy / sklearn / matplotlib / cartopy / pyspellchecker）；集群同环境 + A100（`--gres=gpu:A100:1`，RTX5090 节点与当前 torch 驱动不兼容需避开）。

- **关键命令**：训练 13 层 `python experiments/train_layers.py --skip-existing`；稳定界 `python experiments/stability_bound.py`；系数路径 `python question/code/q1_coefficient_paths.py`；地图 `python question/code/q6_valid_map.py`；等。
- **提交产物（首选/备选）**：
  - world：raw L11（`results/slurm_layers/world/weights/world_layer11_extra0/weights.npz`，MSE 150.43）；备选 z-score L2（157.57）。
  - truth：raw L20（`results/slurm_layers/truth_b/weights/truth_layer20/weights.npz`，acc 0.8967）；备选 L23（0.8900）。
- **数据来源对拍记录**：KC 房价（Q1/Q2）与 OpenML 全表对拍见 `question/execution_log.md` §1.2；truth 来源指纹见 Q8。
- **日志归档约定**：每轮集群运行的全部日志集中在 `results/slurm_*` 对应时间戳目录。

F 实验反馈与建议

【骨架 · 以第一人称成文（1 段），以下为要点草稿】

- 数据集构造不公布带来的“反推/对拍”过程（Q8）本身很有意思，建议以后在指南中提示“鼓励做来源调查”。
- 算力平台 Students 分区混部 RTX5090/A100，当前 torch 与 RTX5090 驱动不兼容（CUDA error 804）一度让提取全 FAIL；建议在附录 B 明确“钉 A100”的坑。
- 4h 时限对“13 层 × 5000 轮”级别实验需要分块与断点续跑设计——这本身是一次很好的工程训练，但建议在指南给出时间预算参考。
- 报告要求“思考题回答为主、背景进附录、不设长度限制”的设定很好，让我们可以把扫描/稳定性等附加内容放进附录而不挤压正文。
- 提示中“推荐 AI 工具辅助可视化”明确而友好；建议再补充一句“AI 辅助内容需能讲清原理”（验收提示已有类似要求）。