LAB1 超参数扫描实验报告（truth / world）

- 实验任务：LAB1 线性模型 / Linear Probing（USTC AI3002，2026 秋）
- 运行作业：Slurm job `88653`（2026-10-09，本科生算力平台）
- 结果目录：`results/slurm_grid/20261009_115559_88653/`（`results.json`、`summary.csv`、每组权重 `weights/*/weights.npz`、图表 `plots/`）
- 配置与执行器：`experiments/hparam_grid.json`、`experiments/run_grid.py`

结论速览

1. **truth（真假分类）**：最佳配置为 **layer 23 + lr≈0.005 + epochs≥2000 + λ1≈0 + λ2 任意**，验证准确率 **84.3%**（随机水平 50%）。中层表征线性可分性最强，深层/浅层都明显更差。
2. **world（经纬度回归）**：最佳配置为 **layer 11 + lr=0.0005 + epochs=2000 + λ2=0.1**，验证 MSE **150.43**；相对「预测训练集均值」基线（MSE≈6622）解释约 **97.7% 方差**（RMSE≈12.3°）。
3. **world 的优化是当前瓶颈**：可用 lr 被稳定性上限死死卡住（lr>0.0005 即溢出），且 layer 23/35 在 lr=0.0002 下直接发散（MSE=inf）。根源是激活幅度随层深急剧增大，**必须先做特征标准化再谈调参**。
4. 正则化影响很小：**λ2 几乎无影响**（两任务）；**λ1 偏大有害**（truth 在 λ1=0.1 时崩到随机水平）。

1. 实验设置

- **模型**：`model.py` 中纯 NumPy 实现、全批量梯度下降训练；线性回归（MSE + L1 + L2）用于 world 的纬度、经度各一个一维回归；逻辑回归（交叉熵 + L1 + L2）用于 truth。过程完全确定，无随机成分。
- **特征**：Qwen3-4B-Base 解码器块输出（final RMSNorm 之前），取第 **11 / 23 / 35** 层，维度 2560，float16 读取后转 float64。
- **数据**：world 训练 500 / 验证 130（目标为 latitude、longitude）；truth 训练 5088 / 验证 300（二分类）。
- **方法**：每组只改变**一个**超参数，其余固定（单变量对照），共 9 组 35 次训练；模型选择与报告指标均在验证集上。

2. 结果总览

truth（验证准确率，n=300，随机水平 50%）

组	变量	固定条件	各取值结果	最佳
truth_lr	lr	layer11, ep500, λ1=λ2=0.001	0.0005→63.7%，0.001→65.0%，0.002→67.7%，0.005→68.7%，0.01→63.0%	0.005 → 68.7%
truth_epochs	epochs	layer11, lr0.005, λ1=λ2=0.001	200→67.7%，500→68.7%，1000→70.3%，2000→73.0%	2000 → 73.0%
truth_lambda1	λ1	layer11, lr0.005, ep500, λ2=0.001	0→70.0%，0.001→68.7%，0.01→67.0%，0.1→50.0%	0 → 70.0%
truth_lambda2	λ2	layer11, lr0.005, ep500, λ1=0.001	0 / 0.001 / 0.01 / 0.1 全部 68.7%	无差异

组	变量	固定条件	各取值结果	最佳
truth_layer	layer	lr0.0005, ep500, λ1=λ2=0.001	11→63.7%，23→**84.3%**，35→63.0%	23 → 84.3%

world（验证 MSE，越小越好）

组	变量	固定条件	各取值结果	最佳
world_lr	lr	layer11, ep2000, λ1=λ2=0.001	5e-5→239.64，1e-4→186.51，2e-4→162.32，5e-4→150.94	0.0005 → 150.94
world_epochs	epochs	layer11, lr0.0005, λ1=λ2=0.001	500→177.02，1000→157.44，2000→150.94，4000→157.74	2000 → 150.94
world_lambda2	λ2	layer11, lr0.0005, ep2000, λ1=0.001	0→150.95，0.001→150.94，0.01→150.84，0.1→150.43	0.1 → 150.43
world_layer	layer	lr0.0002, ep2000, λ1=λ2=0.001	11→162.32，23→**inf（发散）**，35→**inf（发散）**	11

参考基线：用训练集均值预测验证集，MSE≈6622.54（RMSE≈81.4°）；最佳模型 MSE=150.43（RMSE≈12.3°，R^2≈0.977）。

3. 逐超参数分析

3.1 学习率 lr

truth：呈倒 U 形，峰值在 0.005。 63.0% (0.01) → 68.7% (0.005) → 63.7% (0.0005)。过大（0.01）震荡回退，过小（≤0.001）在 500 轮内欠拟合。

world：单调「越大越好」，但上限被迫锁死在 0.0005。 lr 每翻一倍、MSE 明显下降（239.6 → 150.9）；非不想更大，而是 lr=0.001 时梯度直接溢出（此前实验已确认，本次未再越界）。

解读：两个任务合适的 lr 相差一个数量级以上，说明 world 的原始特征尺度不适应固定 lr 的近端梯度法；truth（logistic）因梯度有界（$\sigma' \le 0.25$）对 lr 鲁棒得多。

3.2 训练轮数 epochs

truth：单调上升，2000 轮仍未到顶（67.7% → 73.0%），说明 lr=0.005 下收敛依然很慢，继续加轮数或适当提高 lr 都可能有收益。

world：U 形，2000 最优（177.0 → 157.4 → 150.9 → 157.7）。4000 轮回升不能区分过拟合与优化漂移，但结合 3.5 的数值分析，更可能是接近稳定边界时的数值噪声积累。

通用备注：所有正常运行都跑满了 epochs 上限——模型内的收敛早停（连续两轮 loss 几乎不变）从未在有限结果中触发。因此 **epochs 目前是「训练预算」而非「收敛轮数」**，两个模型都远未真正收敛到驻点。

3.3 L1 正则 λ1（仅对 truth 做了扫描）

70.0%（λ1=0）→ 68.7% → 67.0% → **50.0%（λ1=0.1）**。λ1=0.1 时准确率断崖式跌到随机水平：L1 的次梯度 `λ1·sgn(w)`（与样本量无关的常数项）在 2560 维下把权重持续压向 0，模型退化为只剩偏置。

统计提醒：验证集 300 条，1 个样本约 0.33 个百分点；λ1 从 0 到 0.01 的差异（≈9 个样本）处于噪声边缘，而 20 个百分点的崩溃远非噪声。**推荐 λ1=0（或至多 0.001），且 world 也应复核这一结论。**

3.4 L2 正则 λ2

truth：完全无影响（4 个取值全部 68.7%，连一个样本都没变）。**world：极微弱**（150.95 → 150.43，0.3%，可忽略）。

原因推断：全批量梯度下降 + 轮数受限下还没到过拟合阶段，λ2 的收缩力（2λ2·w，w 范数仅 ~25）相对梯度量级太小；且 truth 特征尺度大，正则项占比更小。**在本实验的轮数区间内，L2 不是有效旋钮。**

3.5 隐表征层 layer

truth：layer 23（中层）一枝独秀：84.3%，而 layer 11 / 35 都只有 63%~64%。 相差 21 个百分点（≈63 个样本），远超统计噪声。说明 Qwen3-4B-Base 对「句子真假」的线性编码在中层最清晰：浅层还是低阶词法特征，深层（RMSNorm 前）表征幅度大且高度非线性/被后续计算重塑。

world：只有 layer 11 能稳定训练（MSE 162.3），layer 23/35 在 lr=0.0002 下发散。这不代表深层不含空间信息，而是**数值上根本训不动**——见下一节。

注意混杂因素：layer 扫描被钉死在 lr=0.0005（truth_lr 组显示这是偏小的 lr），且只用了 500 轮。layer 23 的 84.3% 很可能被低估；layer 间的相对优劣也可能随 lr 变化。

4. world 深层发散问题的完整证据链

现象：`world_layer` 组 lr=0.0002、epochs=2000 下，layer 23 在第 263 轮、layer 35 在第 71 轮后 MSE 变为 `inf`（wall time 仅 1.1s / 0.3s）。

证据 1（日志）：`Training converged at epoch 263, loss=inf`。这是收敛判据的缺陷——`np.isclose(inf, inf)` 返回 True，把「损失溢出」误报成「收敛」。

证据 2（权重实测）：发散 run 的权重并未变成 `nan`，而是有限但天文数字级的爆炸：

运行	max|w|	||w|
layer 11（正常）	2.50	21.9
layer 23（发散）	1.8e151	4.9e151
layer 35（发散）	7.9e152	5.9e153

因此 `run_grid.py` 里「权重是否有限」的 `finite` 检查误报 True；同一原因，日志头部出现 `residual**2` 与 MSE 计算的 `overflow` RuntimeWarning（w 大 → 预测大 → 平方溢出为 inf）。

证据 3（特征幅度，本机复测）：

layer	world 行范数均值	world ~$\|\|X\|\|_2$	truth 行范数均值	truth ~$\|\|X\|\|_2$
11	51.3	958	42.1	2627
23	118.5	2444	102.9	6182
35	623.4	13428	824.7	55013

残差流幅度随深度快速增长（world 从 51 → 623，约 12 倍）。全批量梯度下降的稳定条件约为 **lr < 2N/$\|X\|_2^2$**，代入 world（N=500）：

- layer 11：lr_max ≈ 5.4e-4 —— 观测吻合：0.0005 稳定（贴线），0.001 溢出；
- layer 23：lr_max ≈ 8.4e-5 —— 实测用 0.0002（超 2.4 倍）→ 收敛前爆炸；
- layer 35：lr_max ≈ 2.8e-6 —— 实测超 70 倍 → 71 轮即炸。

结论：这不是「深层没有信息」，而是**未标准化特征 + 固定 lr 下的纯数值稳定性问题**。修复顺序应是先数值、再调参、最后比较层间信息量。

5. 推荐配置

任务	layer	lr	epochs	λ1	λ2	验证指标
truth	**23**	**0.005**（需在 layer 23 复核，见下）	**≥2000**	**0**（≤0.001）	任意（建议 0.001）	acc **84.3%**
world	**11**	**0.0005**（当前上限；标准化后可放宽）	**2000**	未扫描	0.1（收益微弱）	MSE **150.43**

诚实说明：以上是**扫描网格内**的最优；truth 的 84.3% 取自 layer 扫描组（lr=0.0005、500 轮——该组 lr 偏小、轮数偏少），与 truth_lr / truth_epochs 的结论叠加后，**在 layer 23 上用 lr≈0.005 + 2000 轮的真实上限几乎可以肯定高于 84.3%**，这正是下一步最值得做的实验。

6. 下一步建议（按优先级）

1. **修数值判据（两处小 bug）**：`model.py` 收敛判断加 `np.isfinite(loss)`（当前 `isclose(inf, inf)` 假收敛）；`run_grid.py` 的 `finite` 改为基于预测/指标是否有限，而非只看权重。
2. **world 特征标准化后重扫 layer**：对每层特征做 z-score（或按行范数归一化），重新扫 layer 11/23/35 × lr。预期：深层解锁、MSE 显著下降、lr 可提高一两个数量级。这也是提高 world 成绩的主要抓手。
3. **truth 在 layer 23 上联合精调**：lr ∈ {0.002, 0.005, 0.01} × epochs ∈ {1000, 2000, 4000}；层数可加密到 {18, 21, 23, 26, 28} 找峰。
4. **交叉验证手写实现**：用 sklearn 的 `Ridge`/`LogisticRegression`（正则约定需折算）对同一特征跑一遍，确认梯度与正则实现无系统性偏差（文档允许）。
5. **补充学习曲线**：记录每 epoch 训练/验证损失，用于回答「73.0% 是否仍在上升」「world 4000 轮回升是过拟合还是数值漂移」这两个悬而未决的问题。

7. 图表与复现

- 已生成的图（PNG 200dpi + PDF）：`plots/truth_grid.*`、`plots/world_grid.*`（每任务 2×3 汇总），`plots/per_group/*`（9 组单图）。
- 重新出图：`python experiments/plot_grid.py`
- 重跑扫描：`python experiments/run_grid.py --config experiments/hparam_grid.json`
- **计时说明**：`seconds` 字段受共享节点负载影响极大（同样 500 轮，truth 从 22.7s 到 161.6s 不等），只能说明数量级，不可作为算法成本比较。
- 完整明细以 `summary.csv` / `results.json` 为准。